FTN · Novi Sad · 2026

Linearna regresija

Aleksandar Kovačević

UVOD

Koliko košta stan?

Zamislite da radite u agenciji za nekretnine i neko vas pita za cenu stana.



Stan 1

40 m²

66.000 €



Stan 2

60 m²

102.000 €



Stan 3

95 m²

148.000 €



Novi stan

75 m²

cena: ?

Znamo cene stanova koji su već prodati. Možemo li iz njih da procenimo cenu stana koji tek treba da se proda?

Upravo to radi regresija: iz poznatih podataka izvodi pravilo kojim procenjujemo nepoznatu vrednost.

PODACI

Podaci: stanovi čije cene znamo

Prikupili smo podatke o 8 stanova koji su nedavno prodati.

Stan	Kvadratura (m^2)	Cena (hiljade €)
1	30	58
2	40	66
3	45	82
4	55	88
5	60	102
6	70	108
7	80	131
8	95	148

Svaki red tabele je jedan stan.

x **Kvadratura (x)**

Ono što znamo unapred. Zove se ulaz ili prediktor.

y **Cena (y)**

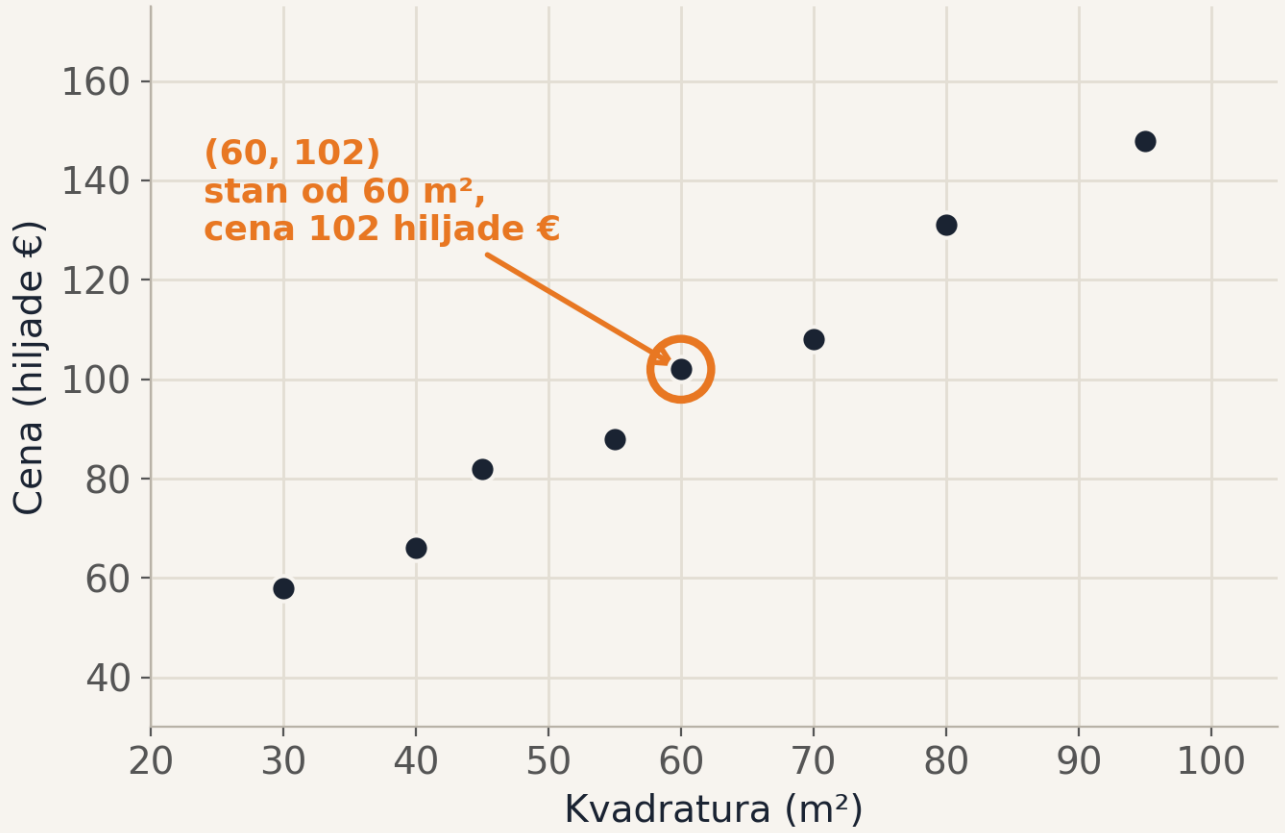
Ono što želimo da predvidimo. Zove se izlaz.

Počinjemo jednostavno: samo jedan ulaz (kvadratura), tj. jedan prediktor.

GRAFIK

Iz tabele u grafik

Svaki stan postaje jedna tačka: vodoravno kvadratura, uspravno cena.



Kako čitamo grafik:

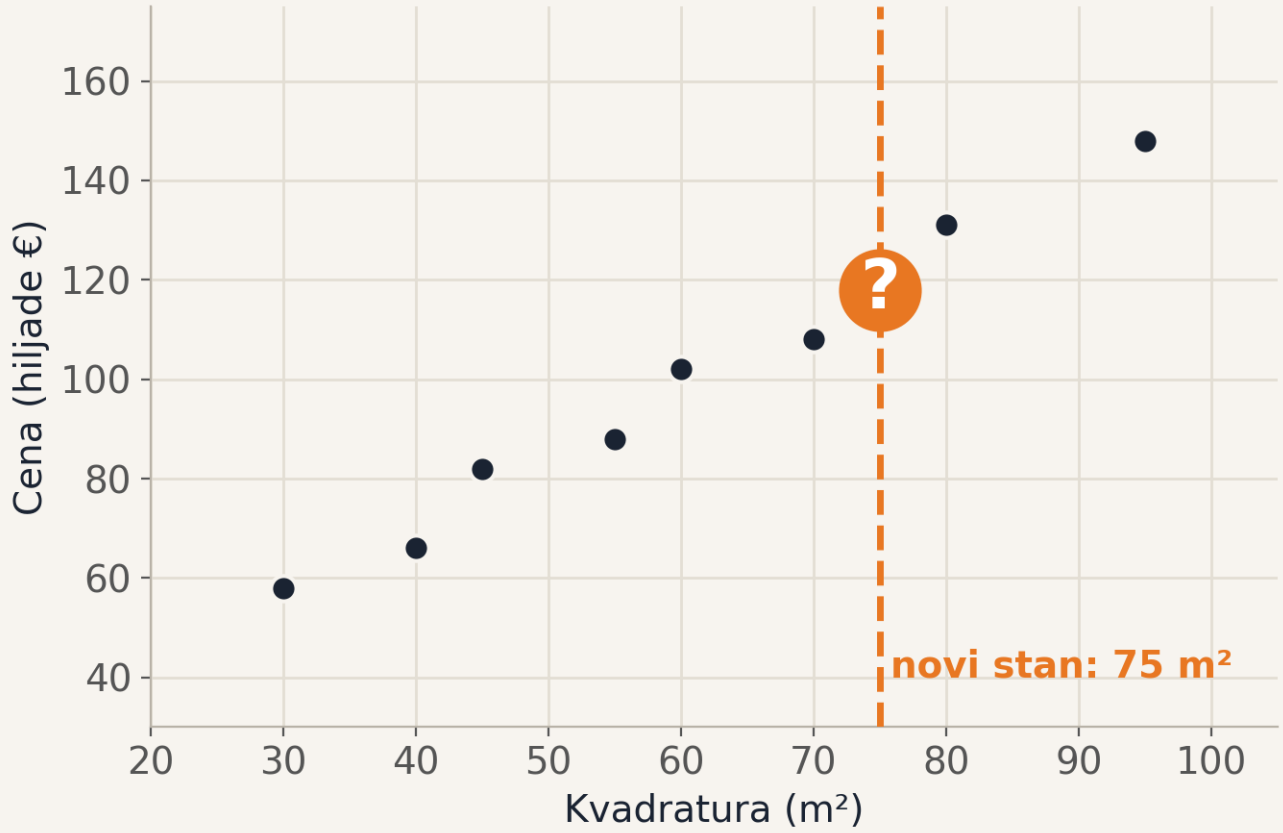
- Svaka tačka je jedan stan.
- Što je tačka više desno, stan je veći.
- Što je tačka više gore, stan je skuplji.

Primer: tačka (60, 102) je stan od 60 m^2 koji je prodat za 102 hiljade €.

PROBLEM

Kolika je cena novog stana?

Stan od 75 m^2 nije u našoj tabeli. Šta iz podataka možemo da zaključimo?



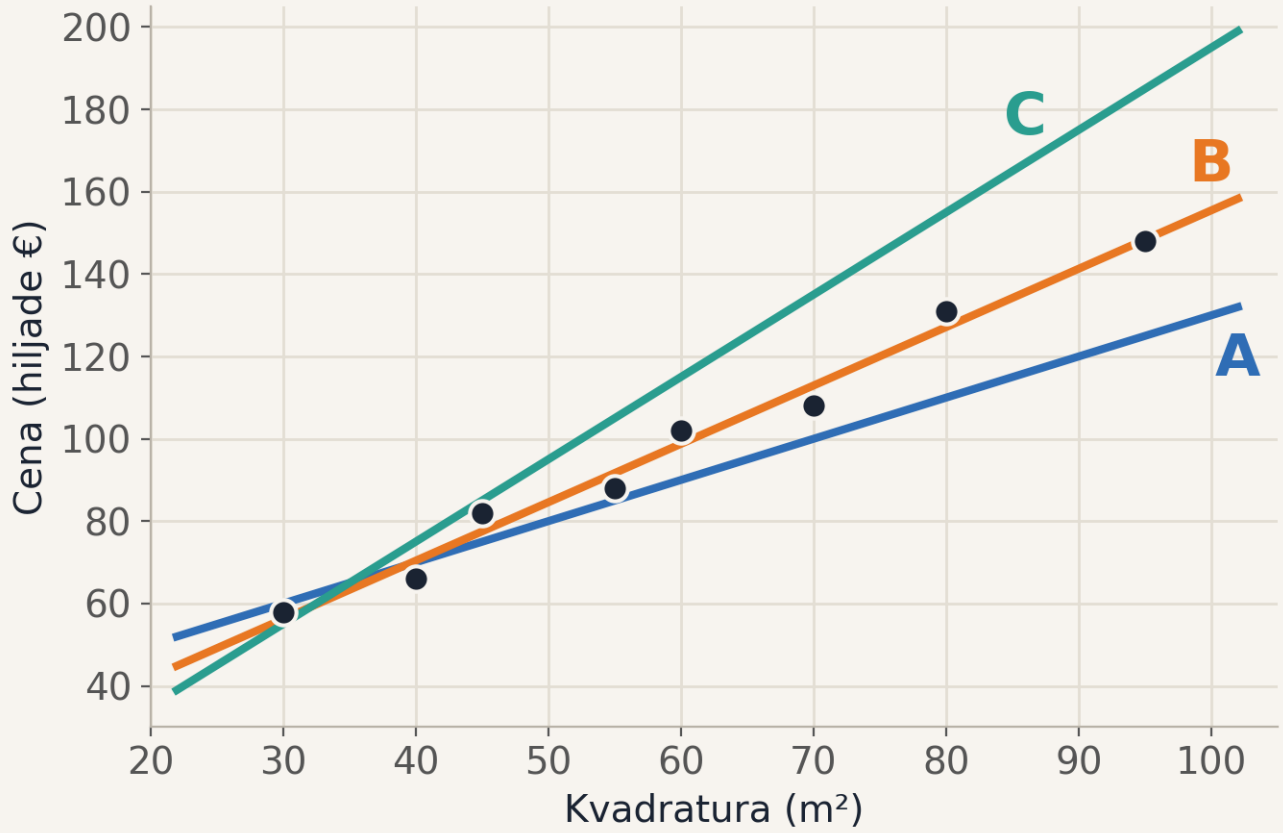
- Tačno takav stan nismo videli: nema ga među podacima.
- Ali vidimo trend: veći stanovi su skuplji.
- Tačke ne leže tačno na jednoj liniji, jer na cenu utiču i lokacija, sprat, godina gradnje...

Ideja: provući pravu kroz oblak tačaka i sa nje očitati cenu.

IDEJA

Koja prava najbolje opisuje podatke?

Kroz iste tačke možemo da povučemo mnogo pravih. Koju da izaberemo?



A Prava A: većina tačaka je iznad nje.

B Prava B: prolazi blizu većine tačaka.

C Prava C: većina tačaka je ispod nje.

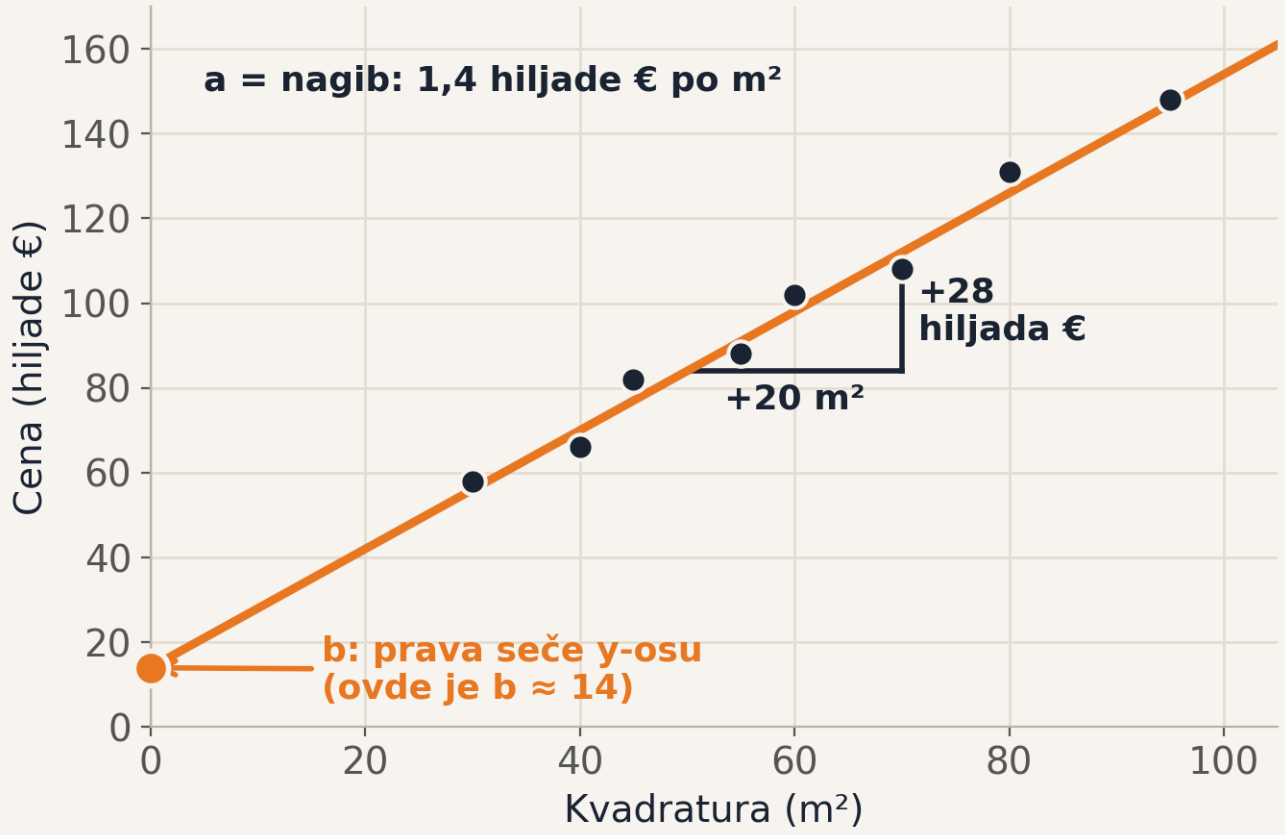
Okom vidimo da je B bolja. Ali računar ne gleda grafik.

Treba nam broj koji meri koliko je prava dobra.

PRAVA

Prava je formula sa dva broja

Svaka prava ima jednačinu cena = a · kvadratura + b. Birajući a i b dobijamo drugu pravu.



$$y = a \cdot x + b$$

a (nagib): za koliko hiljada € poraste cena kad stan bude veći za 1 m^2.

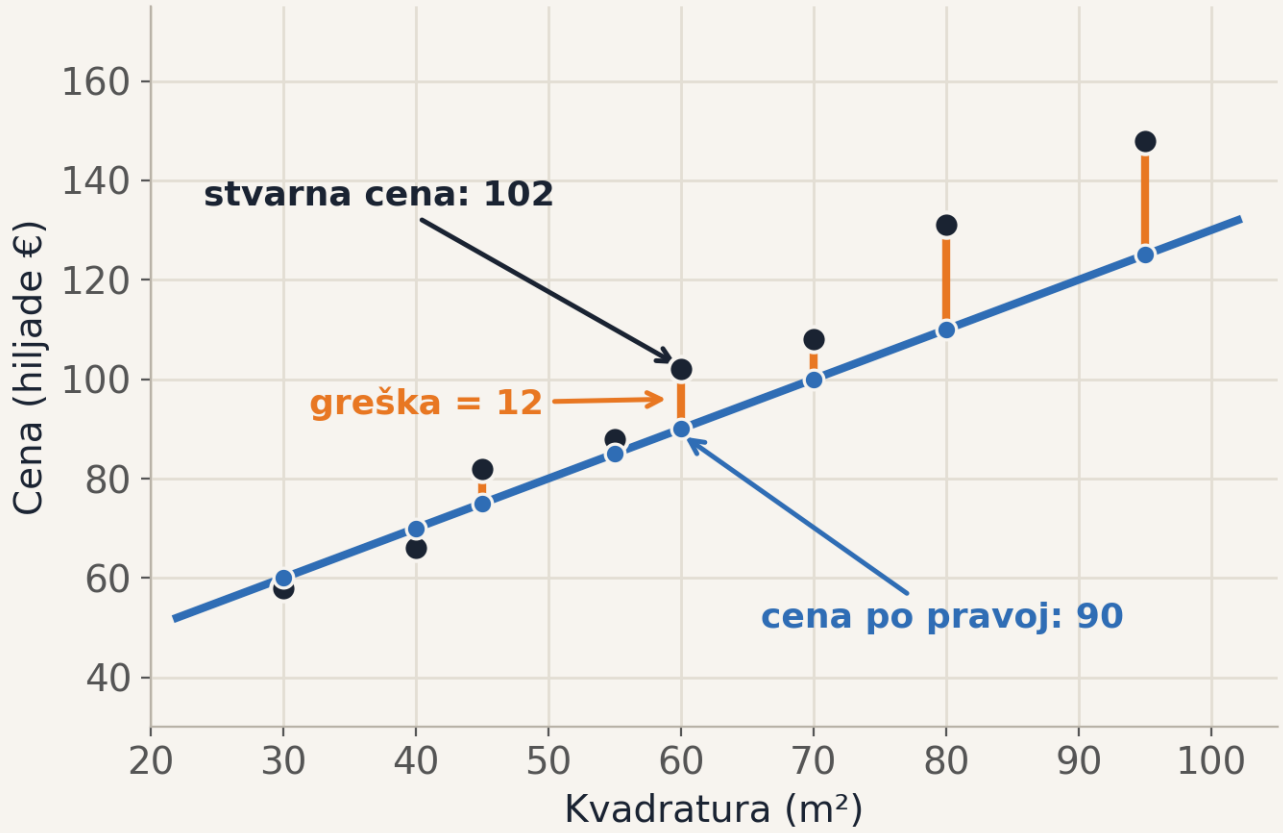
b (početak): vrednost prave kad je x = 0, tačka gde prava seče y-osu.

Cilj regresije: naći a i b za koje je prava najbolja.

GREŠKA

Koliko pogrešimo?

Za pravu A poredimo stvarnu cenu svakog stana sa cenom koju prava predviđa.



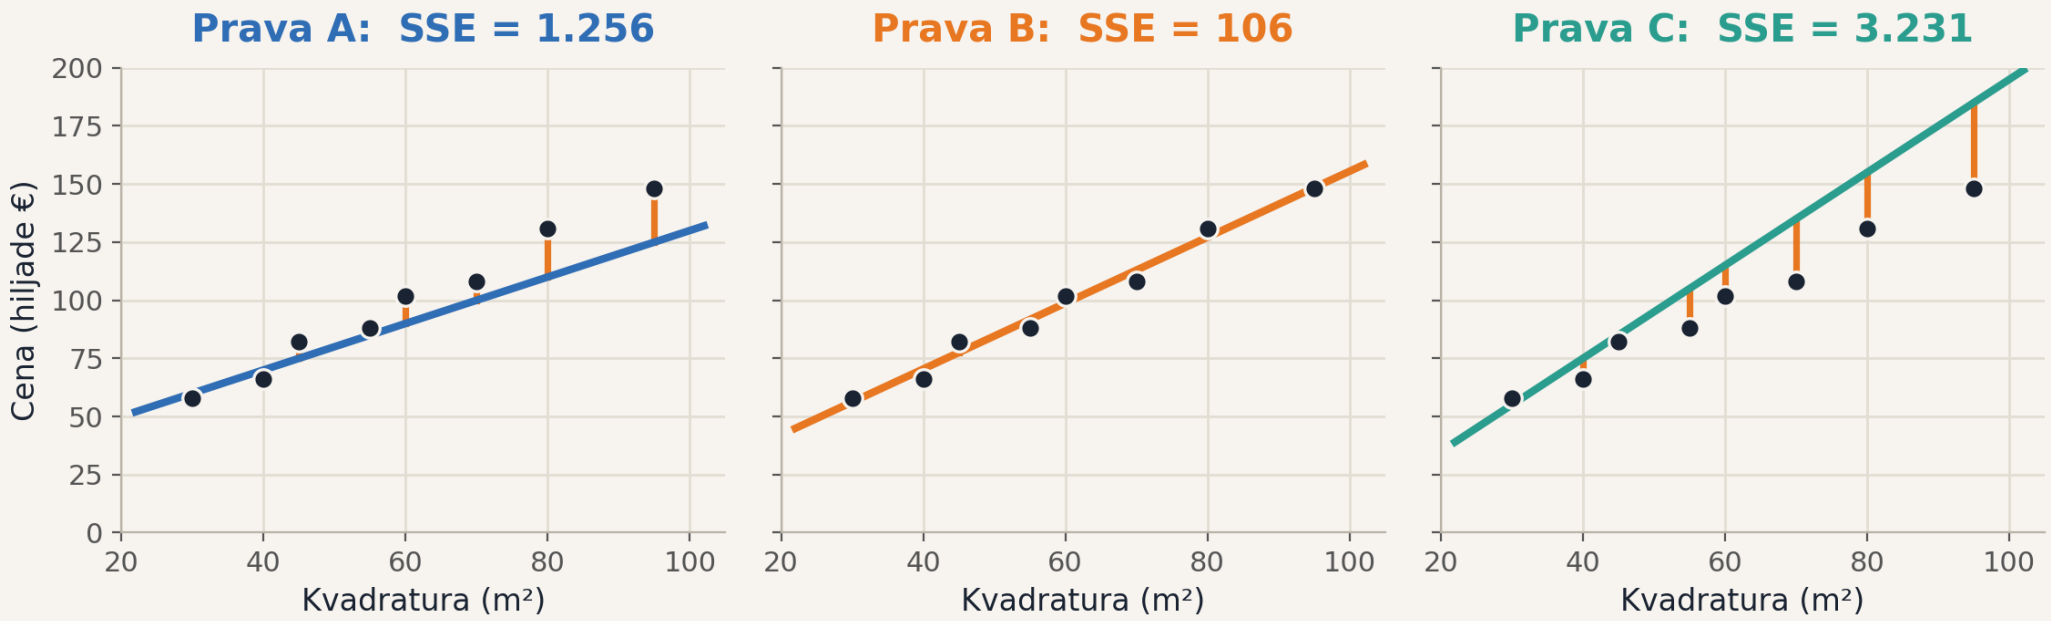
- **Stvarna cena:** za koliko je stan zaista prodat.
- **Predviđena cena:** šta prava kaže za istu kvadraturu.
- **Greška = stvarna − predviđena.**

Stan od 60 m²: 102 − 90 = 12 hiljada €.

Svaka narandžasta duž je greška jednog stana.

Najbolja prava ima najmanju ukupnu grešku

Greške svih stanova sabiramo, ali ih prethodno kvadriramo.



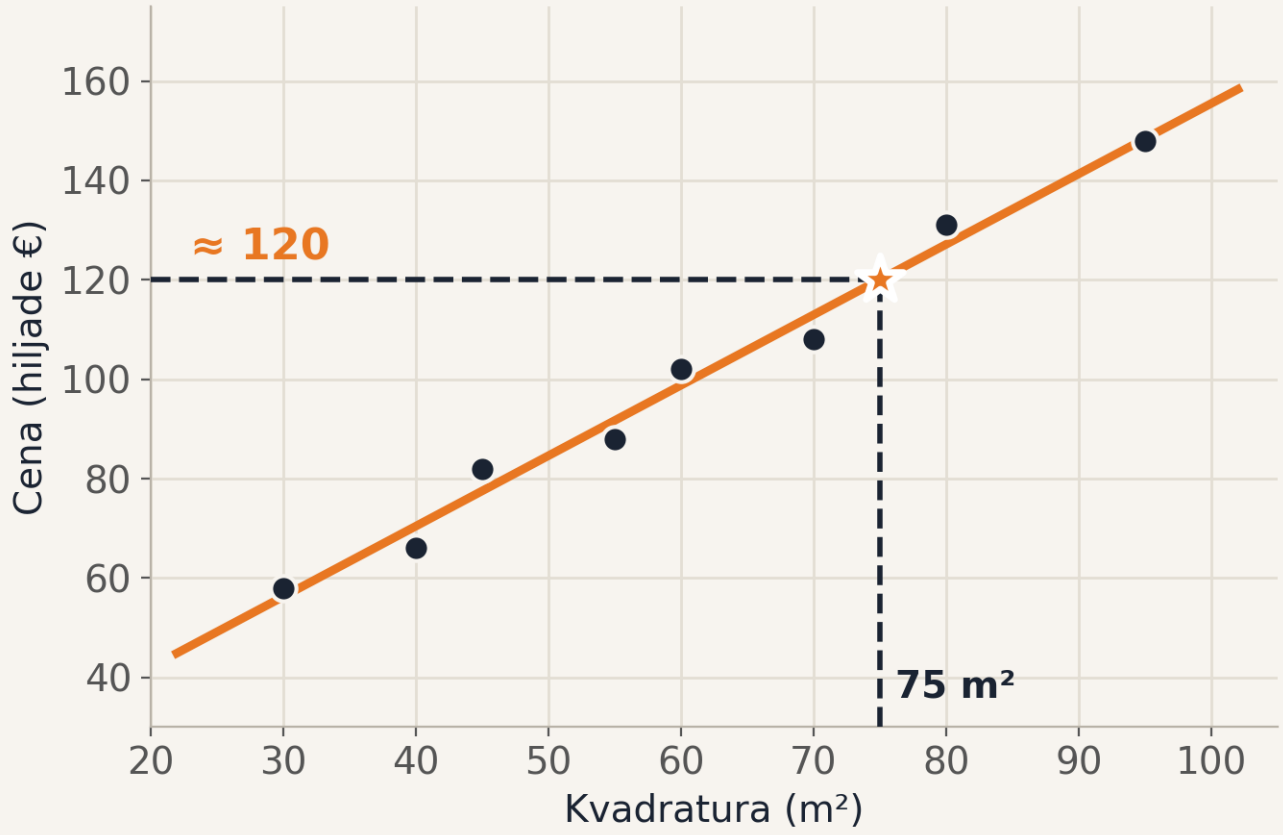
SSE = (greška 1)^2 + (greška 2)^2 + … + (greška 8)^2

Kvadriranjem se pozitivne i negativne greške ne poništavaju, a velike greške se kažnjavaju više. Najbolja je prava sa najmanjim SSE: prava B.

PREDVIĐANJE

Najbolja prava daje procenu cene

Stan od 75 m^2 treba da košta oko 120 hiljada €.



cena ≈ 1,42 · x + 13,7

x = 75: 1,42 · 75 + 13,7 ≈ 120

To je linearna regresija:

1. podaci: kvadratura i cena
2. prava koja ih najbolje uklapa
3. predviđanje cene novog stana

Sledeće: pregled pojmova, pa kako se a i b računaju.

OPŠTI PROBLEM

Ulazi regresije

Za date podatke, oblik funkcije i kriterijum uklapanja — odredi nepoznate parametre.

01	**Podaci**	(x_i, y_i), $i = 1 \ldots n$
02	**Oblik funkcije**	prava, parabola, polinom, proizvoljna baza…
03	**Kriterijum**	mera „najboljeg uklapanja“ (npr. najmanji kvadrati)

Prava g(x) = ax + b

Tražimo a i b tako da funkcija greške Φ(a,b) bude minimalna.

Metod za određivanje koeficijenata prikazujemo za slučaj prave.

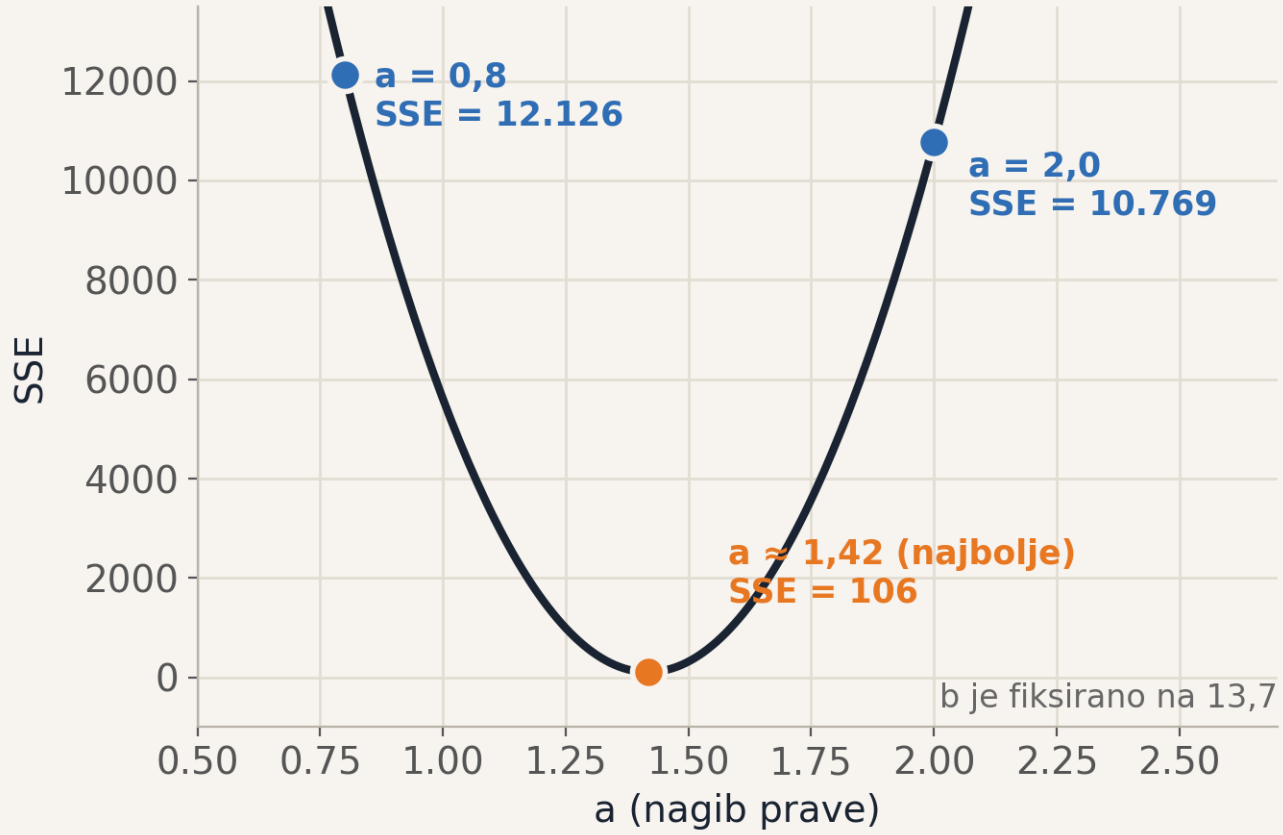
- Zadatak: odrediti a i b tako da je vrednost funkcije greške minimalna.
- Vrednost greške zavisi isključivo od a i b — x_i, y_i su date konstante (podaci koje imamo).

$$f(x) = ax + b$$

$$\Phi(a,b) = \sum_{i=1}^{n} (b + ax_i - y_i)^2$$

Kako da nađemo najbolje a i b?

Svaki par (a, b) daje jednu pravu i jednu vrednost SSE.

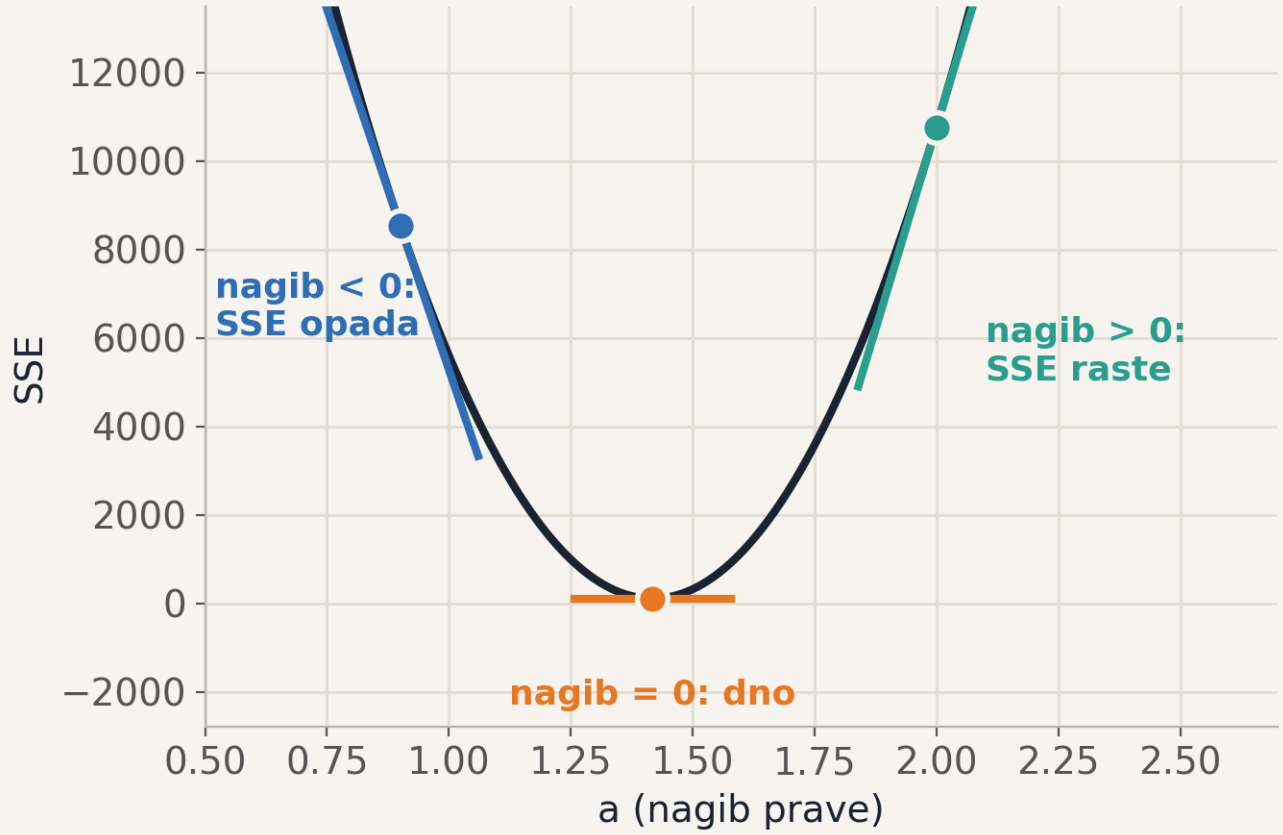


- Menjamo a, a b držimo fiksnim.
- SSE prvo opada, a zatim raste.
- Najbolje a je na dnu krive, gde je SSE najmanja.

Sa oba broja, a i b, kriva postaje „činija“ u prostoru. Ideja je ista: tražimo dno.

Na dnu činije je nagib nula

Dno nalazimo preko nagiba (izvoda) krive, bez crtanja.



- Levo od dna: nagib < 0.
- Desno od dna: nagib > 0.
- Na samom dnu: nagib = 0.

Izvode po a i po b izjednačimo sa nulom: dobijamo 2 jednačine sa 2 nepoznate. Izvođenje je u nastavku.

Uslov minimuma: parcijalni izvodi = 0

Da bismo odredili minimum funkcije greške, izjednačavamo parcijalne izvode po a i b sa nulom.

$$\Phi(a,b) = \sum_{i=1}^{n} (b + ax_i - y_i)^2 \qquad \frac{\partial \Phi}{\partial a} = 0, \frac{\partial \Phi}{\partial b} = 0$$

$$\frac{\partial \Phi(a,b)}{\partial a} = \sum_{i=1}^{n} 2\,(b + ax_i - y_i)x_i = 0$$

$$\frac{\partial \Phi(a,b)}{\partial b} = \sum_{i=1}^{n} 2\,(b + ax_i - y_i) = 0$$

Od izvoda do sistema jednačina

Razvijanjem izvoda dobijamo linearni sistem u nepoznatim a i b.

$$\frac{\partial \Phi(a,b)}{\partial a} = \sum_{i=1}^{n} 2\,(b + ax_i - y_i)x_i = 0$$

$$\frac{\partial \Phi(a,b)}{\partial b} = \sum_{i=1}^{n} 2\,(b + ax_i - y_i) = 0$$

$$nb + (\sum_{i=1}^{n} x_i)a = \sum_{i=1}^{n} y_i$$

$$(\sum_{i=1}^{n} x_i)b + (\sum_{i=1}^{n} x_i^2)a = \sum_{i=1}^{n} x_i\, y_i$$

Zatvorene formule za a i b

Rešenje sistema daje eksplicitne izraze za nagib a i odsečak b.

$$a = \frac{n\sum_{i=1}^{n} x_i\, y_i - (\sum_{i=1}^{n} x_i)(\sum_{i=1}^{n} y_i)}{n\sum_{i=1}^{n} x_i^2 - (\sum_{i=1}^{n} x_i)^2}$$

$$b = \frac{1}{n}(\sum_{i=1}^{n} y_i - a\sum_{i=1}^{n} x_i)$$

PRIMER · STANOVI

Računamo a i b za naše stanove

Potrebne su samo četiri sume: Σx, Σy, Σx^2 i Σxy.

x	y	x^2	x · y
30	58	900	1740
40	66	1600	2640
45	82	2025	3690
55	88	3025	4840
60	102	3600	6120
70	108	4900	7560
80	131	6400	10480
95	148	9025	14060
475	**783**	**31475**	**51130**

n = 8 stanova

$a = (n \cdot \Sigma xy - \Sigma x \cdot \Sigma y) / (n \cdot \Sigma x^2 - (\Sigma x)^2)$

$= (8 \cdot 51130 - 475 \cdot 783) / (8 \cdot 31475 - 475^2)$

$= 37115 / 26175 = 1{,}418$

$b = (\Sigma y - a \cdot \Sigma x) / n$

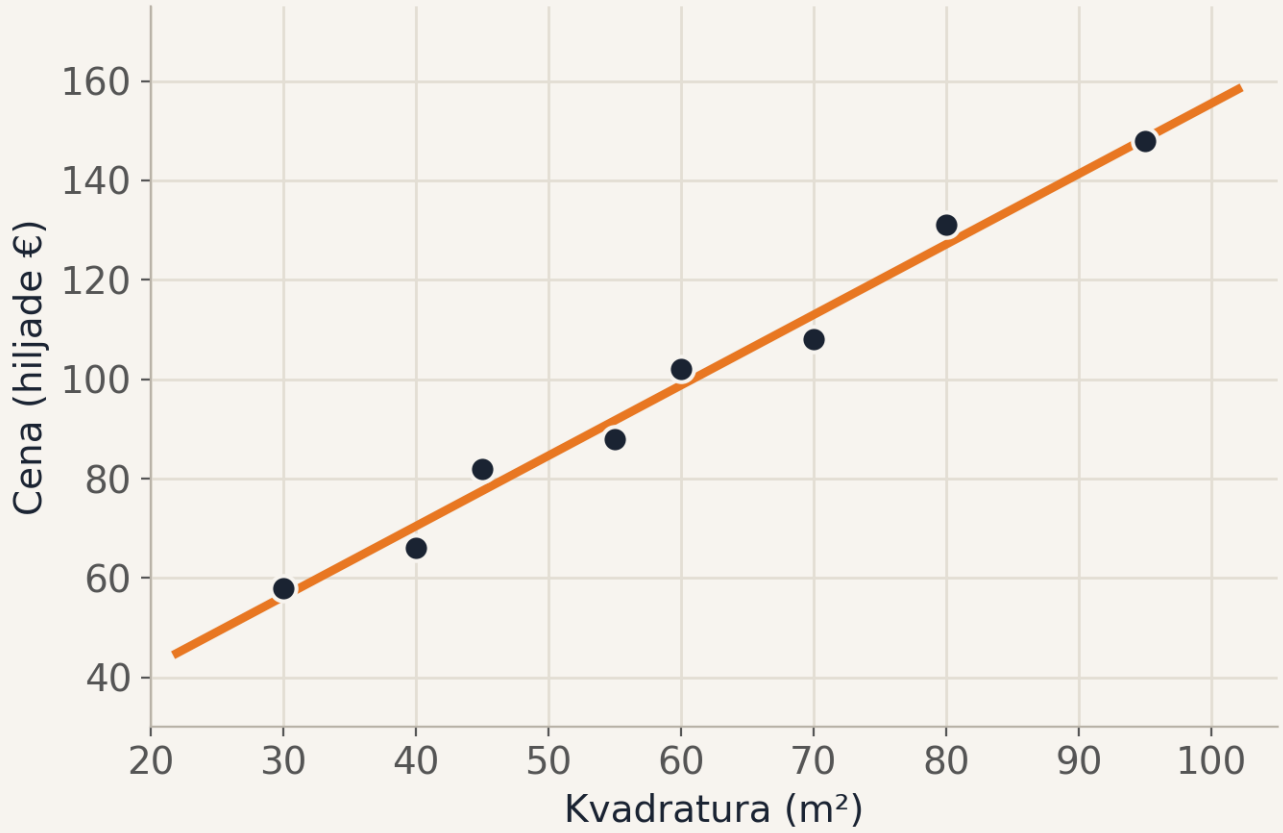
$= (783 - 1{,}418 \cdot 475) / 8 = 13{,}7$

Dobili smo istu pravu kao ranije: cena = 1,42 · kvadratura + 13,7.

KVALITET REGRESIJE

Koliko je naša prava dobra?

Na grafiku izgleda dobro, ali nam treba broj koji to meri.

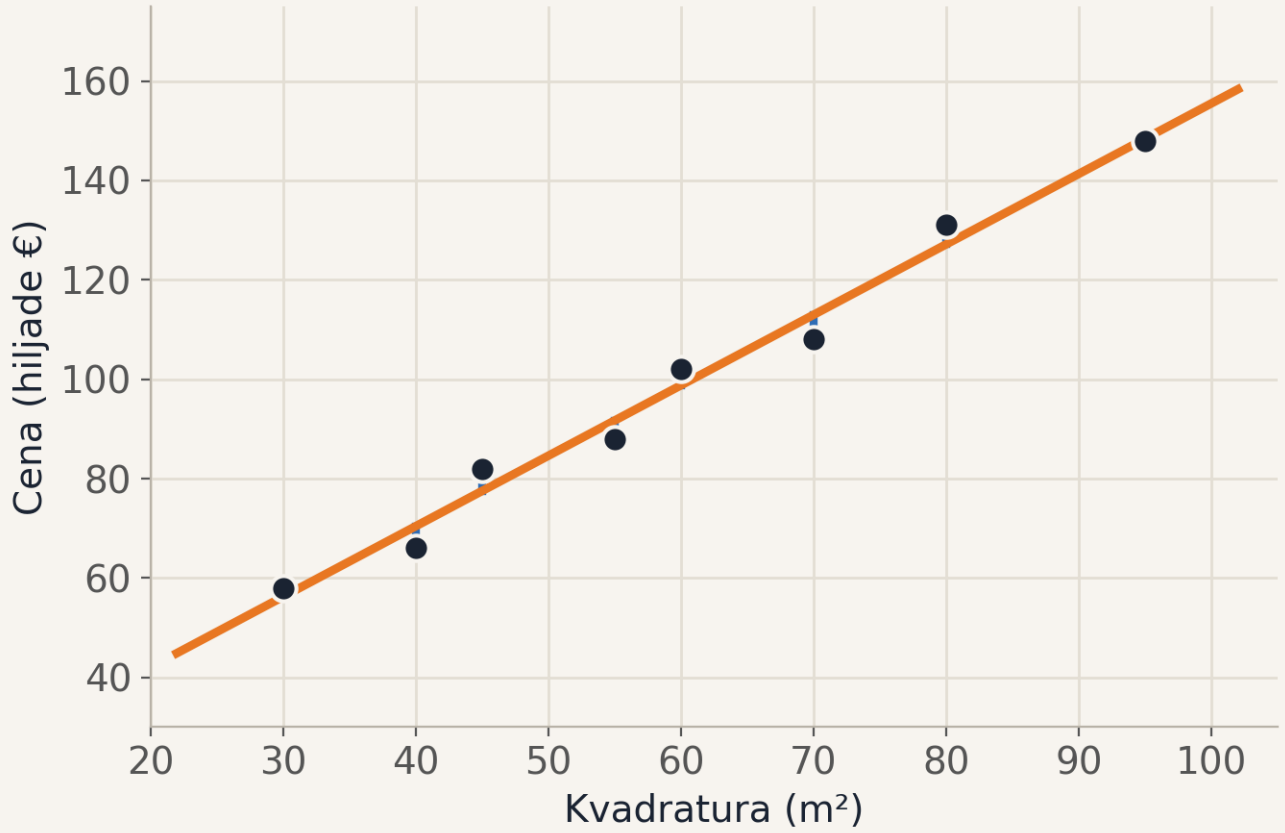


1. Koliko je ukupna greška? (SSE)
2. Da li je ta greška mala ili velika? (SST, R^2)
3. Koliko tipično grešimo, u hiljadama €? (tipična greška)

Odgovore dobijamo u narednih nekoliko slajdova.

SSE: ukupna greška prave

Zbir kvadrata grešaka svih 8 stanova: ono što je regresija minimizovala.



SSE ≈ 106

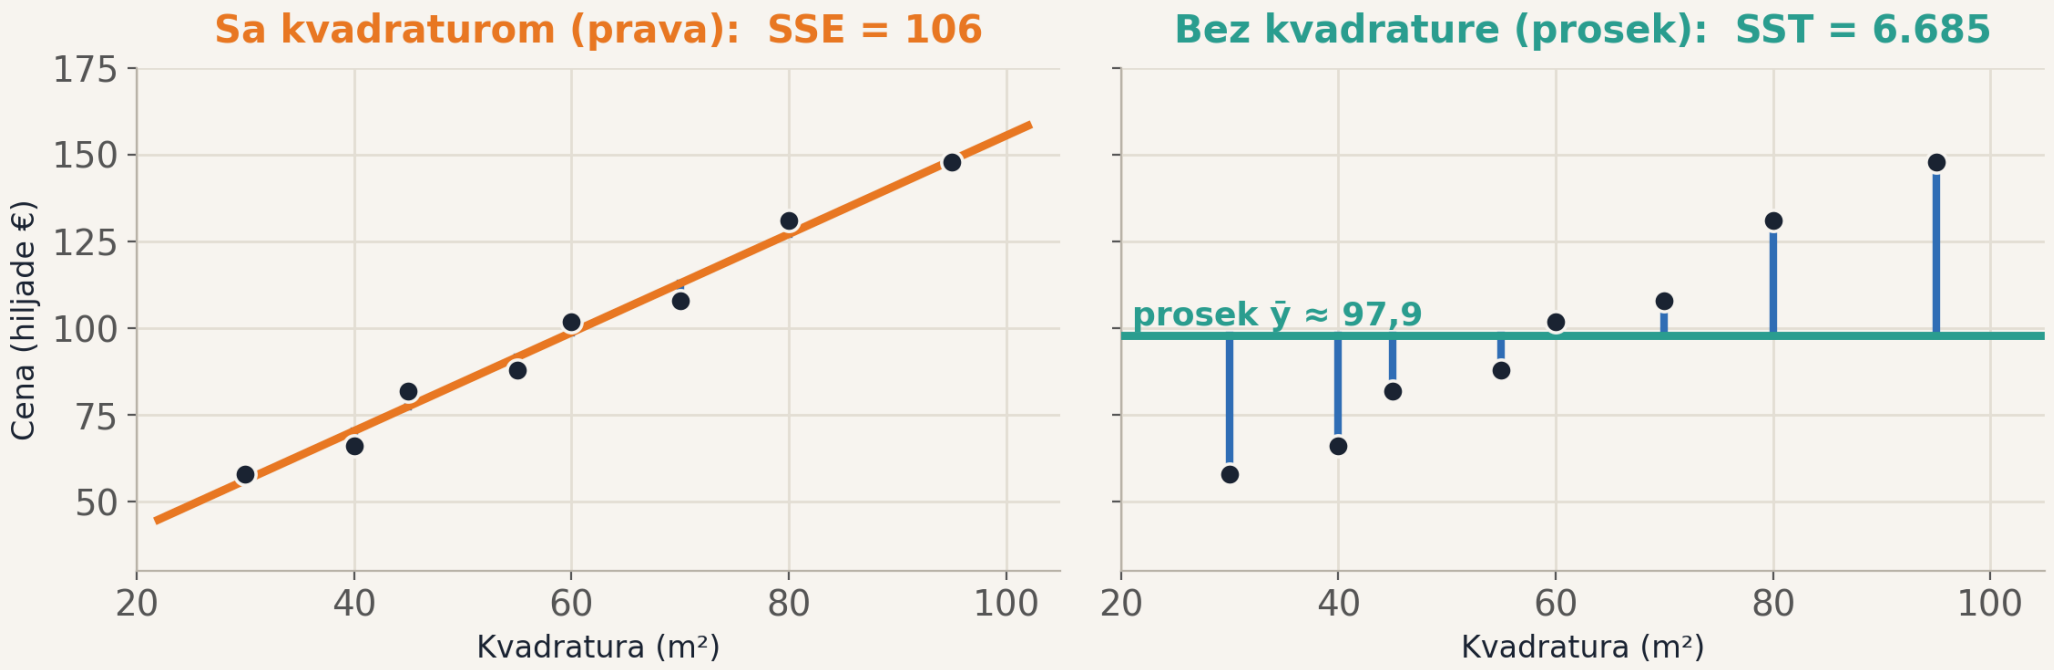
(hiljade €)^2

Da li je 106 mnogo ili malo?

To ne možemo da znamo bez reference za poređenje.

Referenca: procena bez kvadrature

Da ne znamo kvadraturu, za svaki stan bismo predvideli prosečnu cenu.

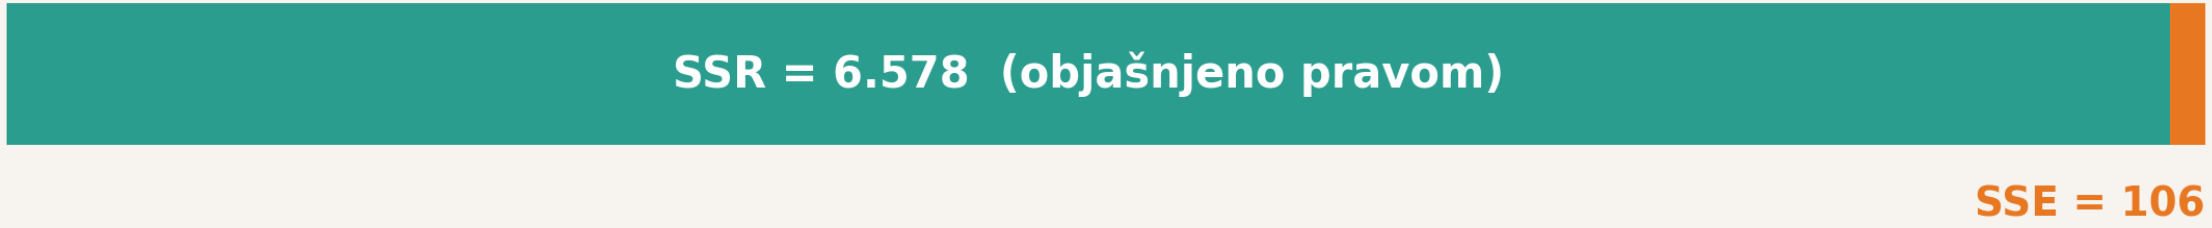


SST je zbir kvadrata odstupanja od proseka. Kvadratura smanjuje grešku sa 6.685 na 106: ulaz zaista pomaže.

R^2: koliko kvadratura objašnjava

R^2 poredi grešku prave (SSE) sa greškom proseka (SST).

SST = 6.685 (ukupne razlike u ceni)



$R^2 = 1 - SSE / SST$

$= 1 - 106 / 6685 \approx 0{,}98$

Kvadratura objašnjava oko 98% razlika u cenama.

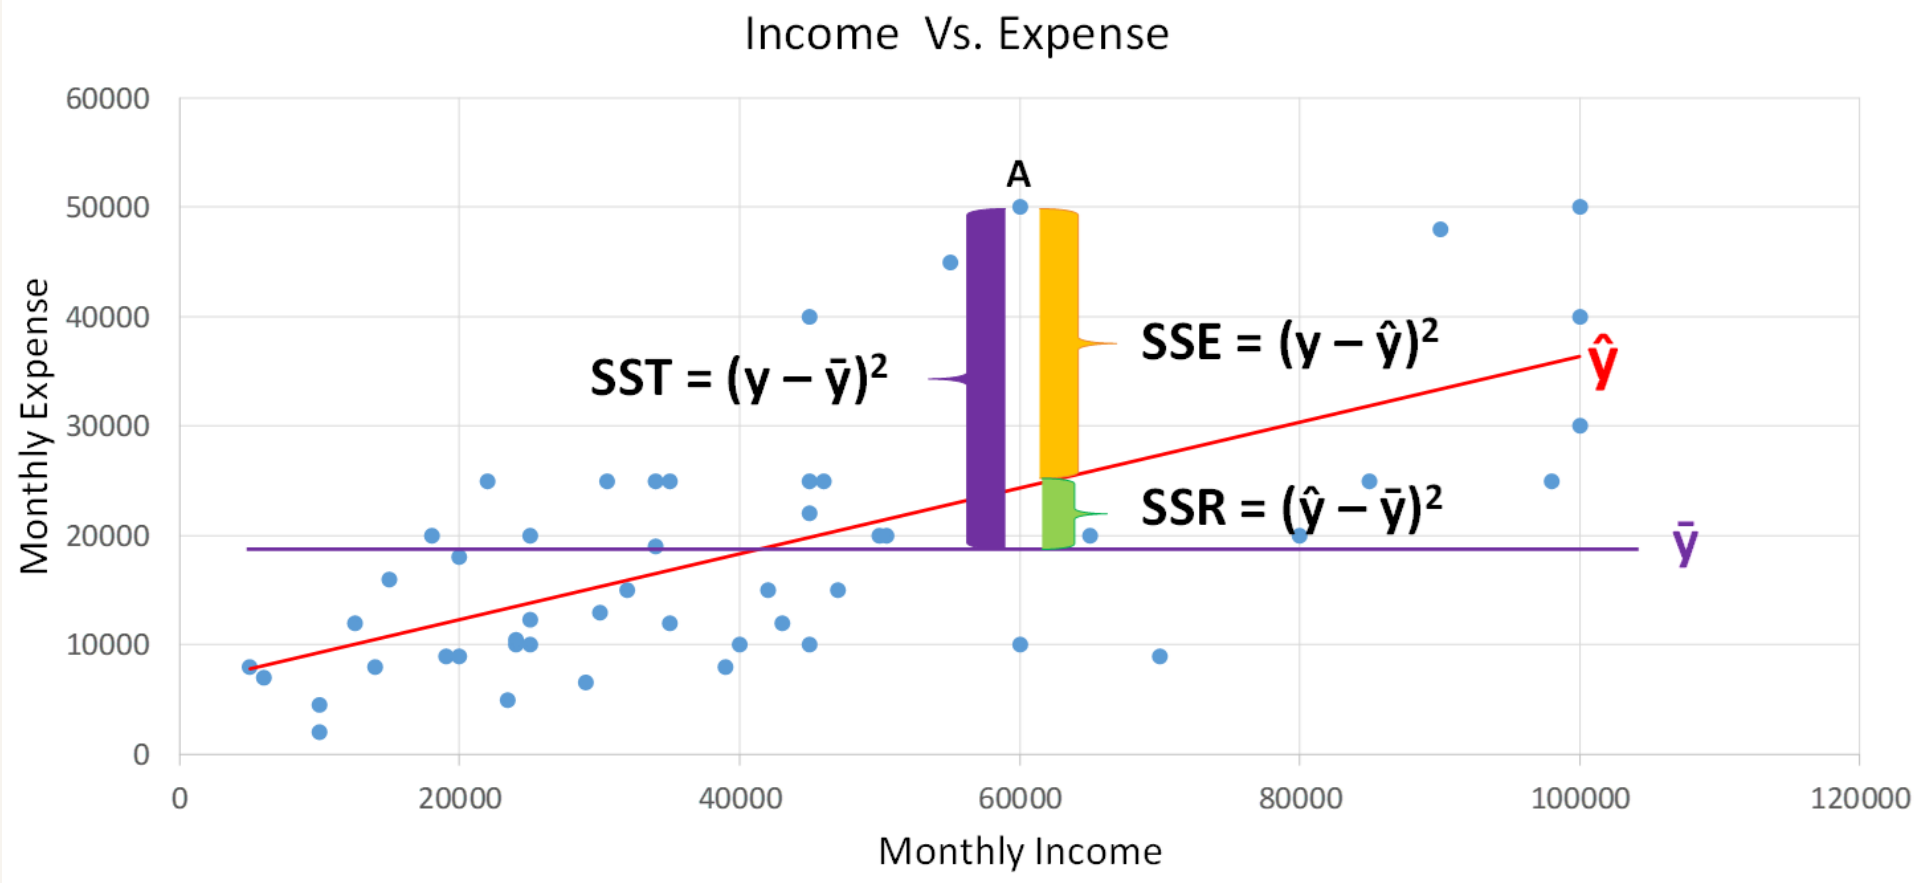
$R^2 = 0$: prava nije bolja od proseka.

$R^2 = 1$: prava savršeno prolazi kroz sve tačke.

Što je R^2 bliže 1, prava je bolja.

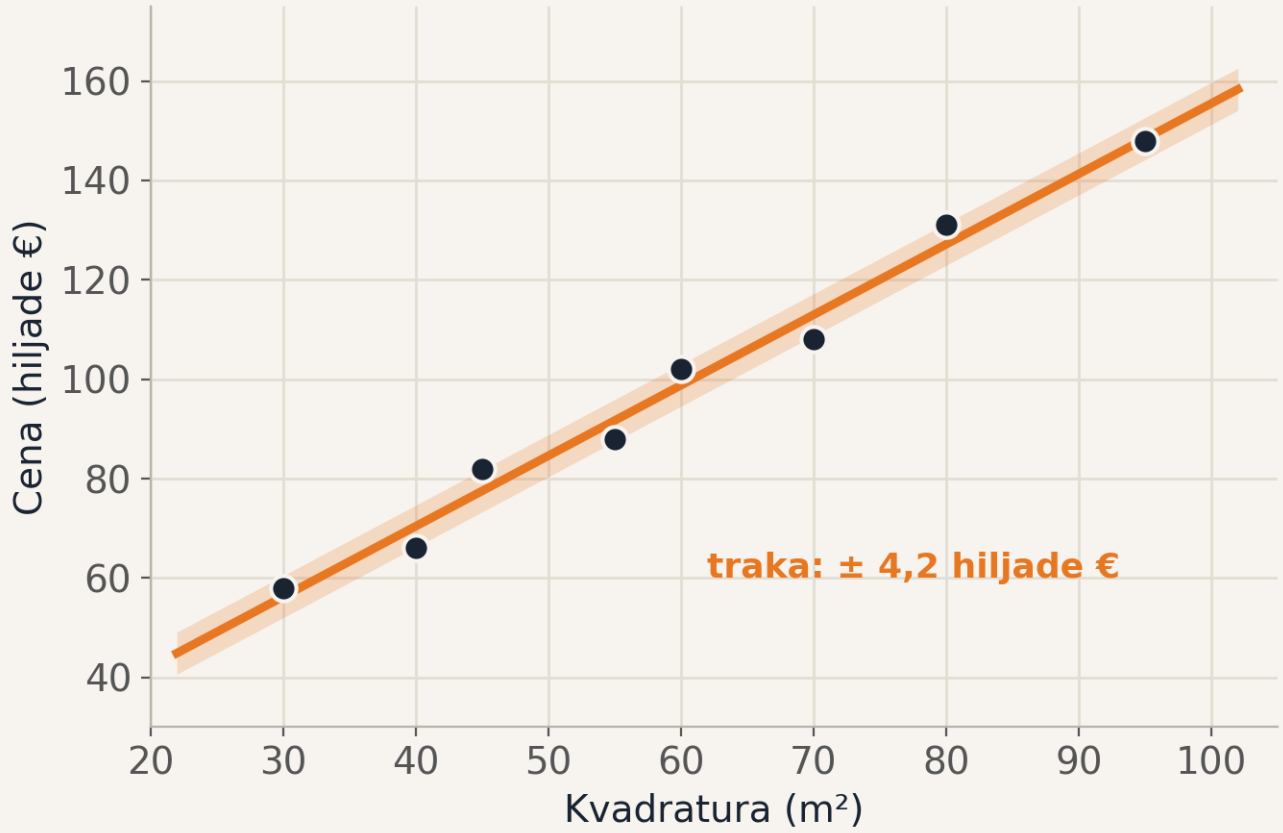
Koeficijent determinacije R^2

R^2 meri deo varijabilnosti y koji objašnjava regresiona jednačina.



Tipična greška procene

Koliko hiljada € se obično mimoilazimo sa stvarnom cenom?



$$s = \sqrt{\frac{\mathrm{SSE}}{\mathrm{n} - \mathrm{m} - 1}}$$

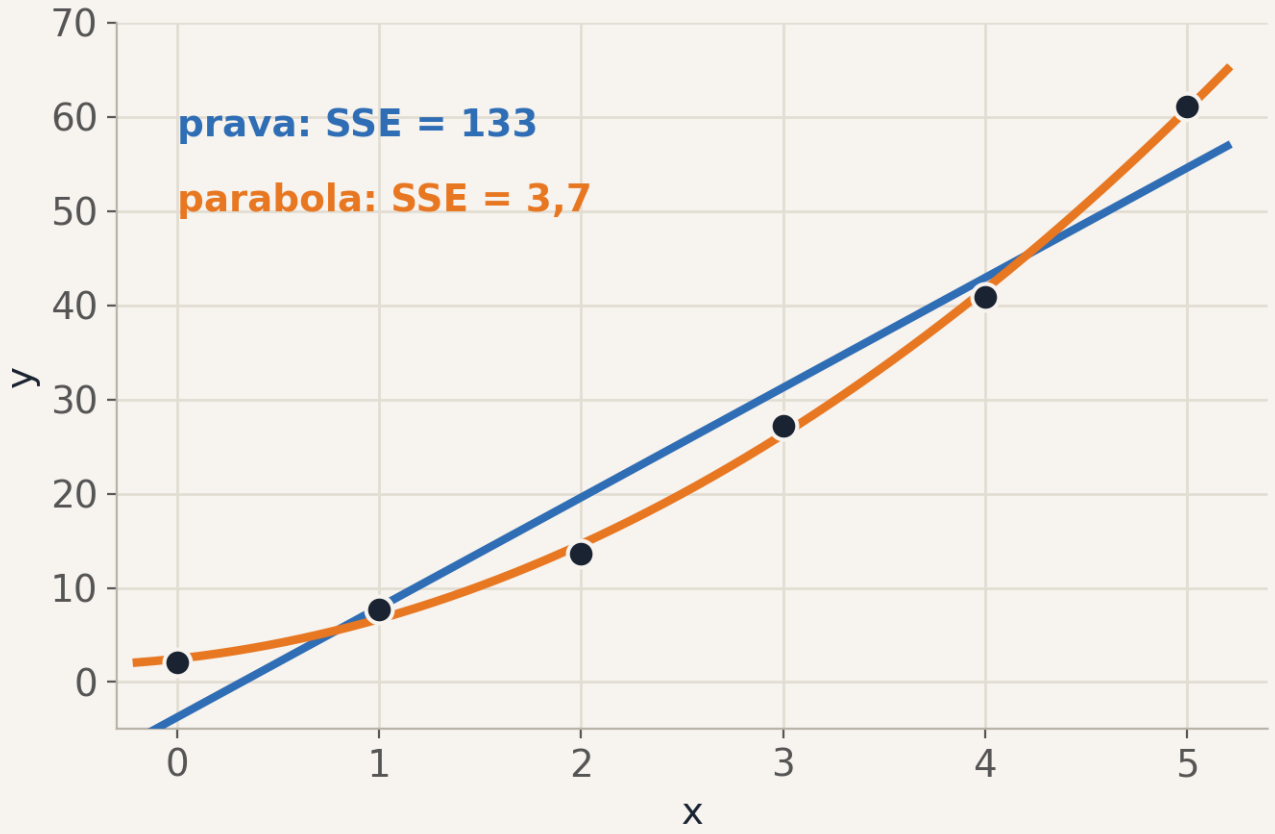
n = 8 stanova, m = 1 prediktor

s = √(106 / 6) = 4,2

Tipično grešimo oko 4 hiljade €, to je oko 4% cene stana od 100 hiljada €.

Kada prava nije dovoljna

Nekad je trend kriv, pa prava loše prati podatke.



- Prava zaostaje za podacima: **SSE = 133.**
- Parabola prati trend: **SSE = 3,7.**
- Biramo oblik funkcije koji odgovara trendu.

Podaci: x = 0, 1, …, 5; y = 2,1; 7,7; 13,6; 27,2; 40,9; 61,1

Postupak je isti, samo imamo više nepoznatih: a, b i c.

Regresija polinomom

Najmanji kvadrati se uopštavaju na polinom proizvoljnog stepena.

Dat je primer polinoma drugog stepena (parabola).

$$f(x) = a + bx + cx^2$$

$$\Phi(a, b, c) = \sum_{i=1}^{n} (a + bx_i + cx_i^2 - y_i)^2$$

POLINOM

Isti postupak, više nepoznatih

Svaki novi koeficijent donosi jednu novu jednačinu.

Prava	$g(x) = a + b \cdot x$	**2 nepoznate**
Parabola	$g(x) = a + b \cdot x + c \cdot x^2$	**3 nepoznate**
Polinom stepena m	$g(x) = a_0 + a_1 \cdot x + \ldots + a_m \cdot x^m$	**m + 1 nepoznata**

Jednačine dobijamo kao i pre: izjednačimo izvode SSE sa nulom. Sistem rešava računar.

PARABOLA · PRIMER

Tabela suma za parabolu

Računamo Σx^k i $\Sigma x^k y$ do reda potrebnog za sistem stepena 2.

$$6a + 15b + 55c = 152.6$$

$$15a + 55b + 225c = 585.6$$

$$55a + 225b + 979c = 2488.8$$

$\Sigma x=15$ · $\Sigma y=152.6$ · $\Sigma x^2=55$ · $\Sigma x^3=225$ · $\Sigma x^4=979$ · $\Sigma xy=585.6$ · $\Sigma x^2y=2488.8$

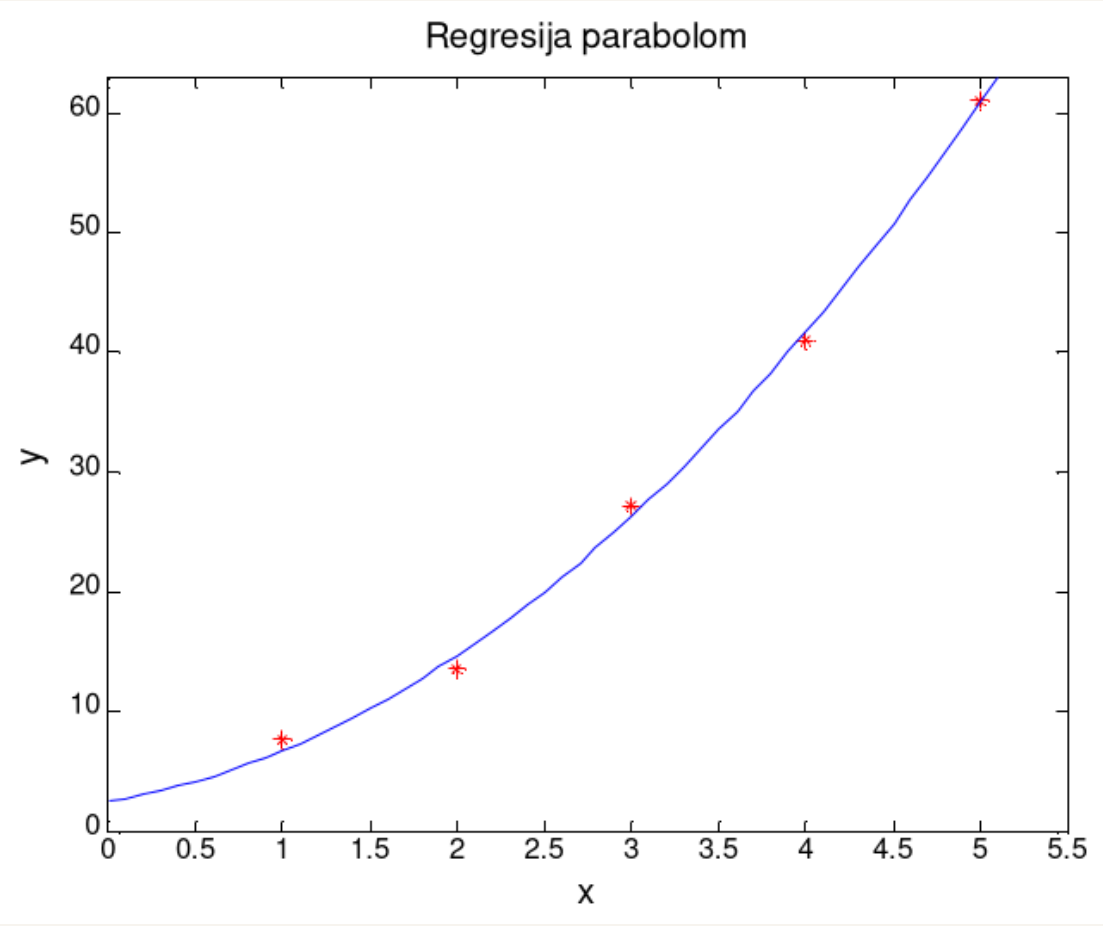
Rešenje sistema i grafik

Dobijamo koeficijente parabole i ucrtavamo fit preko tačaka.

$$a = 2.4786, b = 2.3593, c = 1.8607$$

$$f(x) = 2.4786 + 2.3593x + 1.8607x^2$$

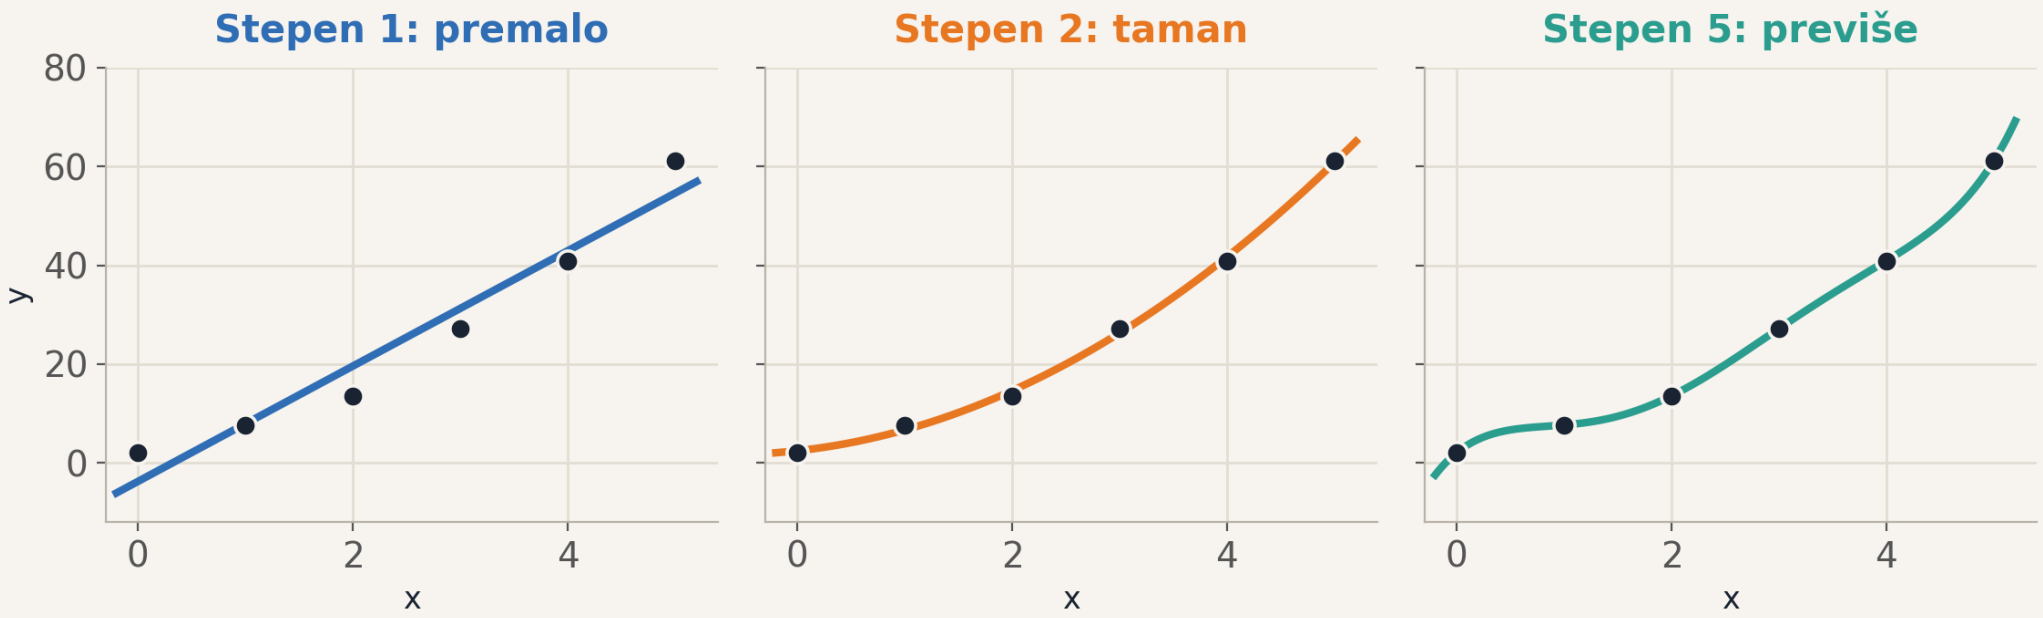
Rešavamo 3×3 sistem normalnih jednačina.



POLINOM

Koji stepen polinoma izabrati?

Stepen biramo mi, a veći stepen nije uvek bolji.



Kroz n tačaka uvek prolazi polinom stepena n − 1 (interpolacija).

Ali on prati i slučajne oscilacije. U regresiji tražimo jednostavan model: stepen m ≪ n.

POLINOM PROIZVOLJNOG STEPENA

Cilj: stepen m ≪ n

Dato n tačaka — uklapamo polinom stepena m (m ≤ n−1). Cilj nam je da minimizujemo grešku.

Za razliku od interpolacije, stepen biramo mi — obično m ≪ n.

Opšti oblik polinoma:

$$\varphi(x) = \sum_{j=0}^{m} a_j \, x^j$$

Normalne jednačine — sažetak

Rešenjem sistema dobijamo koeficijente polinoma stepena m.

$$\left(A^T \cdot A\right) \cdot a = A^T \cdot y,$$

gde je:

$$A = \begin{bmatrix} x_1^0 & x_1^1 & \cdots & x_1^M \\ x_2^0 & x_2^1 & \cdots & x_2^M \\ \vdots & \vdots & \ddots & \vdots \\ x_N^0 & x_N^1 & \cdots & x_N^M \end{bmatrix}_{N\times(M+1)}, \quad a = \begin{bmatrix} a_0 \\ a_1 \\ \vdots \\ a_M \end{bmatrix}_{(M+1)\times 1}, \quad y = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_N \end{bmatrix}_{N\times 1}$$

IMPLEMENTACIJA

Python: lsquares

Gradimo matricu A stepenima x, pa rešavamo $(A^TA)p = A^Ty$.

```
def lsquares(x,y,stepen):
    n=len(x)
    A=np.zeros([n,stepen+1])

    for i in range(n):
        for j in range(stepen+1):
            A[i,j]=x[i]**j

    p=la.solve(np.matmul(A.T, A), np.matmul(A.T, y.T))
    p=np.flip(p)

    return p
```

PRIMER

Ista parabola — opštim metodom

Zadajemo stepen 2; dobijamo isti polinom kao ranije pri ručnom rešavanju.

x_i: 0, 1, 2, 3, 4, 5

y_i: 2.1, 7.7, 13.6, 27.2, 40.9, 61.1

Za razliku od interpolacije, stepen biramo sami.

```
import numpy as np
from matplotlib import pyplot as plt
from numpy.core.function_base import linspace

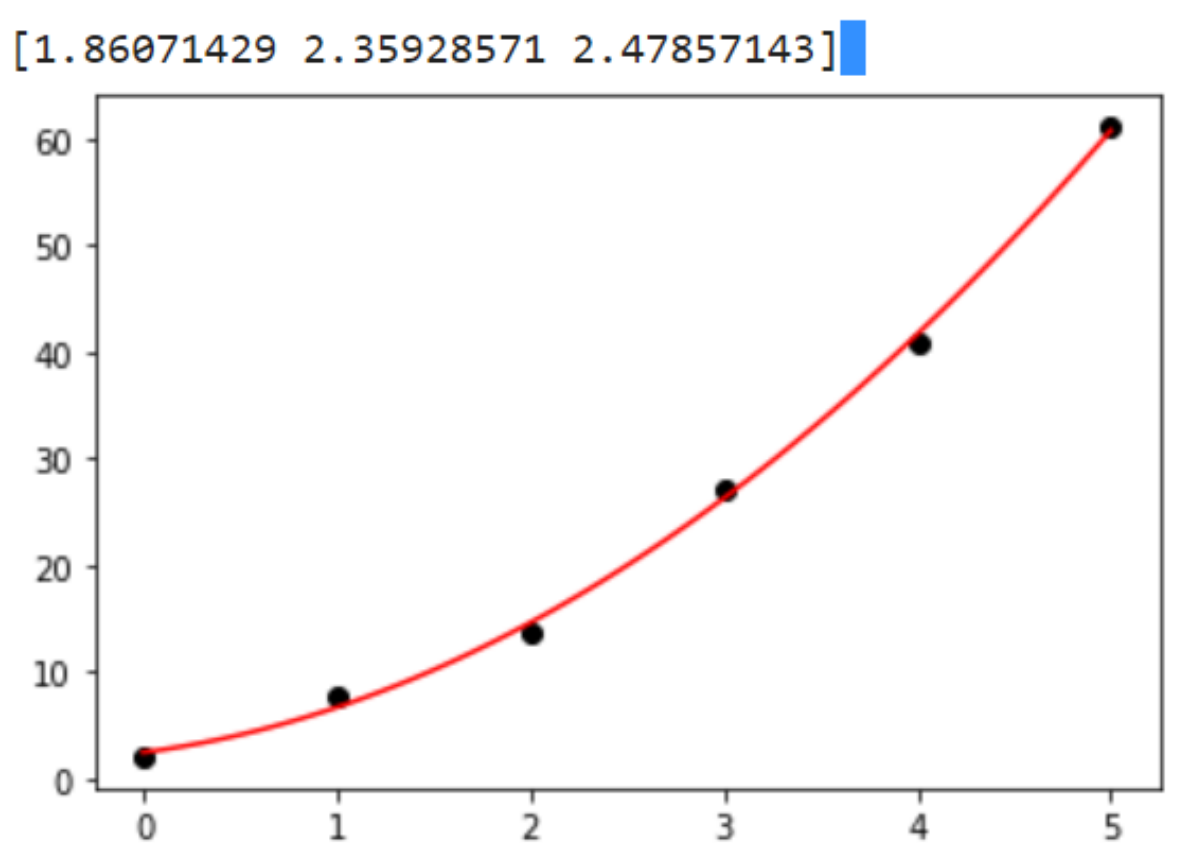


x = np.array([0.0, 1.0, 2.0, 3.0, 4.0, 5.0])
fX = np.array([2.1, 7.7, 13.6, 27.2, 40.9, 61.1])
p = least_squares_regression(x, fX, 2)

print(p)
plt.plot(x, fX, 'ko')

x = linspace(np.min(x), np.max(x), 100)
pX = np.polyval(p, x)

plt.plot(x, pX, 'r')
plt.show()
```



REZIME

Šta treba da zapamtimo

Pet ideja kroz koje smo prošli.

1. Regresija: iz poznatih podataka nalazimo funkciju kojom predviđamo nepoznate vrednosti.
2. Najbolja funkcija je ona sa najmanjom sumom kvadrata grešaka (SSE).
3. Za pravu $g(x) = a \cdot x + b$ koeficijente nalazimo iz uslova da su izvodi SSE jednaki nuli.
4. Kvalitet merimo pomoću R^2 i tipične greške.
5. Ako je trend kriva, koristimo polinom (stepen biramo mi); računar rešava sistem.

Fer kvote za ishode utakmica

Model treba da proceni stvarnu verovatnoću — ne kvotu za zaradu kladionice.

Tim iza football-data.co.uk želeo je model za „fer“ kvote.

Fer = kvota odražava stvarnu verovatnoću događaja,

a ne cilj zarade od tuđeg klađenja.

Predikcija ishoda: pobeda domaćina, nerešeno, pobeda gosta.



Match Rating (MR) kao indikator

Razlika datih i primljenih golova u prethodnih 6 utakmica meri kvalitet tima.

Pretpostavka: gol-razlika na prethodnim utakmicama je dobar indikator kvaliteta.

Posmatra se period od 6 utakmica pre meča čiji ishod predviđamo.

MR = RG_domaći − RG_gostujući

RG = broj datih golova − broj primljenih golova (poslednjih 6 utakmica)

Primer: Manchester – Liverpool

Manchester: 10 datih, 5 primljenih

Liverpool: 6 datih, 4 primljena

MR = 3

Uz istoriju, MR=3 povezujemo sa % pobede domaćina, nerešenog i pobede gosta.

Utakmice 1993–2001 po Match Ratingu

Najviše utakmica je „ujednačeno“ (MR blizu nule); ekstremi su retki.

MR	Br. pobeda domaćina	Br. nerešenih utakmica	Br. pobeda gostujućeg tima	% pobede domaćima	% nerešenih utakmica	% pobeda gostujućeg tima
-26	0	1	1	0.0%	50.0%	50.0%
-23	0	0	2	0.0%	0.0%	100.0%
-22	0	0	3	0.0%	0.0%	100.0%
⋮	⋮	⋮	⋮	⋮	⋮	⋮
-1	375	251	222	44.2%	29.6%	26.2%
0	414	259	235	45.6%	28.5%	25.9%
1	412	243	212	47.5%	28.0%	24.5%
⋮	⋮	⋮	⋮	⋮	⋮	⋮
22	1	0	1	50.0%	0.0%	50.0%
23	1	0	0	100.0%	0.0%	0.0%
27	1	0	0	100.0%	0.0%	0.0%

Slab domaćin
malo utakmica

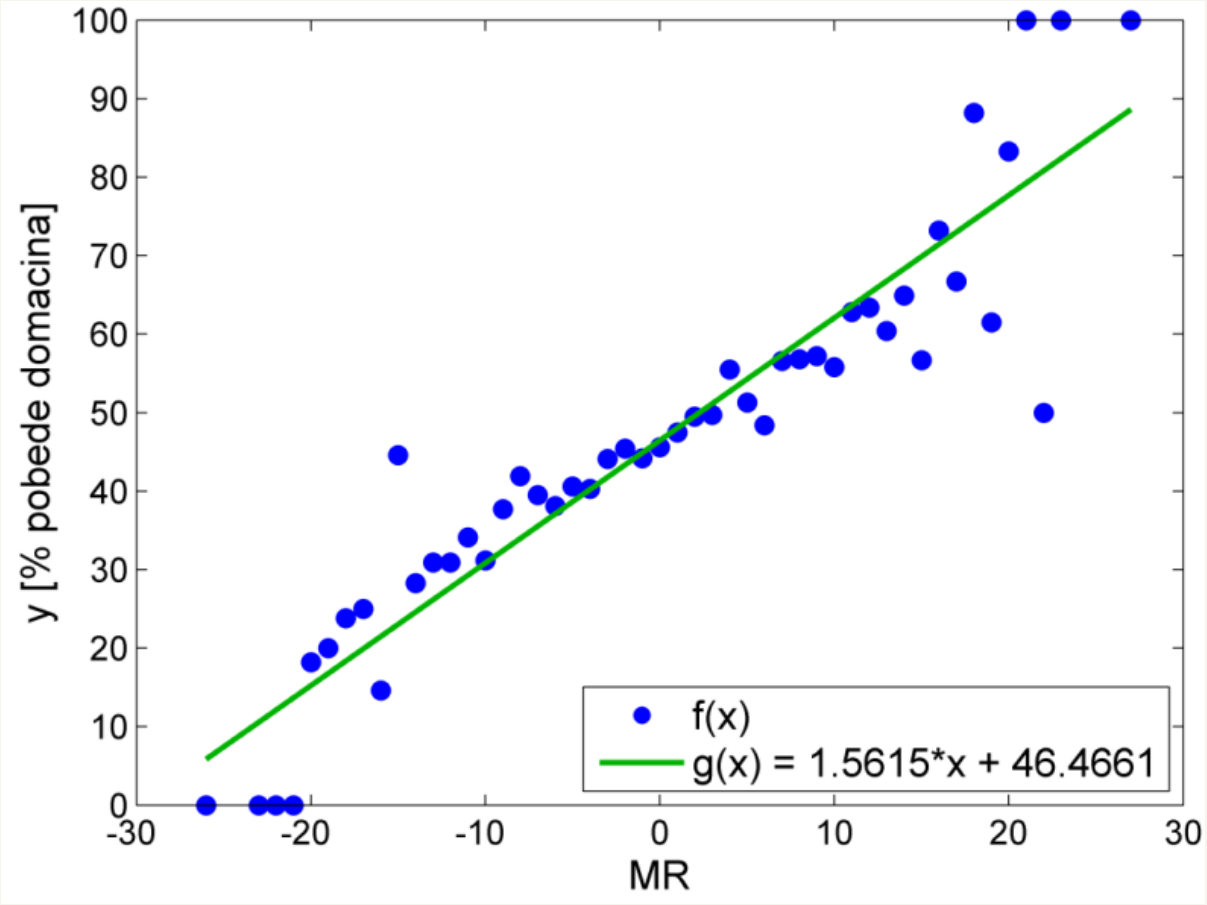
Ujednačeno
najviše utakmica

Jak domaćin
malo utakmica

Pažnja: ekstremne frekvencije su ocene verovatnoće na malom uzorku.

Procenat pobede domaćina vs MR

Sa porastom rejtinga raste % pobede domaćina — linearan trend.



Kreiran je regresioni model za P (% pobeda).

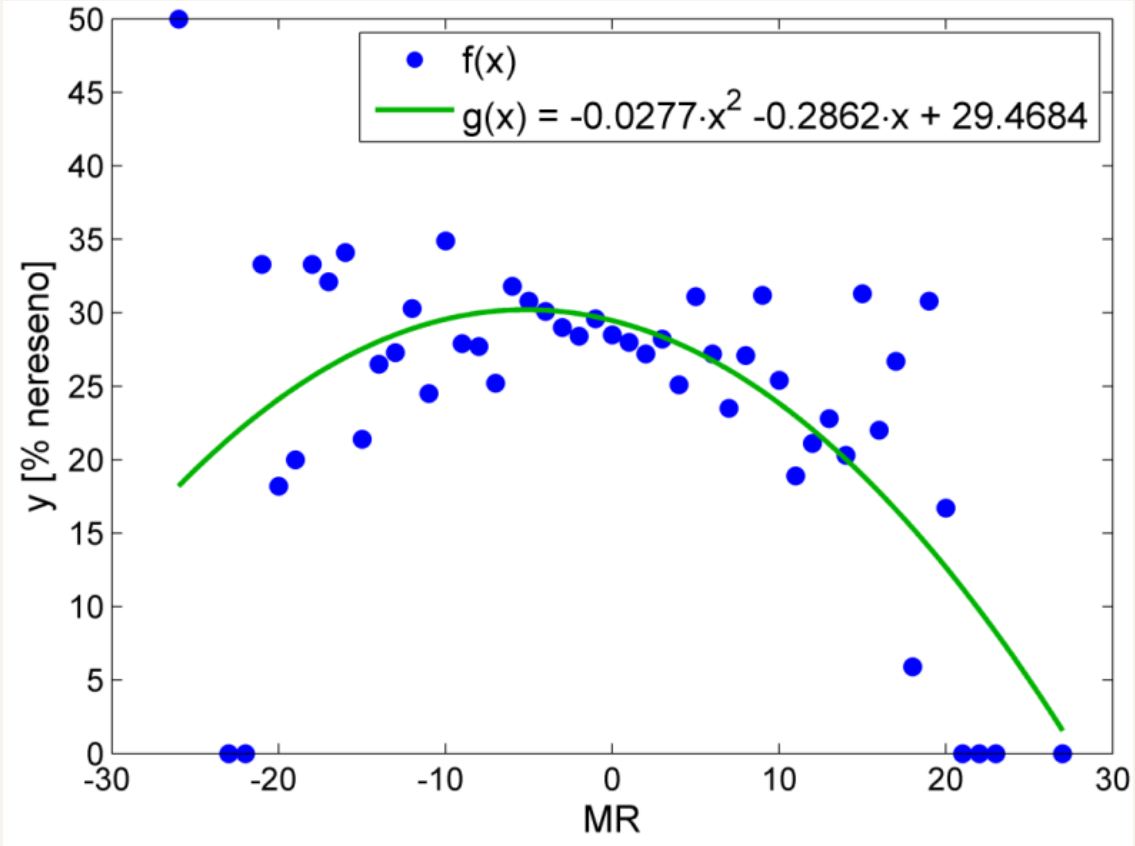
„Fer“ kvota = 1 / verovatnoća.

Za MR ≈ 1.2, model daje ~62% šanse za domaćina.

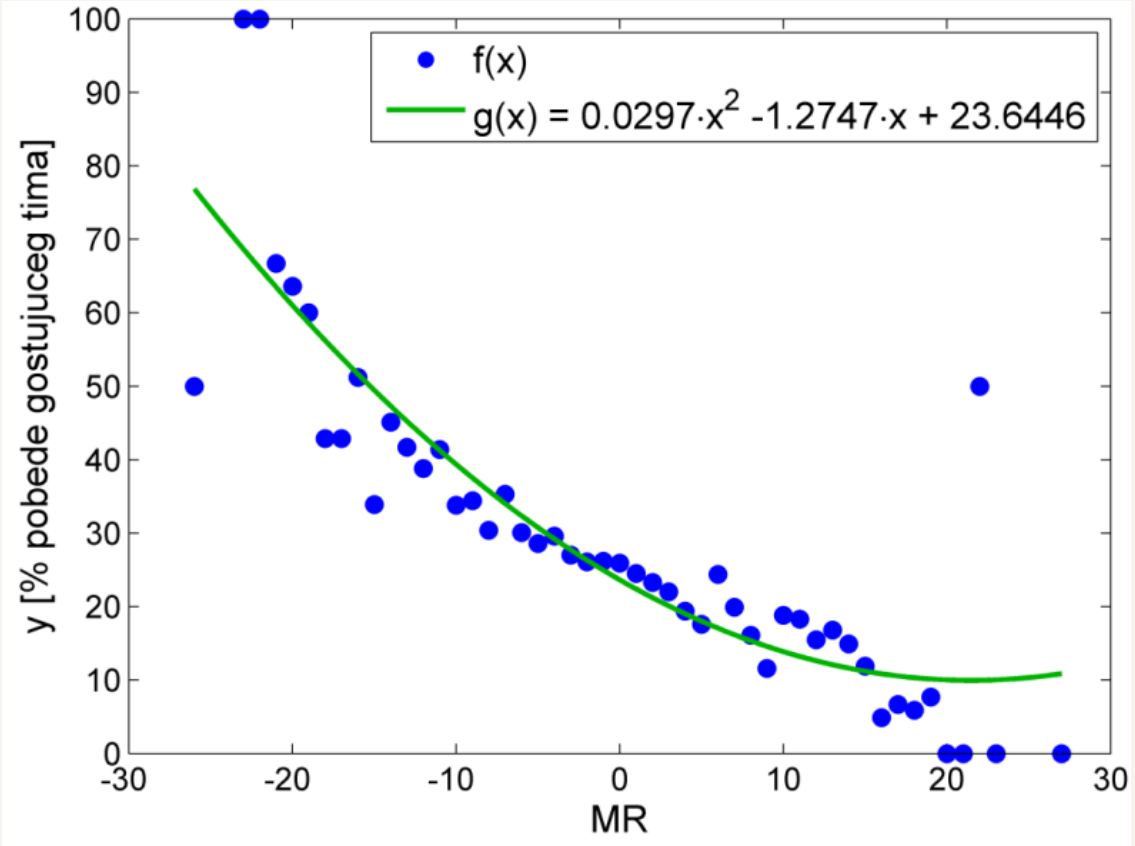
Trend je linearan: veći MR → veći % pobede domaćina.

Parabola bolje opisuje nerešeno i gost

Sa porastom |MR| opadaju % nerešenih i % pobede gosta — kvadratna zavisnost.



% nerešenih ishoda



% pobede gostujućeg tima

Trening 1993–2001 · test 2002

Model je najpouzdaniji oko MR≈0, gde ima najviše utakmica.

+2.1%

Opklada na sve utakmice

+10.13%

Samo „neizvesne“ (−2 < MR < 2)

−3.73%

Slepo klađenje na domaćina

Model je najpouzdaniji na utakmicama sa rejtingom bliskim nuli — tamo ima mnogo više podataka nego na ekstremima.

Prednost: automatski sistem — nije neophodno da se razumemo u fudbal.

DODATAK

Izvođenja i dodatni materijal

Izvođenje formula za a i b, dodatni primer (planinari), polinom proizvoljnog stepena, proizvoljne bazne funkcije.

OPŠTI PROBLEM

Oblik funkcije i najmanji kvadrati

Različiti oblici nose različit broj parametara; grešku merimo sumom kvadrata.

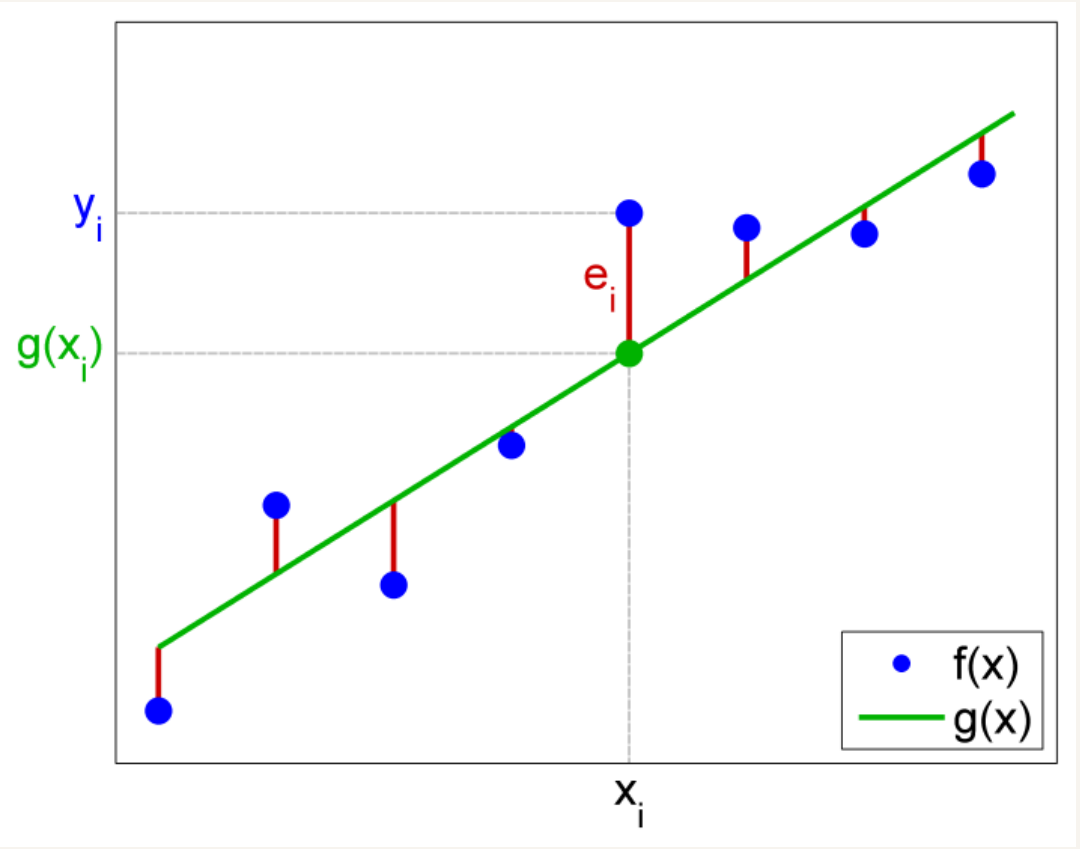
Mogući oblici

- Linearni (prava)
- Kvadratni polinom
- Polinom stepena m
- Opšti oblik: linearna kombinacija zadatih funkcija

Least Squares

Koeficijente određujemo minimizacijom sume kvadrata grešaka.

„Najbolje uklapanje“ u funkciju y = f(x) može se definisati na više načina.



Uslov minimuma: parcijalni izvodi = 0

Da bismo odredili minimum funkcije greške, izjednačavamo parcijalne izvode po a i b sa nulom.

$$\frac{\partial \Phi}{\partial a} = 0, \frac{\partial \Phi}{\partial b} = 0$$

$$\frac{\partial \Phi(a,b)}{\partial a} = \sum_{i=1}^{n} 2\,(b + ax_i - y_i)x_i = 0$$

$$\frac{\partial \Phi(a,b)}{\partial b} = \sum_{i=1}^{n} 2\,(b + ax_i - y_i) = 0$$

Od izvoda do sistema jednačina

Razvijanjem izvoda dobijamo linearni sistem u nepoznatim a i b.

$$\frac{\partial \Phi(a,b)}{\partial a} = \sum_{i=1}^{n} 2\,(b + ax_i - y_i)x_i = 0$$

$$\frac{\partial \Phi(a,b)}{\partial b} = \sum_{i=1}^{n} 2\,(b + ax_i - y_i) = 0$$

$$nb + (\sum_{i=1}^{n} x_i)a = \sum_{i=1}^{n} y_i$$

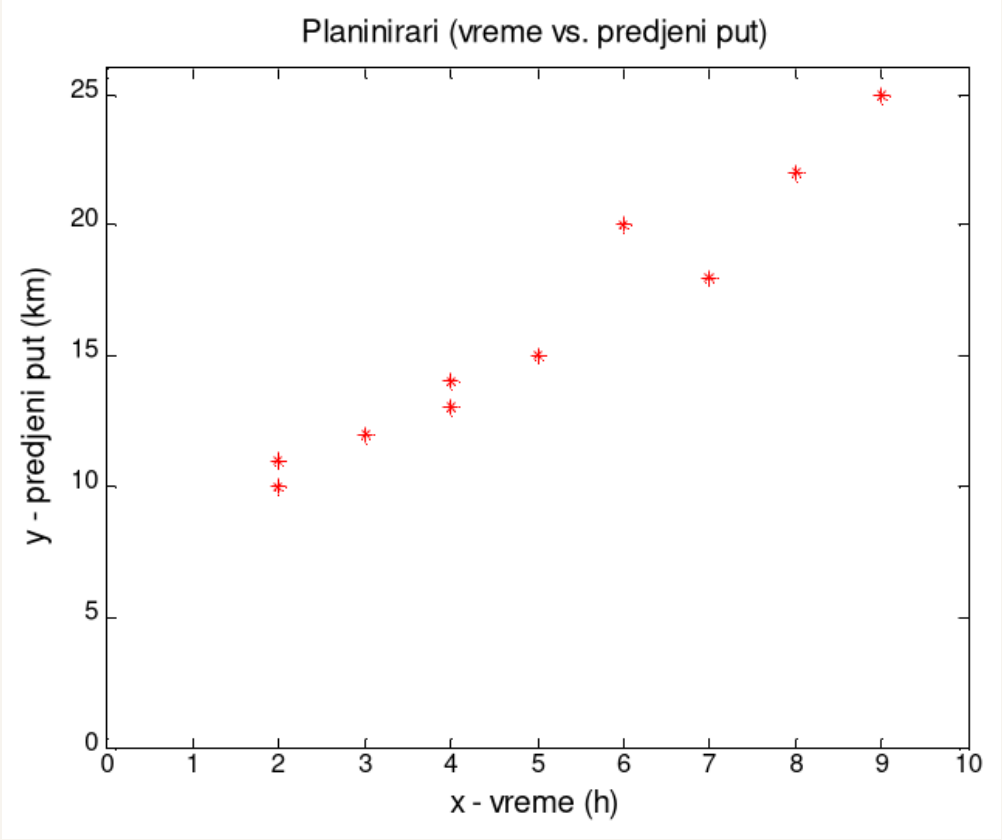
$$(\sum_{i=1}^{n} x_i)b + (\sum_{i=1}^{n} x_i^2)a = \sum_{i=1}^{n} x_i\, y_i$$

PRIMER · PLANINARI

Deset planinara: vreme i pređeni put

Merimo vreme hodanja (h) i pređeni put (km) — tražimo pravu f(x) = ax + b.

Planinar	Vreme (h)	Put (km)
1	2	10
2	2	11
3	3	12
4	4	13
5	4	14
6	5	15
7	6	20
8	7	18
9	8	22
10	9	25



PRIMER · PLANINARI

Sume koje ulaze u sistem

Izračunavamo Σx, Σy, Σx^2, Σxy — ulaze u normalne jednačine.

	1	2	3	4	5	6	7	8	9	10	Σ
xi	2	2	3	4	4	5	6	7	8	9	**50**
yi	10	11	12	13	14	15	20	18	22	25	**160**
xi^2	4	4	9	16	16	25	36	49	64	81	**304**
xi yi	20	22	36	52	56	75	120	126	176	225	**908**

$$10b + 50a = 160$$

$$50b + 304a = 908$$

Rešenje: a = 2, b = 6

Sistem daje f(x) = 2x + 6.

$$10b + 50a = 160$$

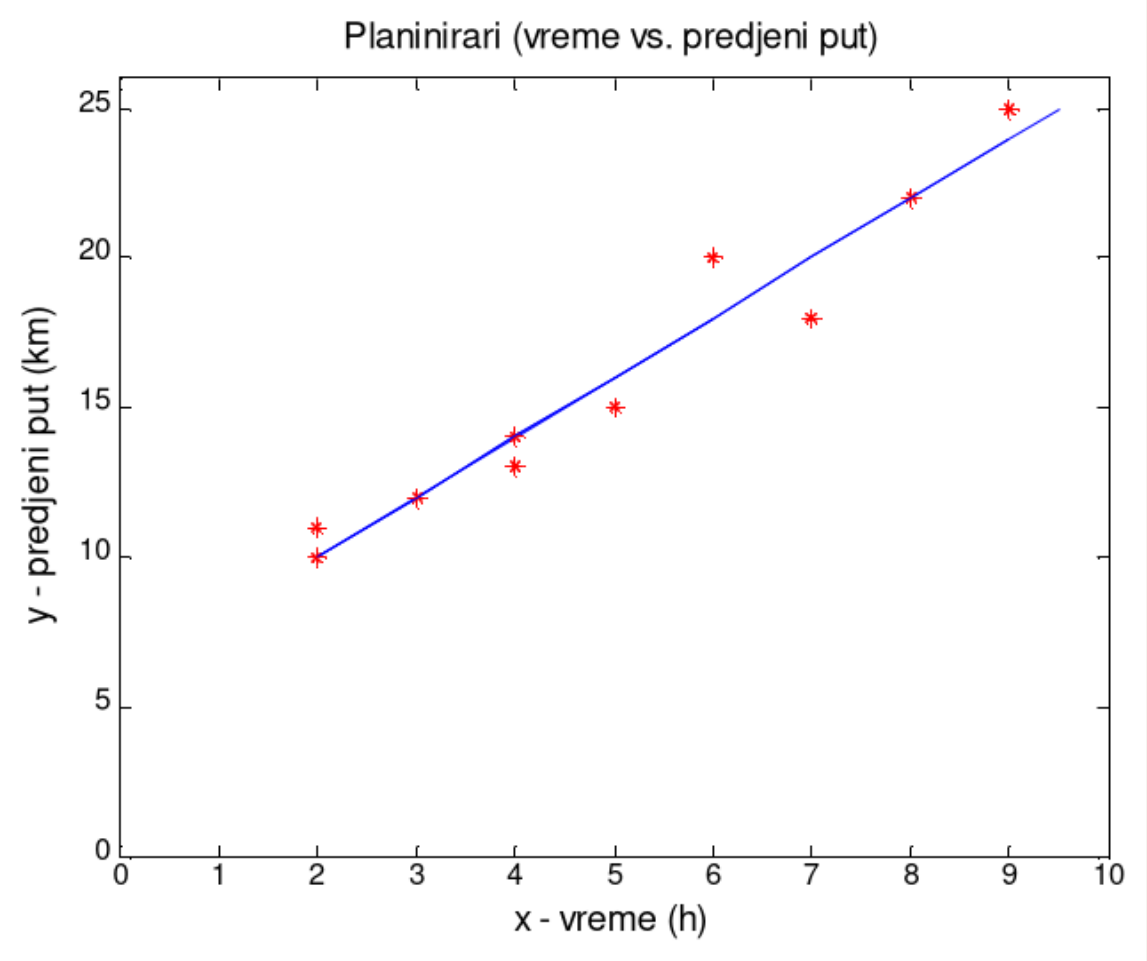
$$50b + 304a = 908$$

Rešenje je a = 2, b = 6 → f(x) = 2x + 6

$$f(x) = 2x + 6$$

Grafik: f(x) = 2x + 6

Prava prolazi blizu tačaka — vidimo trend, ne savršen prolaz kroz svaku tačku.



KVALITET FITOVANJA

Zašto meriti kvalitet?

Grafik pomaže, ali treba automatska mera kvaliteta regresione funkcije.

Iako se pomoću grafika može utvrditi koliko se regresiona funkcija uklapa u podatke, potreban nam je automatski način da izmerimo kvalitet.

Na sledećim slajdovima: SSE, SST, SSR, R^2, tipična greška i korelacija.

SSE — suma kvadrata grešaka

Sabiramo kvadrate odstupanja g(xi) od yi. Za planinare: SSE = 12.

$$\text{SSE} = \sum_{i=1}^{n} (g(x_i) - y_i)^2$$

$$\text{SSE} = \sum_{i=1}^{n} (g(x_i) - y_i)^2 = \sum_{i=1}^{n} (b + ax_i - y_i)^2$$

SSE = 12

Za primer sa planinarima.

Da li je 12 mala ili velika vrednost?

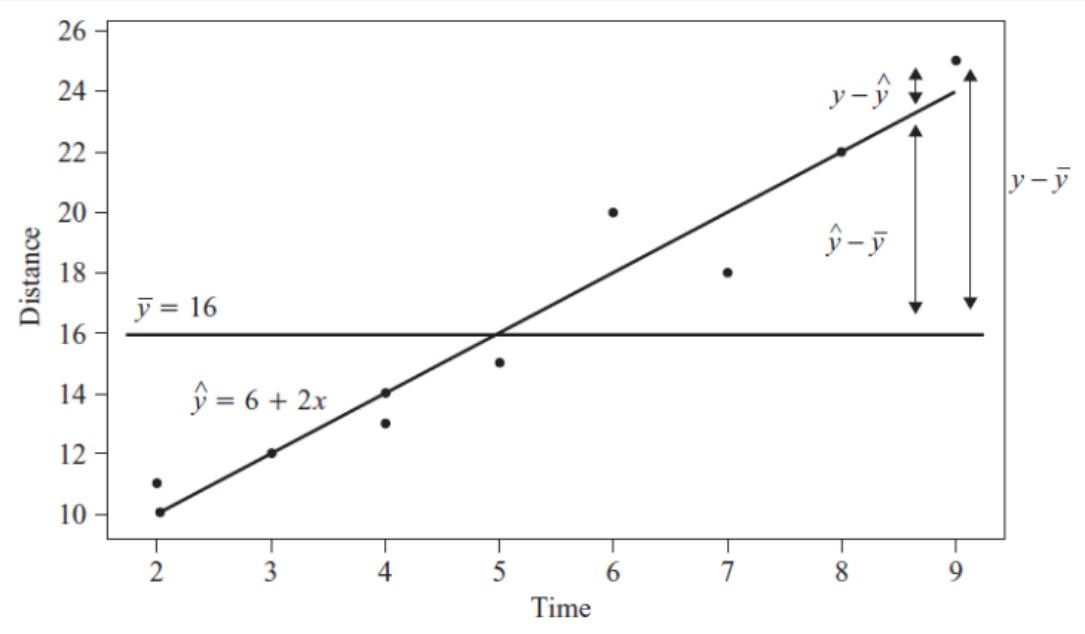
Potrebna nam je referenca za poređenje.

Bez x: najbolja procena je srednja vrednost

Ako ne poznajemo vreme hodanja, procenjujemo put samo pomoću ȳ.

Kako bismo odredili funkciju f ako ne bismo imali informaciju o x, već samo y?

Najbolja moguća procena za pređeni put je srednja vrednost ȳ.



SST — ukupna suma kvadrata

SST meri grešku kada koristimo samo ȳ. Za planinare: SST = 228 ≫ SSE = 12.

- Da bismo odredili vrednost sa kojom poredimo SSE, postavljamo sledeće pitanje:
- Kako bismo odredili funkciju f, ako ne bismo imali informaciju x (nezavisnu promenljivu) već samo y?

- Pošto nemamo informaciju o vremenu (nemamo x), najbolja moguća procena za pređeni put tj. *y* je $\bar{y}$ (*srednja vrednost* pređenog puta).
- Morali bismo da koristimo $\bar{y} = 16$ da procenimo broj pređenih kilometara za svakog od planininara, bez obzira na to koliko je ta osoba dugo hodala.

$$\text{SST} = \sum_{i=1}^{n} (y_i - \bar{y})^2$$

SST = 228

SSE = 12

SSE je mnogo manje od SST — vreme hodanja poboljšava procenu pređenog puta.

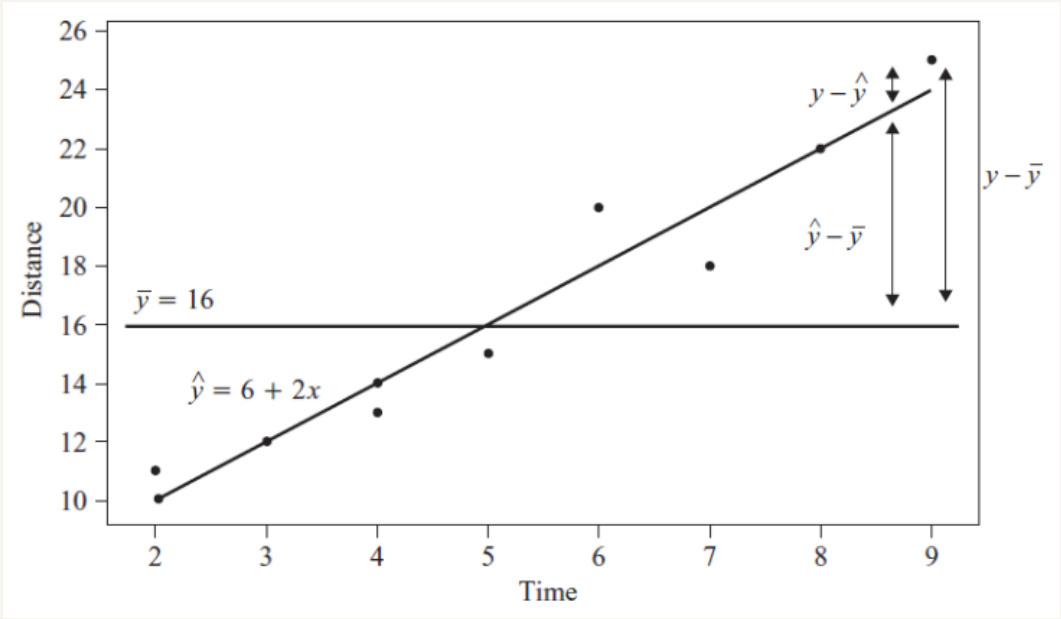
To je indikator da nezavisna promenljiva ima smisla.

SSR — suma kvadrata regresije

Da bismo izmerili koliko x poboljšava kvalitet, računamo SSR.

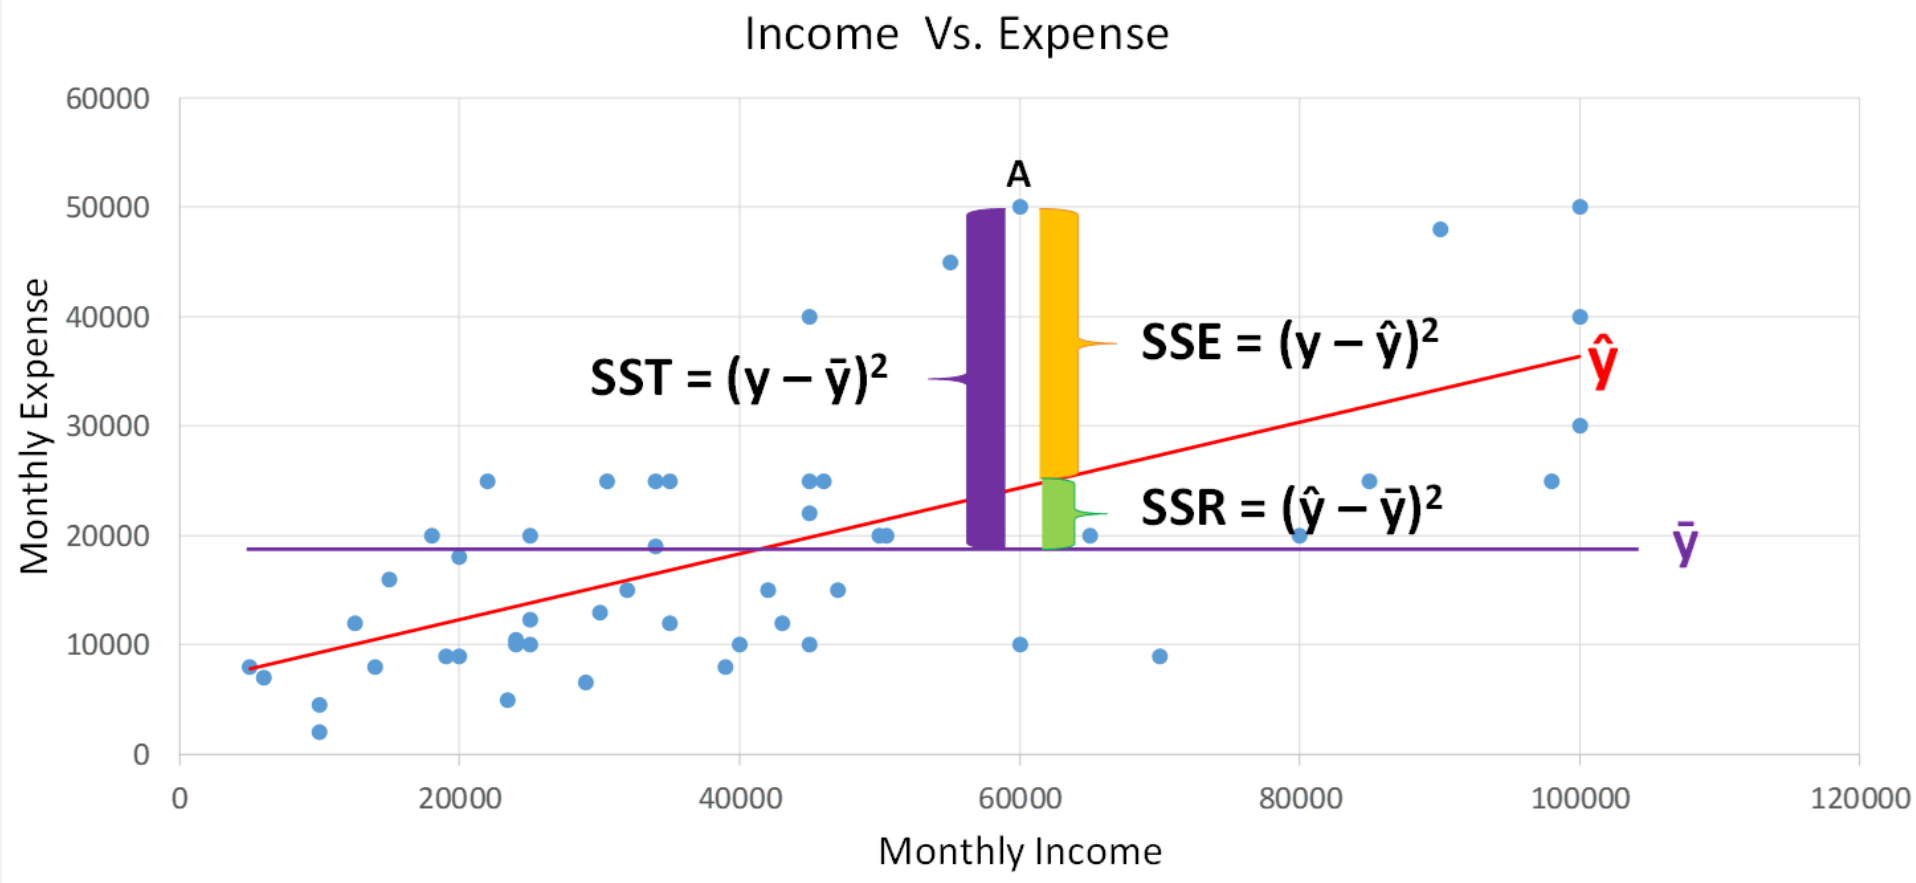
Sum of squares regression — deo varijabilnosti koji objašnjava model.

$$\text{SSR} = \sum_{i=1}^{n} (\hat{y}_i - \overline{y})^2$$



Koeficijent determinacije R^2

R^2 meri deo varijabilnosti y koji objašnjava regresiona jednačina.



Granice R^2 i primer planinara

$R^2 \in [0, 1]$. Za planinare ≈ 95% varijabilnosti puta objašnjeno vremenom.

$R^2 = 0$

Regresija ne donosi poboljšanje u odnosu na $\bar{y}$ → SSR = 0.

$R^2 = 1$

Prava savršeno uklapa podatke → SSR = SST.

$$R^2 = \frac{\text{SSR}}{\text{SST}} = \frac{216}{228} = 0.947$$

Približno 95% varijabilnosti u pređenom putu objašnjeno je vremenom hodanja.

Tipična greška procene

Mera prosečnog odstupanja regresione funkcije od datih tačaka.

$$s = \sqrt{\frac{\mathrm{SSE}}{n - m - 1}}$$

n — broj tačaka; m — broj nezavisnih promenljivih (ovde m = 1).

Planinari: tipično grešimo ~1.2 km

Za dato vreme hodanja, tipična greška procene pređenog puta je 1.2 km.

$$s = \sqrt{\frac{12}{10 - 1 - 1}} = 1.2$$

Kada koristimo regresionu jednačinu za procenu pređenog puta za dato vreme, tipično grešimo za 1.2 km.

Koeficijent korelacije r

Indikator „snage“ linearnog odnosa dve promenljive; r ∈ [−1, 1].

$$r = \frac{\sum_{i=1}^{n}(x_i - \overline{x})(y_i - \overline{y})}{(n-1)s_x s_y}$$

sx, sy — standardne devijacije x i y.

- blizu +1: jaka pozitivna korelacija
- blizu −1: jaka negativna korelacija
- blizu 0: nema linearne korelacije

Šta je „blizu“ zavisi od oblasti (prirodne vs društvene nauke).

Planinari: r = 0.9773

Jaka pozitivna korelacija — sa povećanjem vremena hodanja raste i pređeni put.

r = 0.9773

Jaka pozitivna korelacija između vremena hodanja i pređenog puta.

Trend nije uvek linearan

Kada je trend kriv — regresiju vršimo krivom (npr. parabolom).

Do sada: regresiona funkcija je prava.

Međutim, trend u podacima nije uvek linearan.

Tada regresiju vršimo krivom.

Linearna → prava

Nelinearna → parabola / polinom / ...

Linearna vs parabola

x → y linearni trend

x → y kvadratni trend

PARABOLA

Sistem za polinom stepena 2

Tri nepoznata koeficijenta → sistem od tri normalne jednačine.

$$\Phi(a,b,c) = \sum_{i=1}^{n} (a + bx_i + cx_i^2 - y_i)^2$$

$$\frac{\partial \Phi}{\partial a} = 2\sum_{i=1}^{n} (a + bx_i + cx_i^2 - y_i) = 0$$

$$\frac{\partial \Phi}{\partial b} = 2\sum_{i=1}^{n} (a + bx_i + cx_i^2 - y_i)x_i = 0$$

$$\frac{\partial \Phi}{\partial c} = 2\sum_{i=1}^{n} (a + bx_i + cx_i^2 - y_i)x_i^2 = 0$$

POLINOM PROIZVOLJNOG STEPENA

Minimizujemo zbir kvadrata grešaka

Polinom uklapamo tako da minimizujemo sumu kvadrata odstupanja.

$$\Phi(a_0, \dots, a_m) = \sum_{i=1}^{n} (y_i - \sum_{j=0}^{m} a_j \, x_i^j)^2$$

Od parcijalnih izvoda do sistema

Postavljamo izvode po koeficijentima na nulu; zamenom redosleda sumiranja dobijamo linearni sistem.

$$\frac{\partial \Phi}{\partial a_k} = 0, k = 0, \dots, m$$

$$(A^T A)a = A^T y$$

$$A_{ij} = x_i^j, i = 1 \dots n, j = 0 \dots m$$

Struktura sabiraka i elemenata

Svaki red sistema ima m+1 sabiraka; ukupno m+1 jednačina.

$$\sum_{j=0}^{m} a_j \sum_{i=1}^{n} x_i^{j+k} = \sum_{i=1}^{n} y_i \, x_i^k$$

$$k = 0,1, \dots, m$$

$(m+1)$ jednacina, $(m+1)$ nepoznatih

IZVOĐENJE

Prelazak na matrični oblik

Sume se pakuju u matricu A i vektore a, y.

$$A = [x_i^j]_{n\times(m+1)}$$

$$a = (a_0, \dots, a_m)^T, y = (y_1, \dots, y_n)^T$$

$$(A^T A)a = A^T y$$

Kompletne matrice A, a, y

Vandermonde-struktura: $A_{ij} = x_i^j$.

$$A = \begin{pmatrix} 1 & x_1 & \cdots & x_1^m \\ 1 & x_2 & \cdots & x_2^m \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_n & \cdots & x_n^m \end{pmatrix}$$

$$a = \begin{pmatrix} a_0 \\ \vdots \\ a_m \end{pmatrix}, y = \begin{pmatrix} y_1 \\ \vdots \\ y_n \end{pmatrix}$$

IZVOĐENJE

Normalne jednačine: $(A^TA)a = A^Ty$

Koeficijenti regresionog polinoma se određuju rešavanjem ovog sistema.

$$(A^T A)a = A^T y$$

To je isti oblik koji ćemo kasnije videti i za proizvoljne bazne funkcije.

Linearna kombinacija proizvoljnih baza

Isti $(A^TA)a = A^Ty$ — samo umesto x^j stoje proizvoljne funkcije $f_j(x)$.

Pronalaženje regresionog polinoma proizvoljnog stepena svodi se na $(A^TA)a = A^Ty$.

Taj postupak se uopštava na linearnu kombinaciju proizvoljnih funkcija.

Polinom je specijalan slučaj: $f_j(x) = x^j$.

$$\varphi(x) = \sum_{j=0}^{m} a_j \, f_j(x)$$

Problem i funkcija greške

Minimizujemo sumu kvadrata — sada u bazi {fⱼ}.

$$\varphi(x) = \sum_{j=0}^{m} a_j \, f_j(x)$$

$$\Phi = \sum_{i=1}^{n} (y_i - \sum_{j=0}^{m} a_j \, f_j(x_i))^2$$

Parcijalni izvodi i sređivanje

Isti koraci kao kod polinoma — menjaju se samo članovi baze.

$$\frac{\partial \Phi}{\partial a_k} = 0, k = 0, \dots, m$$

$$\sum_{j=0}^{m} a_j \sum_{i=1}^{n} f_j\,(x_i) f_k(x_i) = \sum_{i=1}^{n} y_i\, f_k(x_i)$$

$$(A^T A)a = A^T y$$

Matrični oblik za opštu bazu

$A_{ij} = f_j(x_i)$ — umesto stepena stoje vrednosti baznih funkcija.

$$A_{ij} = f_j(x_i)$$

$$A = [f_j(x_i)]_{n\times(m+1)}$$

$$(A^T A)a = A^T y$$

Isti rezultat: $(A^TA)a = A^Ty$

Koeficijenti regresione funkcije se određuju rešavanjem istog sistema.

$$(A^T A)a = A^T y$$

$$\varphi(x) = \sum_{j=0}^{m} a_j \, f_j(x)$$

Proizvoljne bazne funkcije — sažetak

Rešenjem sistema dobijamo koeficijente g(x) = Σ a_m f_m(x).

$$\left(A^T \cdot A\right) \cdot a = A^T \cdot y,$$

gde je

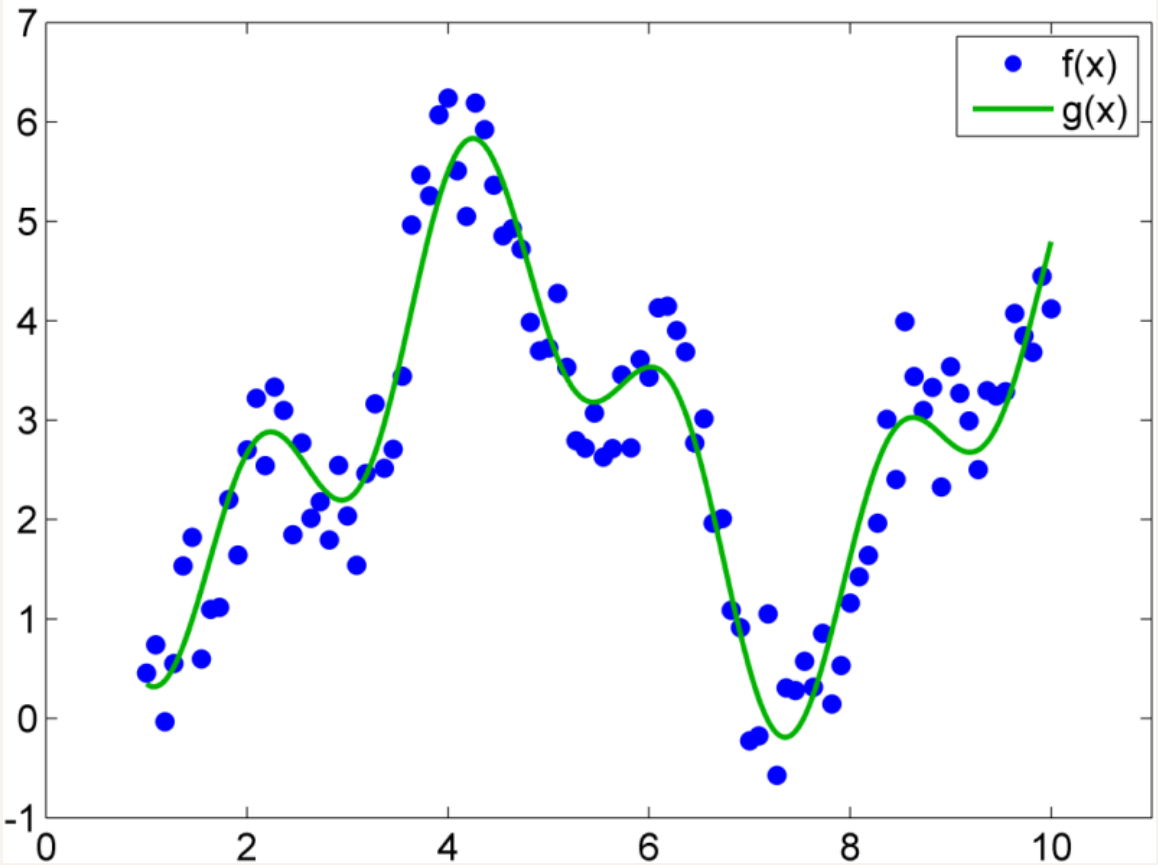
$$A = \begin{bmatrix} f_0(x_1) & f_1(x_1) & \cdots & f_M(x_1) \\ f_0(x_2) & f_1(x_2) & \cdots & f_M(x_2) \\ \vdots & \vdots & \ddots & \vdots \\ f_0(x_N) & f_1(X_N) & \cdots & f_M(x_N) \end{bmatrix}, a = \begin{bmatrix} a_0 \\ a_1 \\ \vdots \\ a_M \end{bmatrix} \; i \; y = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_N \end{bmatrix}$$

- Rešenjem sistema dobijamo nepoznate koeficijente $a_0, a_1, \ldots, a_M$ regresione funkcije $g(x) = \sum_{m=0}^{M} a_m f_m(x)$

PRIMER

Tačke sa šumom

Date su tačke funkcije u koje dodajemo slučajno generisani šum.



- Date su nam tačke funkcije
  $f(x) = 2 - 0.6 \cdot \cos(x) - 1.7 \cdot \sin(x) + 1.1 \cdot \cos(3 \cdot x) + 0.2 * \sin(1.5 \cdot x)$
- u koje dodajemo i slučajno generisani šum.

PRIMER

Baza: 1, cos, sin, ...

Modelujemo podatke linearnom kombinacijom odabranih funkcija.

$$1, cosx, sinx, cos2x, sin2x, \dots$$

$$\varphi(x) = \sum_{j=0}^{m} a_j \, f_j(x)$$

$$(A^T A)a = A^T y$$

- Pokušaćemo da odredimo regresionu funkciju u obliku:
- Konkretno, podatke ćemo modelovati funkcijom: $f(x) = a_1 - a_2 \cdot cos(x) - a_3 \cdot sin(x) + a_4 \cdot cos(3 \cdot x) + a_5 * sin(1.5 \cdot x)$
- Poziv metode
- `functions = {@(x) 1, @(x) cos(x), @(x) sin(x), @(x) cos(3*x), @(x) sin(1.5*x)};`
- `coeffs = lsquares_general(x, y, functions);`

PRIMER

Rezultat: koeficijenti blizu pravih

Dobijeni koeficijenti su približni koeficijentima date funkcije.

```
coefs =

    2.9419
   -0.6983
   -1.7368
    1.0210
    0.2543
```

- Rezultat je vektor koeficijenata:

$$g(x) = 2.9419 \cdot 1 - 0.6983 \cdot cos(x) - 1.7368 \cdot sin(x) + 1.0210 \cdot cos(3 \cdot x) + 0.2543 \cdot sin(1.5 \cdot x)$$

- Rezultati su približni koeficijentima date funkcije:

$$2 - 0.6 \cdot \cos(x) - 1.7 \cdot \sin(x) + 1.1 \cdot \cos(3 \cdot x) + 0.2 * \sin(1.5 \cdot x)$$