FTN · Novi Sad · 2026

Jednostruka linearna regresija

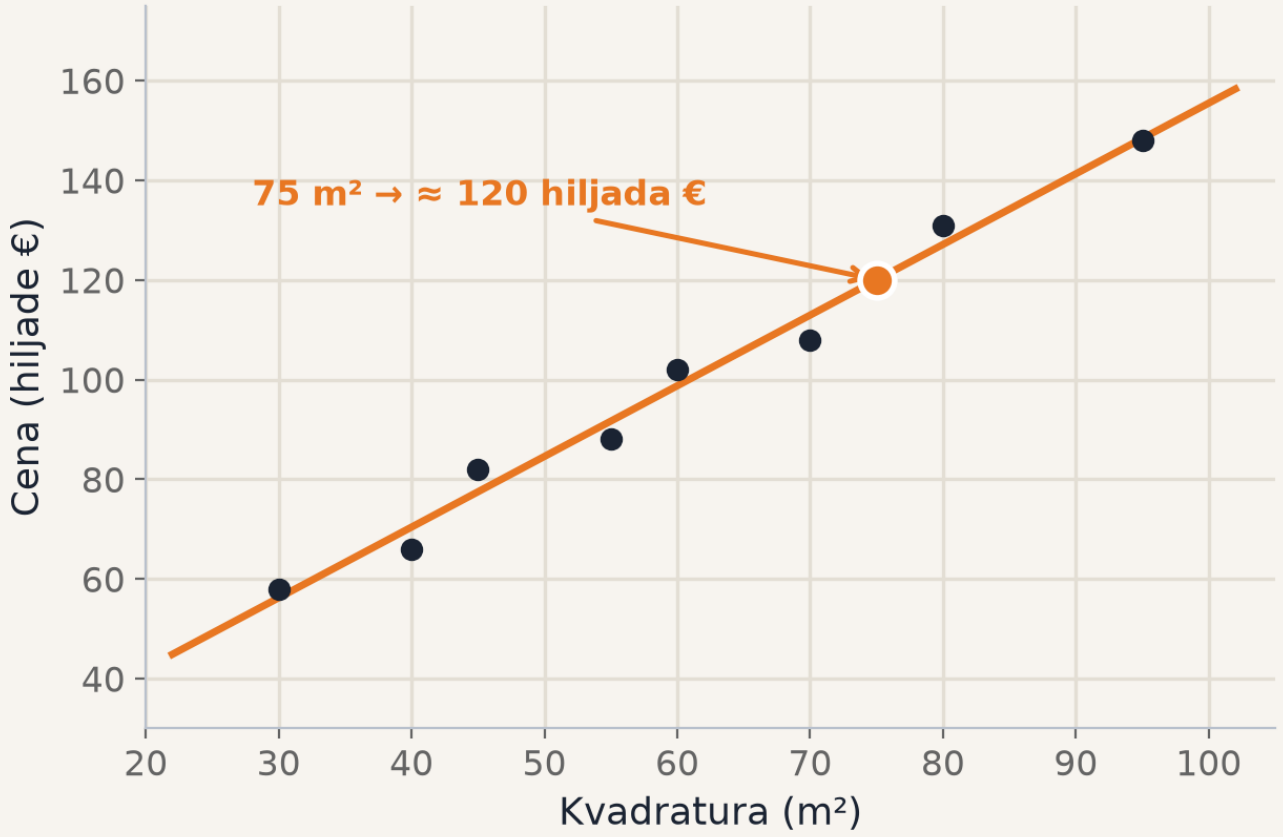
Model, pretpostavke i zaključivanje

Aleksandar Kovačević

PODSEĆANJE

Šta znamo iz prošlog predavanja

Kroz podatke provlačimo pravu sa najmanjom sumom kvadrata grešaka.



1. Podaci su parovi (x, y), npr. kvadratura i cena stana.
2. Najbolja prava ima najmanji SSE: metod najmanjih kvadrata.
3. Sa prave čitamo procenu za novi x.

Danas: kada smemo da verujemo toj pravi i koliko smo sigurni u njene brojeve?

POJMOVI

Zavisna i nezavisna promenljiva

Jednostruka regresija ima samo jednu nezavisnu promenljivu.

y

Zavisna promenljiva

Ono što želimo da predvidimo ili objasnimo. Primer: cena stana.

x

Nezavisna promenljiva

Ono što koristimo za predviđanje. Primer: kvadratura stana.

Jednostruka regresija: jedan x.

Kada imamo više x-ova (kvadratura, sprat, lokacija...) to je **višestruka** regresija, tema sledećeg predavanja.

OZNAKE

Ista prava, nove oznake

U statistici i u Python bibliotekama prava se piše malo drugačije.

Prošli put: $y = a \cdot x + b$

Od danas: $y = b_0 + b_1 \cdot x$

$b_1 = a$ **nagib:** za koliko se y promeni kada x poraste za 1.

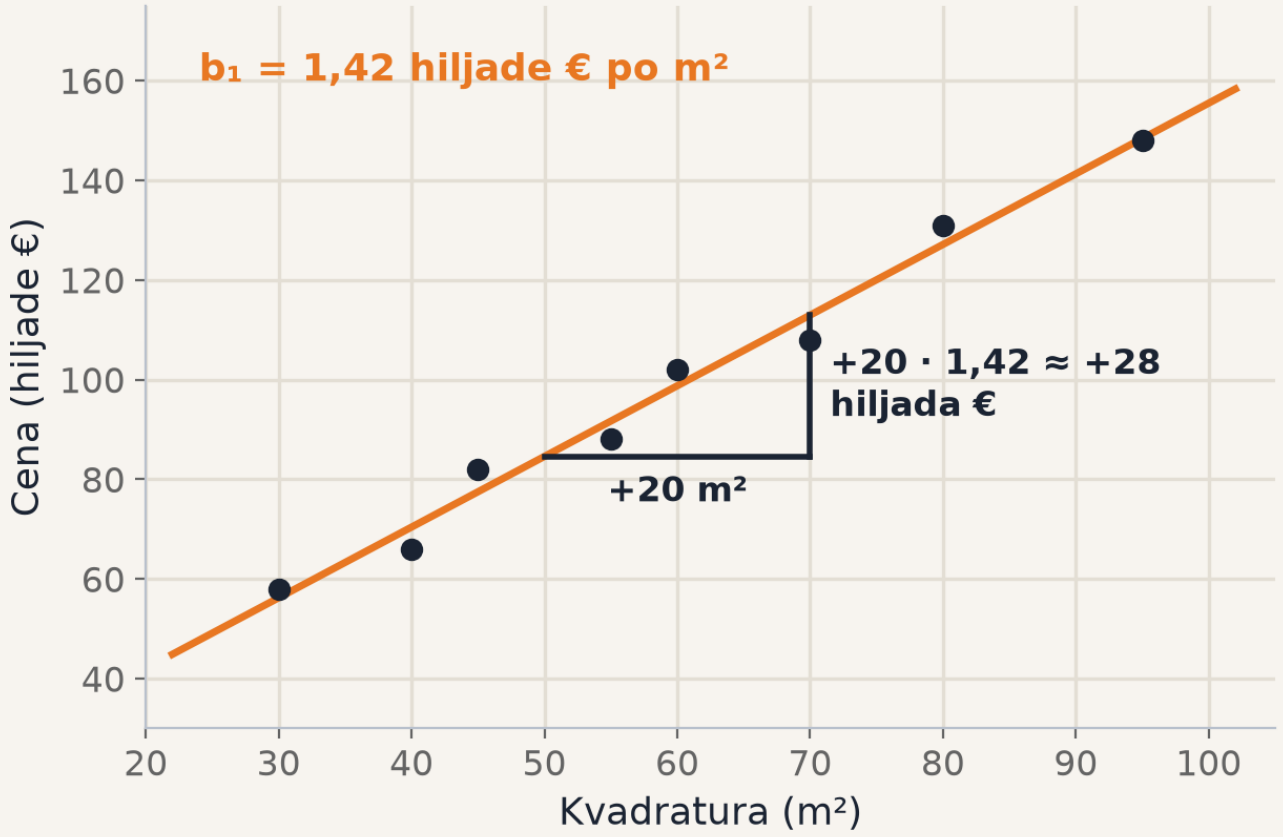
$b_0 = b$ **odsečak:** vrednost y kada je x = 0 (gde prava seče y-osu).

Zašto indeksi? Lako se proširuje na više promenljivih: $y = b_0 + b_1 \cdot x_1 + b_2 \cdot x_2 + \ldots$

NAGIB

Šta nam govori nagib b_1?

Nagib je najvažniji broj u modelu: meri uticaj x na y.



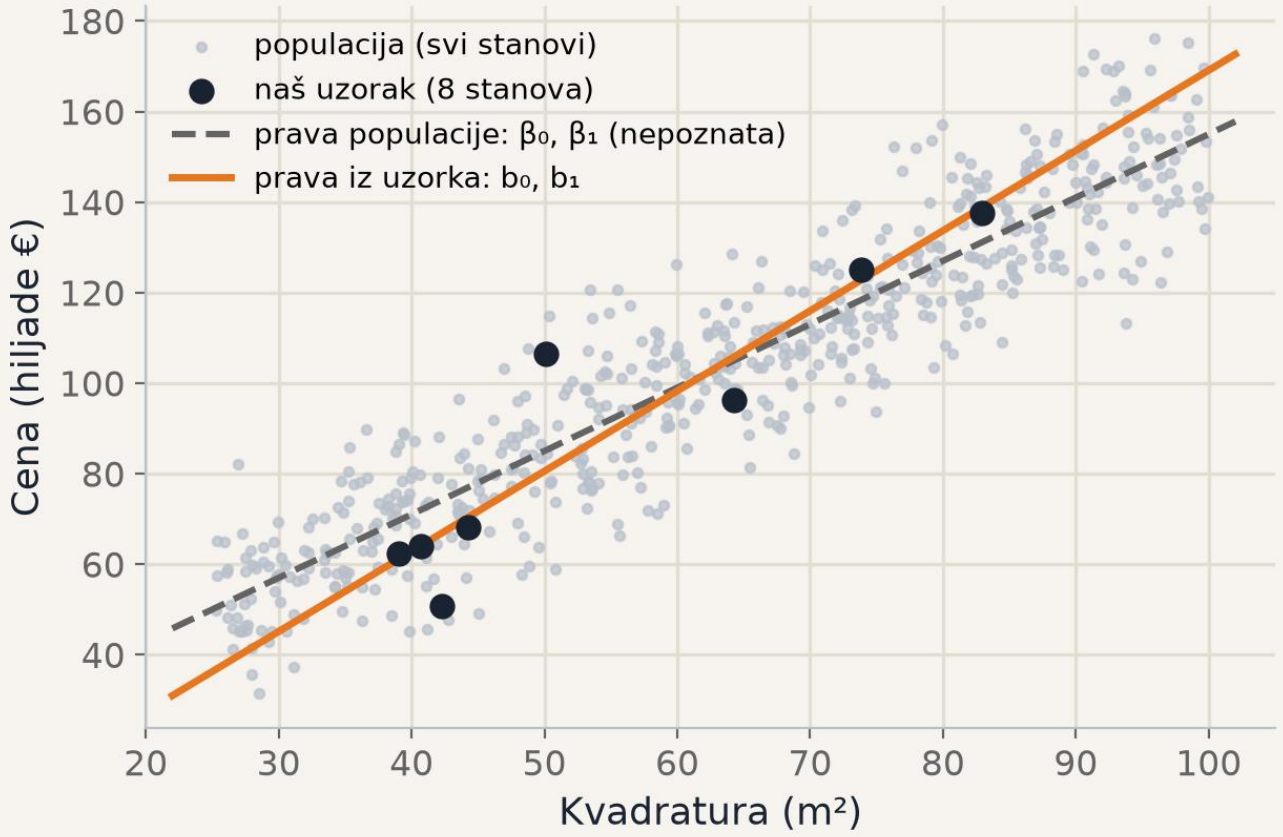
- Stanovi: $b_1 = 1{,}42$, tj. svaki dodatni m^2 dodaje u proseku oko 1.420 €.
- $b_1 > 0$: veći x, veći y. $b_1 < 0$: veći x, manji y.
- Jedinice su važne: cena u € umesto u hiljadama € daje $b_1 = 1.420$.

Negativan nagib: teži auto prelazi manje milja po galonu (nagib −8,4).

POPULACIJA I UZORAK

Imamo samo uzorak, ne sve podatke

Naših 8 stanova je mali deo svih stanova u gradu.



- **Populacija:** svi primeri koji nas zanimaju, npr. svi stanovi u Novom Sadu.
- **Uzorak:** podaci koje zaista imamo, npr. naših 8 stanova.
- Populaciju biramo mi. Uzorak mora dobro da je predstavlja (različiti delovi grada, različite veličine).

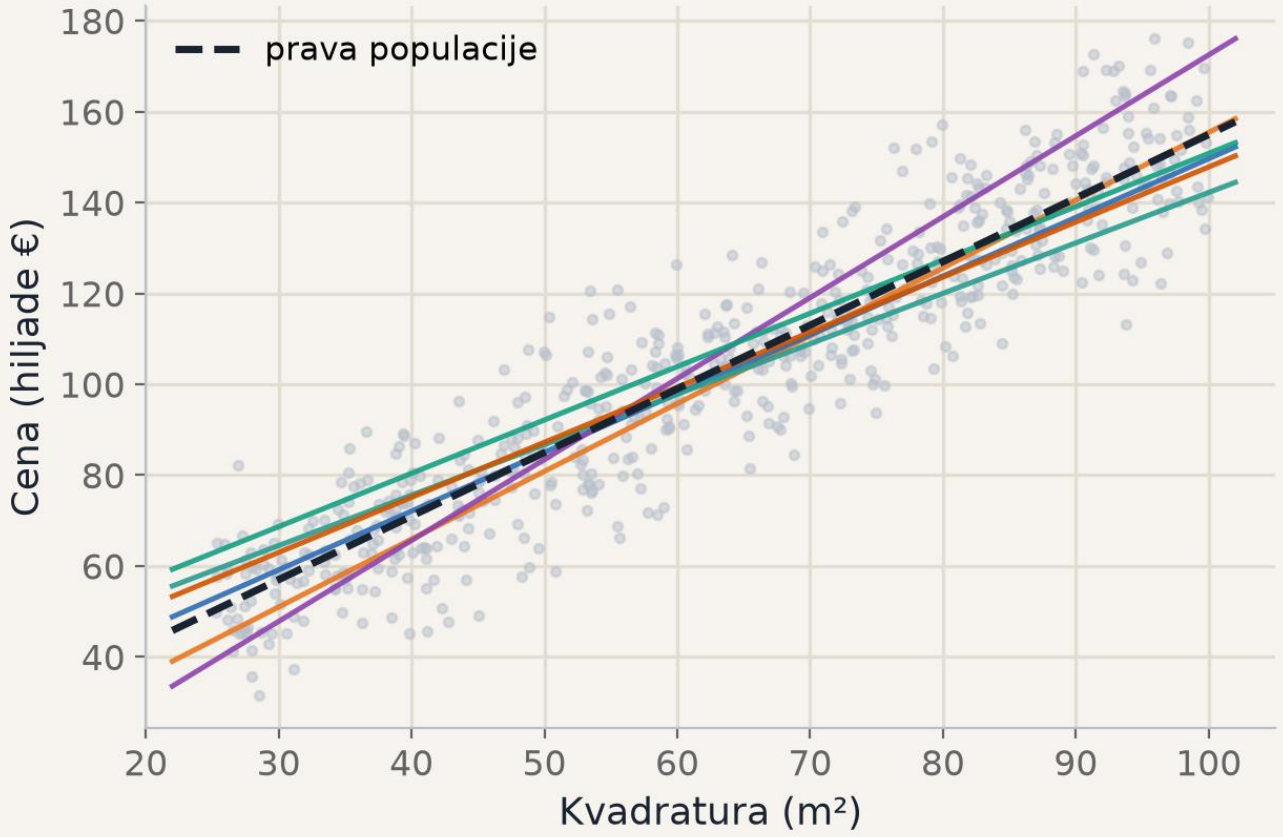
β_0, β_1: prava cele populacije (nepoznata).

b_0, b_1: naše procene iz uzorka.

POPULACIJA I UZORAK

Drugi uzorak, druga prava

Procene b_0 i b_1 se menjaju od uzorka do uzorka.

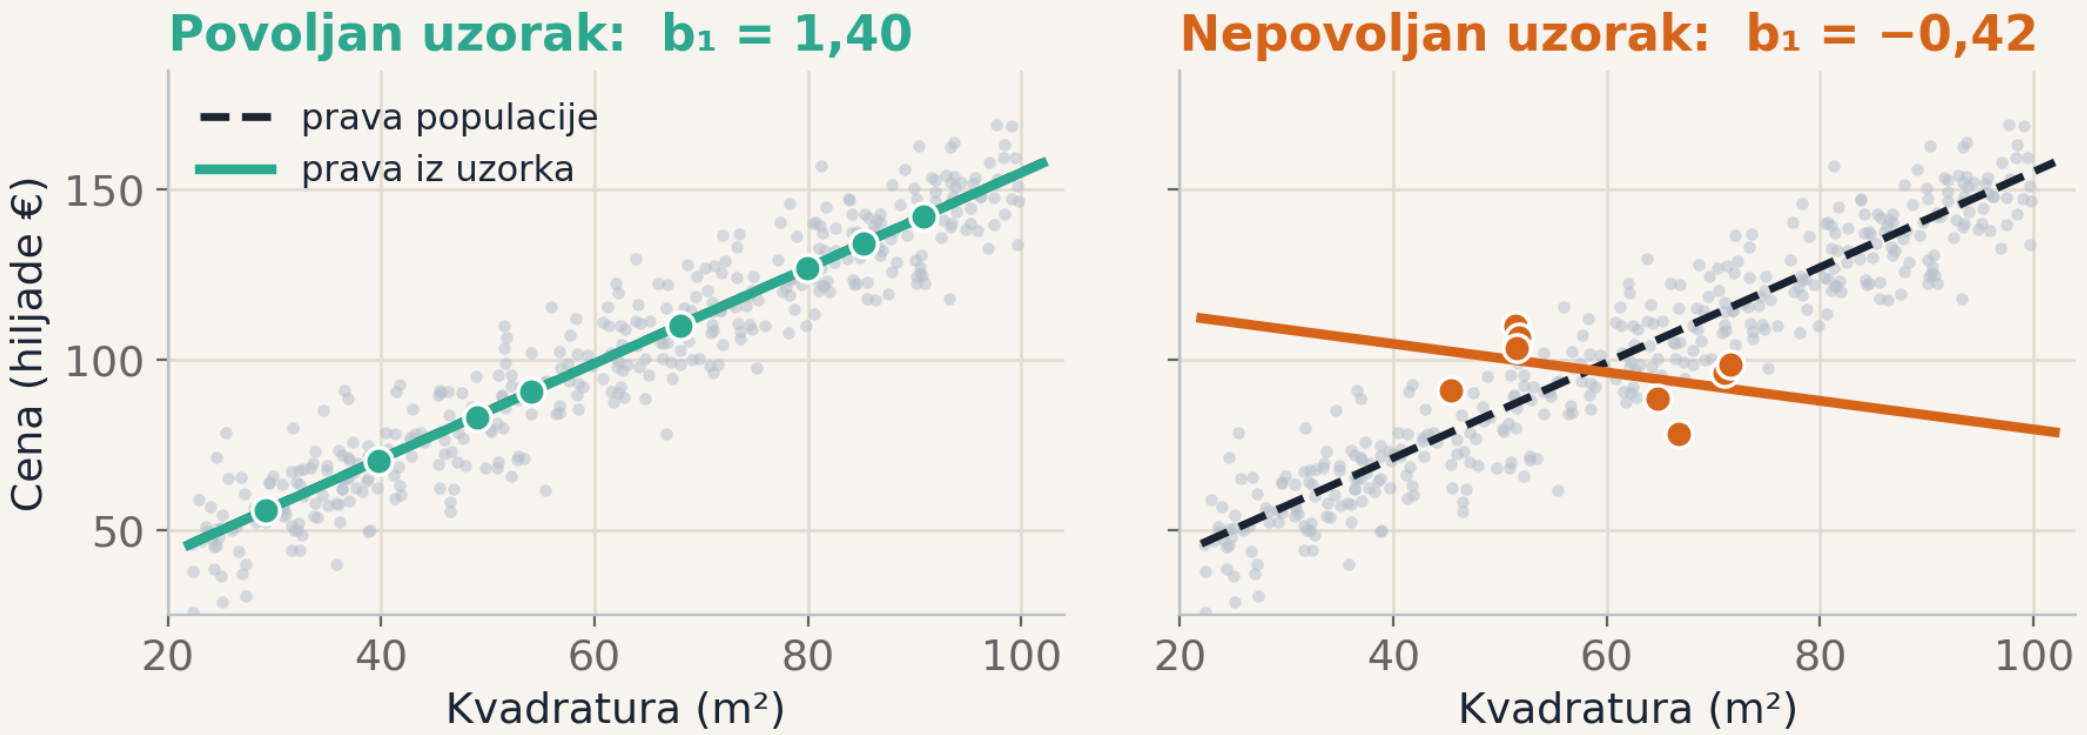


- Uzeli smo 6 različitih uzoraka od po 8 stanova.
- Svaki uzorak daje malo drugačiju pravu: nagibi su od 1,11 do 1,78.
- Prava populacije (isprekidana) je uvek ista, ali je ne znamo.

Zato pitamo: koliko smo sigurni u naš b_1? Pogledajmo dva slučaja na sledećem slajdu.

Povoljan i nepovoljan uzorak

Isti stanovi, dva uzorka od po 8: dve potpuno različite prave.



Pouka: ne znamo da li nam je uzorak povoljan ili nepovoljan, pa moramo da procenimo koliko smemo da mu verujemo.

Zaključivanje o verdnostima parametara regresije

Koliko verujemo uzorku podataka koji imamo?

Populaciju ne vidimo: koliko sememo da verujemo uzroku?

Zato nam treba zaključivanje o parametrima.

β

Parametar: ono što tražimo

Kod nas: β_1 za sve stanove.

b

Procena: ono što imamo

Kod nas: b_1 iz 8 stanova.

Zaključivanje o parametrima kaže koliko smemo da verujemo modelu napravljenom na uzorku.

Zaključivanje je svuda oko nas

Mali uzorak testiramo da bismo odlučili o svima.

Lekovi

Lek se testira na stotinak ljudi, a odluka važi za milione pacijenata.

Uzorak → svi pacijenti

Automobili

Tokom tesitranja se namerno slupa uzorak vozila, a ocena bezbednosti važi za sva vozila tog modela.

Uzorak → ceo model

Regresija

Model pravimo na uzorku, a pitamo se koliko taj model važi za celu populaciju.

Uzorak → populacija

Svuda je pitanje isto: koliko smemo da verujemo zaključku iz uzorka?

Nesigurnost u vrednost dobijenu iz uzorka

Procenu uvek saopštavamo zajedno sa poverenjem (merom nesigurnosti) u nju.

Procena cene stana

Banka koja odobrava kredit za stan sa procenom 82.000 € traži raspon u kom cena može da bude, a ne samo jedan broj.

82.000 € ± 5.000

Marketing: budžet za reklame (x) → prodaja (y)

Recimo da je $b_1 = 3$, tj. svaki dodatni evro u reklamu donosi oko 3 € prodaje. Interval [0,5; 5,5] kaže da donja granica ne pokriva ni trošak, pa ulaganje može da bude gubitak. Interval [2,5; 3,5] bi bio siguran signal da se isplati. Ista procena, različita odluka.

3 € ± 2.5 ili 3 € ± 0.5

Regresija

Nagib $b_1 = 1{,}42$ iz 8 stanova je procena. Interval kaže gde je verovatno pravi nagib.

$b_1 = 1{,}42 \pm ?$

Uvek je dobro reći koliko poverenja imamo u procenu. Broj bez te mere deluje preciznije nego što jeste.

Kako izmeriti poverenje u procenu?

Za to postoje gotovi alati iz statistike.

?

Problem

Imamo b_1 iz uzorka, a zanima nas β_1 iz populacije.

→

Alat

Zaključivanje o parametrima: koliko b_1 može da odstupa od β_1.

Prvo ćemo videti koja dva pitanja postavljamo, a zatim ih razraditi na primeru.

Alat i uslovi upotrebe

Svaki statistički alat daje tačan odgovor samo pod određenim uslovima.

1

Alat: zaključivanje

p-vrednost i intervali mere koliko b_1 može da odstupa od β_1.

2

Uslovi upotrebe

Formule važe samo ako se greške ponašaju kako se očekuje (L.I.N.E).

Kao kuhinjska vaga: uvek pokaže neki broj, ali je tačna samo na ravnoj podlozi. Prvo učimo alate, a zatim proveravamo da li je „podloga ravna“.

Primer: novi lek za pritisak

Isti model kao kod stanova, samo drugi podaci.

Eksperiment

Lek smo dali 50 pacijenata u različitim dozama i merili pad pritiska.

x = doza, y = pad

Naš nagib

Prava iz uzorka kaže: svaki dodatni mg leka snižava pritisak za oko 0,8 jedinica.

$b_1 = 0{,}8$

Pitanje

To je samo uzorak od 50 ljudi. Šta zaista važi za sve pacijente?

$\beta_1 = ?$

Pre nego što lek stigne u apoteke, moramo da znamo koliko smemo da verujemo broju 0,8.

Dva pitanja o leku

Svako od pitanje zahteva drugačiji odgovor i drugi statistički alat.

1

Da li lek uopšte deluje?

Ili je pad pritiska slučajan? Kod nas: da li je $\beta_1 \neq 0$. Alat: p-vrednost.

2

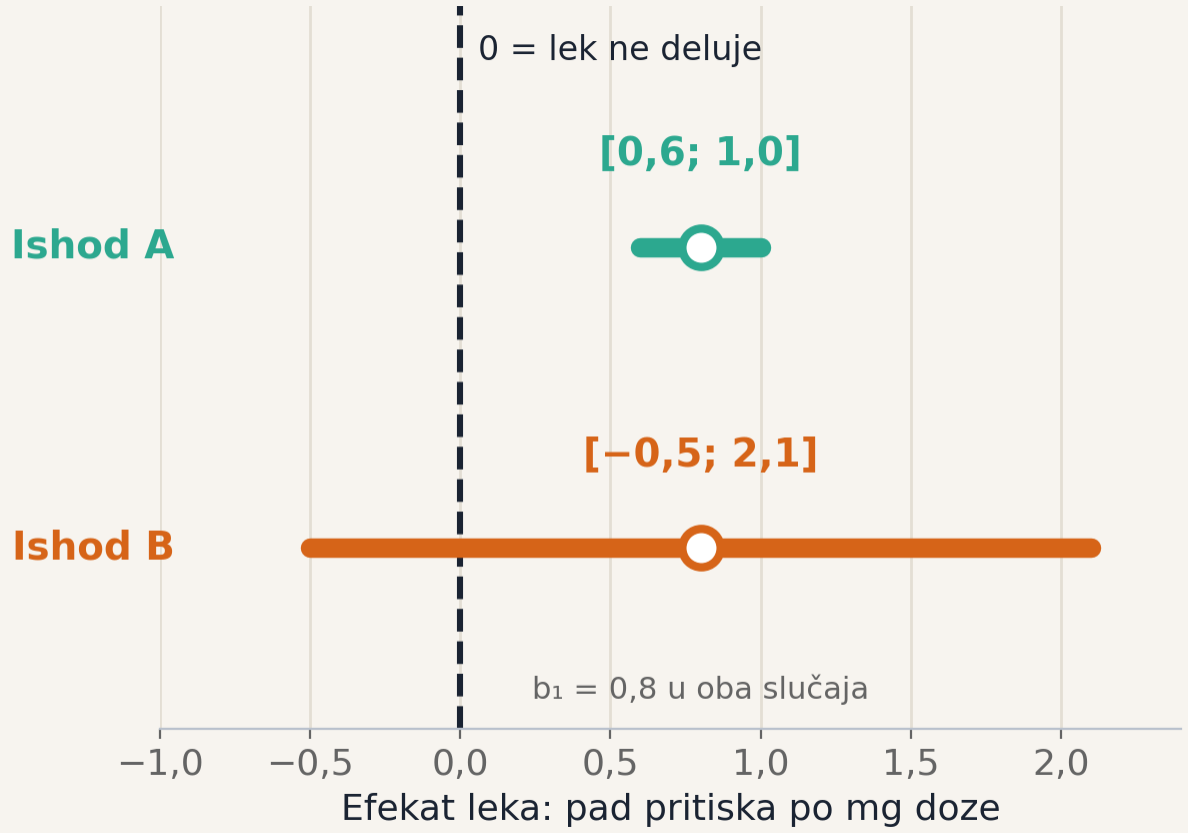
Koliko jako deluje?

Treba nam opseg efekta. Kod nas: u kom opsegu je β_1. Alat: interval poverenja.

Prvo pitanje je „da ili ne“, drugo je „koliko“. Lek sa efektom 0,1 i lek sa efektom 2 nisu isto, čak i kada oba deluju.

Isti nagib, različita sigurnost

Dva moguća ishoda eksperimenta sa lekom.



- Ishod A: interval [0,6; 1,0] ne sadrži 0. Lek deluje, a znamo i koliko.
- Ishod B: interval [−0,5; 2,1] sadrži 0. Ne možemo da tvrdimo ni da lek uopšte deluje.
- U oba slučaja je $b_1 = 0{,}8$.

Pouka: isti nagib, potpuno različit zaključak. Zato nam nije dovoljan sam broj b_1, treba nam i mera nesigurnosti.

Zaključivanje o parametrima regresije

Četiri koraka, na realnom primeru od 280 kuća. Zatim proveravamo uslove upotrebe.

1. **Procena:** nagib b_1 iz uzorka.
2. **Nesigurnost:** standardna greška kaže koliko b_1 „skače“ od uzorka do uzorka.
3. **Test:** t-vrednost i p-vrednost odgovaraju na pitanje da li veza postoji.
4. **Interval:** poverenja za nagib i predikcije za cenu jedne kuće.

PRIMER · KUĆE

Pravi podaci: 280 kuća

Kuće prodate u kanadskom gradu Windsoru 1987. godine.

Kuća	Cena ($)	Plac (m^2)
1	74.700	658,5
2	85.000	652,4
3	68.500	650,6
4	82.900	650,6
5	86.000	641,3
6	78.900	641,3
…	…	…
Ukupno	280 kuća	

y

Cena kuće ($)

Zavisna promenljiva: želimo da je predvidimo.

x

Površina placa (m^2)

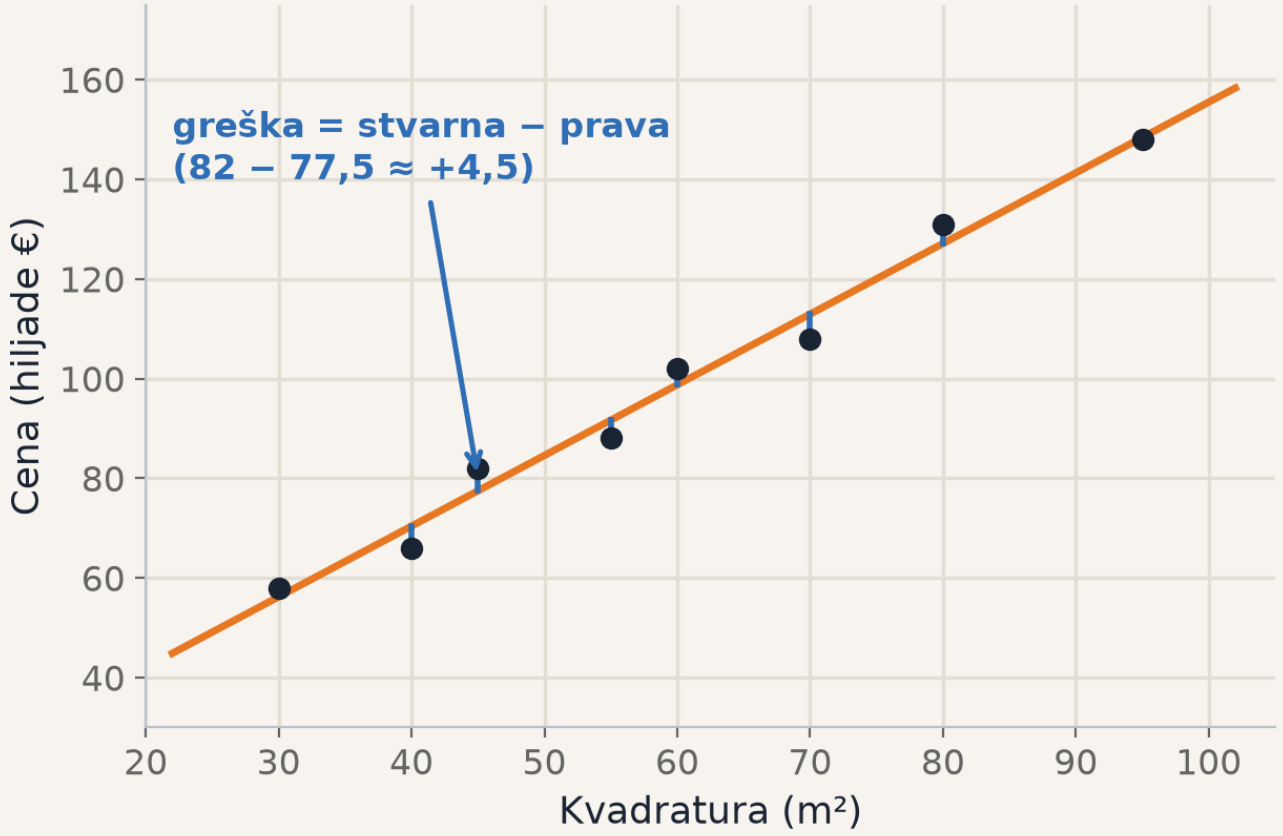
Nezavisna promenljiva: koristimo je za predviđanje.

Skup ima još 11 atributa (sobe, kupatila, garaža…). Njih koristimo kod višestruke regresije.

MODEL

Podsećanje: model je prava + slučajna greška

Tačke ne leže na pravoj. Razliku između tačke i prave zovemo greška.



$$Y = \beta_0 + \beta_1 \cdot X + \varepsilon$$

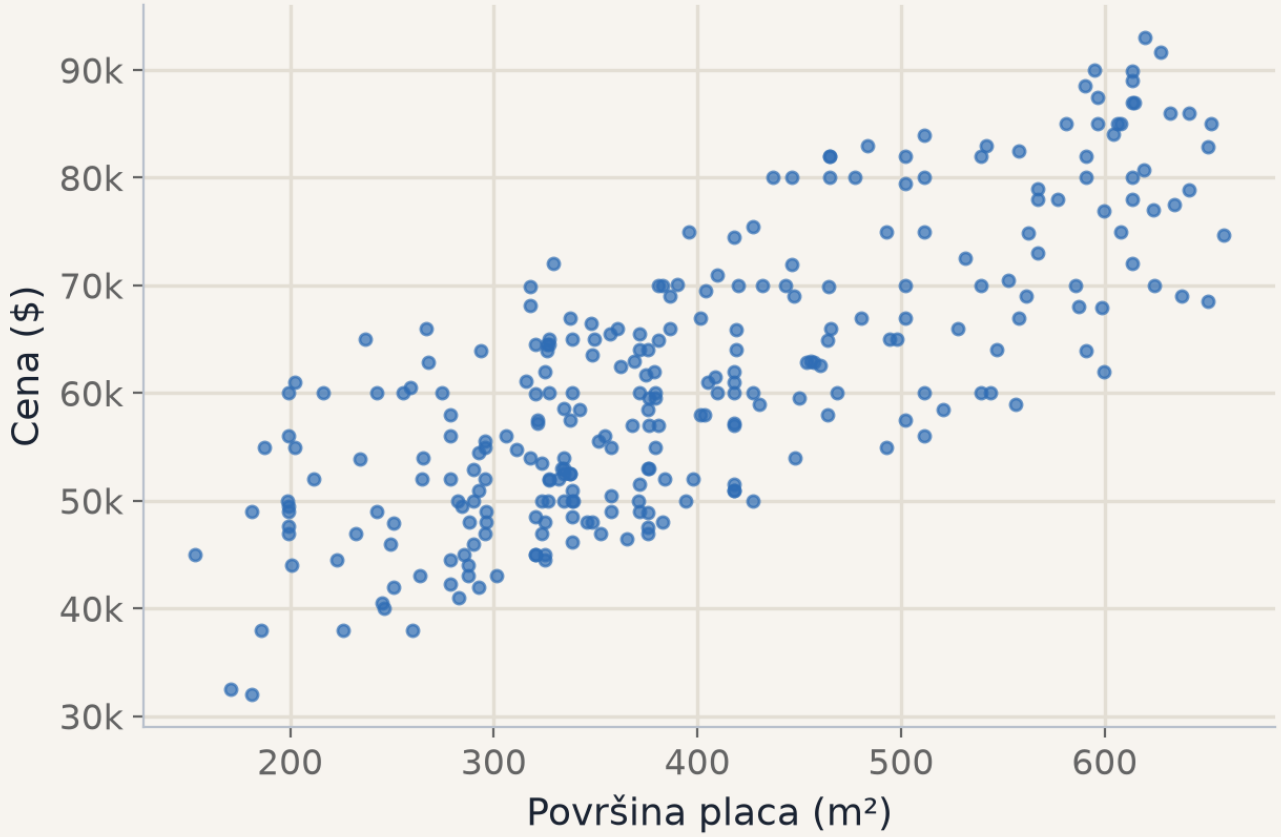
$\beta_0 + \beta_1 \cdot X$: deo koji objašnjava x (prava).

ε (epsilon): sve ostalo što utiče na cenu: lokacija, sprat, godina gradnje, slučajnost.

Prave greške ε ne znamo. Iz podataka računamo **reziduale**:
$e = y - \hat{y}$ (stvarna − predviđena vrednost).

Grafik rasipanja: kuće

Veći plac, u proseku skuplja kuća.

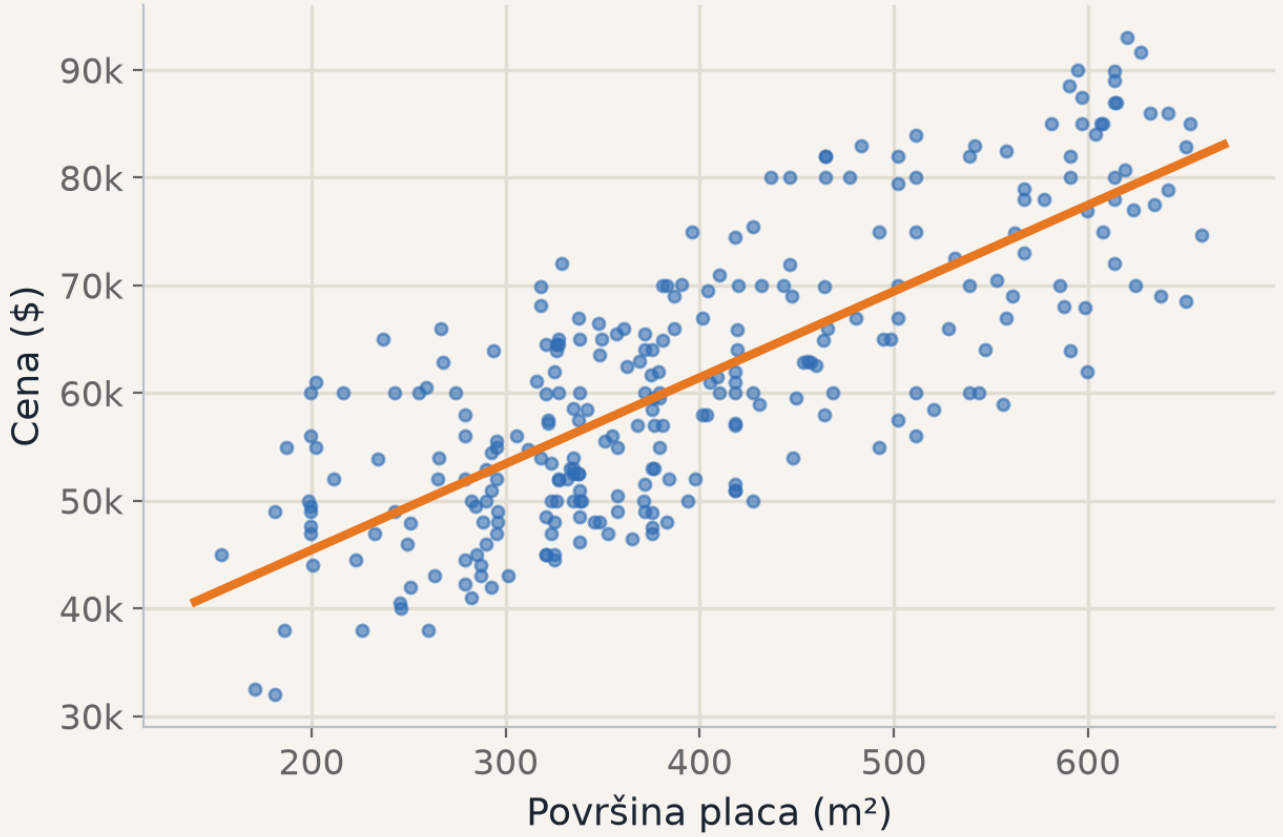


- Vidimo jasan rastući trend.
- Tačke su dosta rasute: veza postoji, ali nije savršena.
- Na cenu utiče još mnogo toga osim placa.

PRIMER · KUĆE

Regresiona prava za kuće

Metodom najmanjih kvadrata dobijamo pravu.



cena = 80,07 · plac + 29.422

```
from sklearn.linear_model import
LinearRegression
m = LinearRegression().fit(X, y)
m.coef_, m.intercept_   # 80.07, 29421.88
```

Iste formule kao u predavanju 2, samo sa 280 kuća umesto 8 stanova.

PRIMER · TUMAČENJE

Podsećanje: Šta znače b_1 i b_0?

$b_1 = 80{,}07$

Kada plac poraste za 1 m^2, cena kuće poraste u proseku za oko 80 $.

Plac veći za 100 m^2: kuća skuplja za oko 8.000 $.

$b_0 = 29.422$

Cena kuće kada je plac 0 m^2.

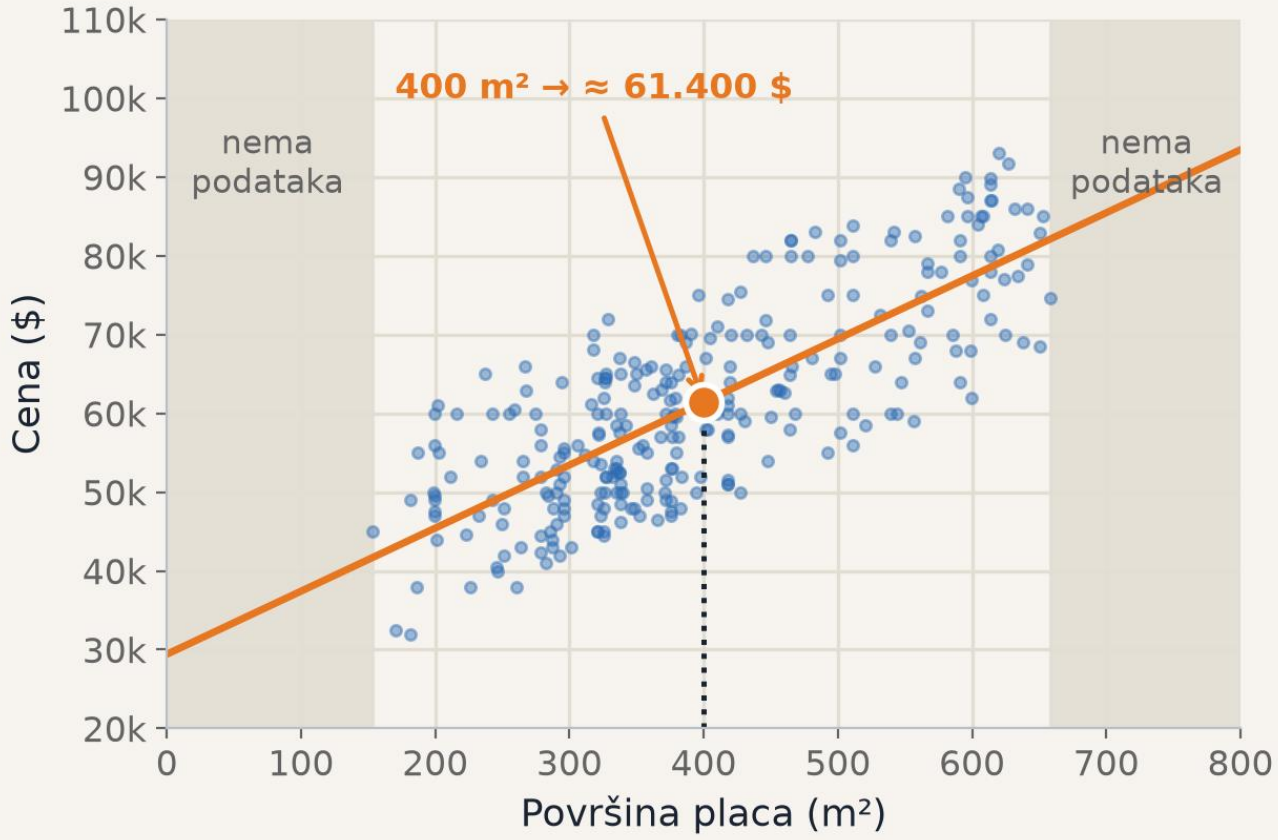
Takva kuća ne postoji, pa b_0 nema praktično značenje. Samo postavlja pravu na pravo mesto.

„U proseku“: model opisuje prosečnu cenu kuća sa datim placem, a ne cenu svake kuće.

PREDVIĐANJE

Podsećanje: Predviđanje cene nove kuće

Površinu placa ubacimo u formulu.



80,07 · 400 + 29.422 ≈ 61.450 $

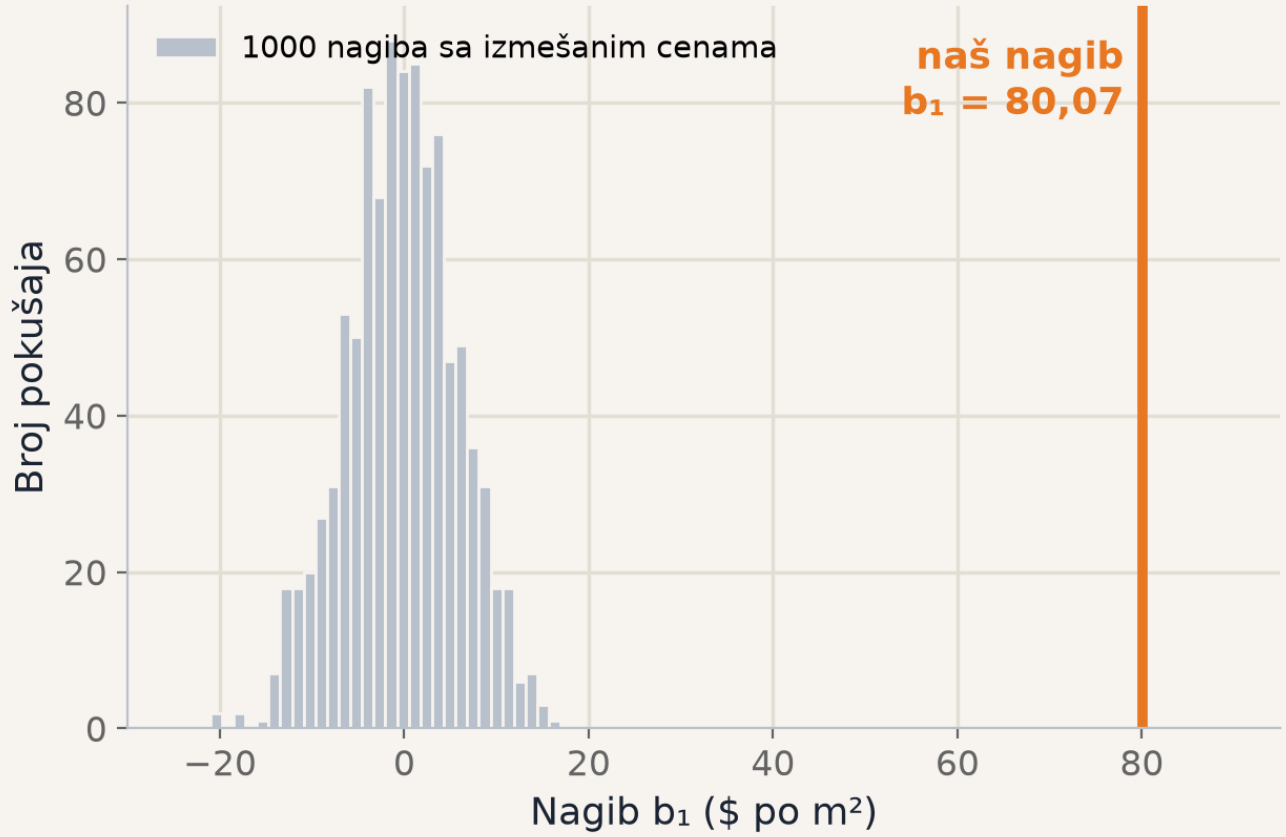
- Podaci pokrivaju placeve od 153 do 658 m^2.
- Van tog opsega (sivo) ne znamo da li prava i dalje važi. Npr. plac od 100 m^2 je izvan podataka.

Sledeće pitanje: koliko smemo da verujemo ovoj proceni?

ZAKLJUČIVANJE

Da li veza zaista postoji?

Nagib $b_1 = 80$ dobili smo iz jednog uzorka. Šta ako je to slučajnost?



- **Eksperiment:** nasumično izmešamo cene među kućama. Tako veza sa placem sigurno nestaje.
- Ponovimo 1000 puta. Nagibi su tada između −21 i +17.
- Naš nagib 80 je daleko od svih njih: to nije slučajnost.

Proveravamo hipotezu $\beta_1 = 0$ (plac ne utiče na cenu). t-test radi isto, ali formulom umesto mešanja.

ZAKLJUČIVANJE · STATISTIČKI TEST

Kako odlučujemo da li je veza ubedljiva?

Ne pitamo samo koliki je nagib, već da li je rezultat uverljiv ako veze zapravo nema.

1. Polazna pretpostavka

Pretpostavimo da u populaciji nema linearne veze između površine placa i cene.

$H_0: \beta_1 = 0$

2. Uporedimo sa podacima

U uzorku smo dobili nagib $b_1 = 80{,}07$. Koliko je taj rezultat udaljen od onoga što očekujemo ako H_0 važi?

$b_1 = 80{,}07$

3. Izmerimo iznenađenje

Statistički test izračunava statistiku testa i procenjuje koliko bi ovako ekstreman rezultat bio neuobičajen pod H_0.

To vodi do p-vrednosti.

Važno: ne dokazujemo da je H_0 tačna. Proveravamo da li su podaci dovoljno neuobičajeni da bismo je odbacili.

Statistički test kao suđenje

Pretpostavimo da je okrivljeni nevin. Koliko bi nas iznenadio dokaz? To meri p-vrednost!

Pretpostavka

Okrivljeni je nevin.
U regresiji: nema veze, $\beta_1 = 0$.

H_0: $\beta_1 = 0$

Dokaz

U njegovom stanu nalazimo oružje ubistva.
U regresiji: naš nagib b_1 iz uzorka.

Kuće: $b_1 = 80{,}07$

p-vrednost

Koliko je verovatno da bismo kod nevinog čoveka našli oružje ubistva? Ako je jako malo, sumnjamo u nevinost.

Kuće: $p < 0{,}001$

Mala p-vrednost ne dokazuje krivicu. Kaže samo da je ovakav dokaz vrlo neobičan za nevinog čoveka.

t-TEST: Signal i šum

Test poredi koliko je efekat jak sa koliko je naša procena nesigurna.

Signal

Koliko je b_1 daleko od nule.

Kuće: 80,07

Šum

Standardna greška SE(b_1): koliko b_1 „skače“ od uzorka do uzorka. Veći uzorak, manji šum.

Kuće: 3,86

t = signal / šum

Koliko puta je signal jači od šuma.

Kuće: 80,07 / 3,86 = 20,8

Kao razgovor: u čitaonici čujete i šapat, a na svadbi morate da vičete. Više šuma traži jači signal.

Od t-vrednosti do p-vrednosti

t-vrednost ne koristimo direktno već od nje dobijamo p-vrednost (to umesto nas radi softver)

t-vrednost: signal / šum

$t = b_1 / SE(b_1) = 80,07 / 3,86 = 20,8$

Veoma velika vrednost |t|

Šta očekujemo pod H_0?

Ako je $\beta_1 = 0$, uzorci bi obično davali t-vrednosti blizu nule. Ekstremne vrednosti su ređe.

Poređenje sa t-raspodelom

p-vrednost: koliko je retko?

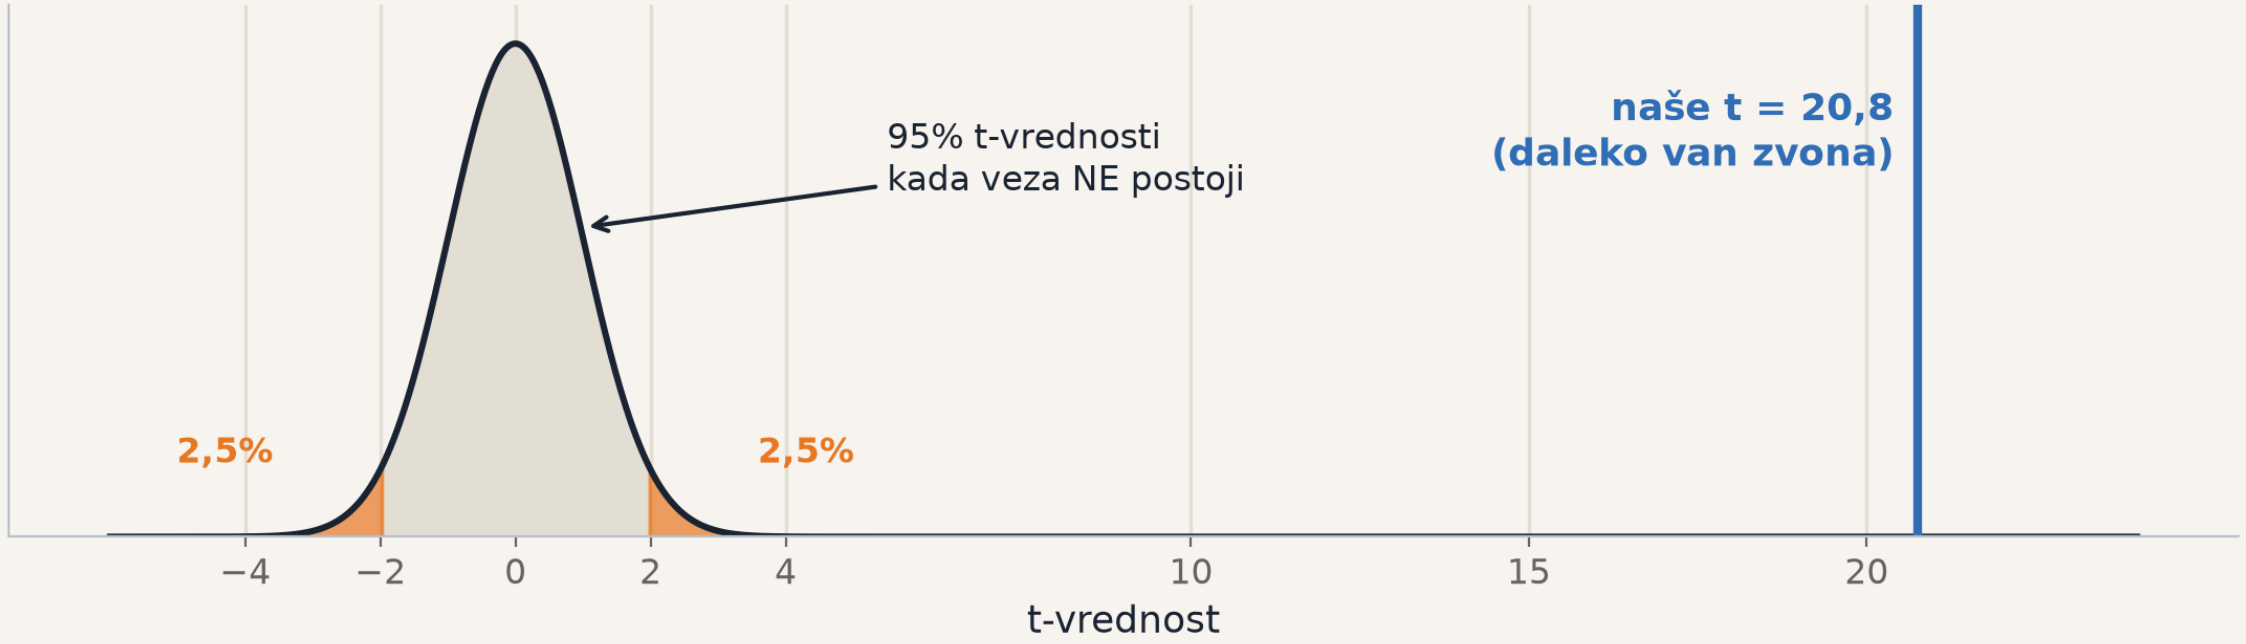
p-vrednost je verovatnoća da pod H_0 dobijemo t-vrednost bar ovoliko ekstremnu (u oba smera).

Ovde: $p < 0,001$

t-test daje t-vrednost; uz odgovarajuću t-raspodelu izračunamo p-vrednost.
Mala p-vrednost znači da je rezultat teško objasniti samo slučajnim uzorkovanjem ako H_0 važi.

p-vrednost: Da li je t = 20,8 mnogo?

Poredimo ga sa t-vrednostima koje bismo dobijali kada veza ne postoji.



p-vrednost = verovatnoća da samo slučajno, kada veza ne postoji, dobijemo ovako veliko t (ili veće). Kuće: p ≈ 0 (manje od 0,001).

Pravilo odlučivanja: p ≤ 0,05

Softver računa t i p umesto nas (Python biblioteka statsmodels).

	coef	std err	t	P>|t|	[0.025	0.975]
const	29421,88	1608,77	18,29	0,000	26255	32589
plac (m^2)	80,07	3,86	20,76	0,000	72,48	87,66

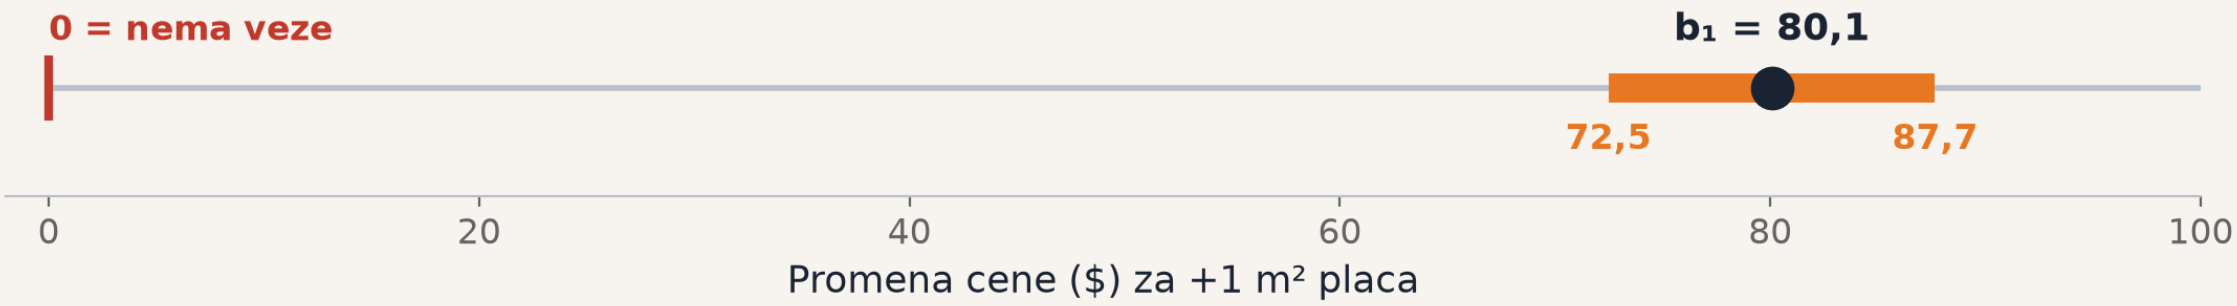
p ≤ 0,05: veza postoji ($\beta_1 \neq 0$). Rizik da pogrešimo je najviše 5%.

p > 0,05: ne možemo da tvrdimo da veza postoji.

Kuće: p < 0,001, pa površina placa zaista utiče na cenu kuće.

Interval poverenja za nagib

Umesto jednog broja dajemo opseg u kome je verovatno prava vrednost β_1.



95% interval: [72,5; 87,7]

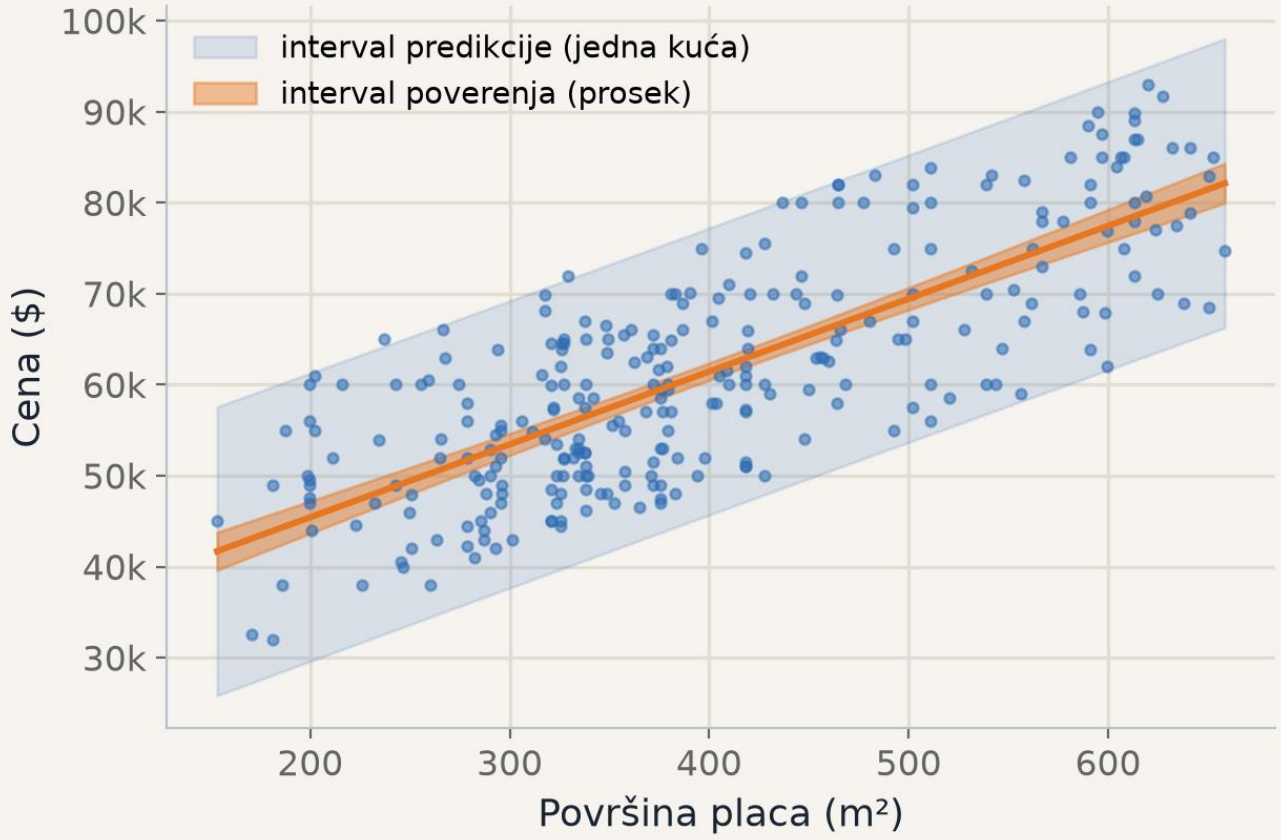
Kada plac poraste za 1 m^2, prosečna cena kuće poraste za 72 do 88 $ (sa 95% pouzdanosti).

Brza procena: $b_1 \pm 2 \cdot SE = 80{,}07 \pm 2 \cdot 3{,}86$

Interval ne sadrži 0. To je isti zaključak kao $p \leq 0{,}05$: veza postoji.

Interval predikcije: cena jedne kuće

Koliko stvarna cena jedne kuće može da odstupa od prave?



Interval poverenja (narandžasto): gde je **prosečna** cena kuća sa datim placem. Uzak.

Interval predikcije (plavo): gde će biti cena **jedne** kuće. Širok, jer uključuje i grešku ε te kuće.

Plac 658 m^2: procena 82.144 $.

95% interval predikcije: **[66.258; 98.030] $**.

Zašto je interval predikcije tako širok?

Širina zavisi od tipične greške modela.

Tipična greška modela:

$s \approx 7.993$ $

Interval ≈ procena ± 2 · s

= 82.144 ± 16.000 $

Kako ga suziti?

1. Više atributa (sobe, kupatila, lokacija...). Tema sledećeg predavanja.
2. Više podataka. Pomaže, ali nove podatke je često teško nabaviti.

$R^2 = 0,61$: površina placa objašnjava oko 61% razlika u cenama. Ostatak je u grešci ε.

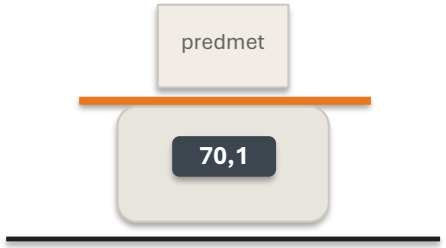
Provera pretpostavki regresije

Koliko verujemo p-vrednostima i intervalima poverenja?

Svaki statistički alat ima svoje pretpostavke

Pretpostavke su uslovi pod kojima alat može ispravno da se koristi

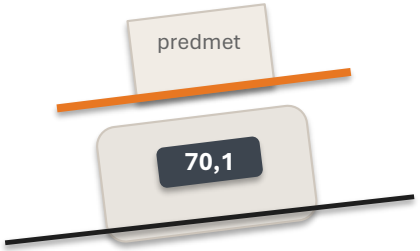
1 · Vaga na ravnoj podlozi
Alat koristimo ispravno - rezultatima verujemo



70,1 · 70,0 · 70,2 kg

To rasipanje je nesigurnost. Nju interval meri interval poverenja

2 · Vaga na neravnoj podlozi
Alat ne koristimo ispravno - rezultatima ne verujemo



Očitavanja mogu biti stabilna, a ipak pogrešna.

Još merenja ponavljaju istu grešku.

Zašto proveravamo pretpostavke?

Provere nam govore da li su p-vrednosti i intervali poverenja pouzdani.

Nevinost, dokaz i fer sistem

p-vrednost meri iznenađenje samo ako je suđenje fer.

NEVINOST

$H_0: \beta_1 = 0$

Nema veze. Suđenje počinje pretpostavkom nevinosti: optuženi je nevin dok dokaz ne pokaže suprotno.

DOKAZ

Nagib iz uzorka

p-vrednost pita: koliko bi nas ovaj dokaz iznenadio da je optuženi zaista nevin?

FER SISTEM

Prepostavke regeresije

Ako pravni sistem nije fer, p-vrednost nam ne znači ništa.

Interval od 95% je garancija postupka. Važi samo kad se ta pravila poštuju.

PRETPOSTAVKE

Četiri pretpostavke: L.I.N.E

Sve se odnose na to kako model opisuje vezu i greške oko procenjene prave.

L

Linearity

Linearnost

Veza između x i y je (približno) prava.

I

Independence

Nezavisnost grešaka

Greška jedne tačke ne govori ništa o grešci druge.

N

Normality

Normalnost grešaka

Greške su raspoređene kao zvono oko nule.

E

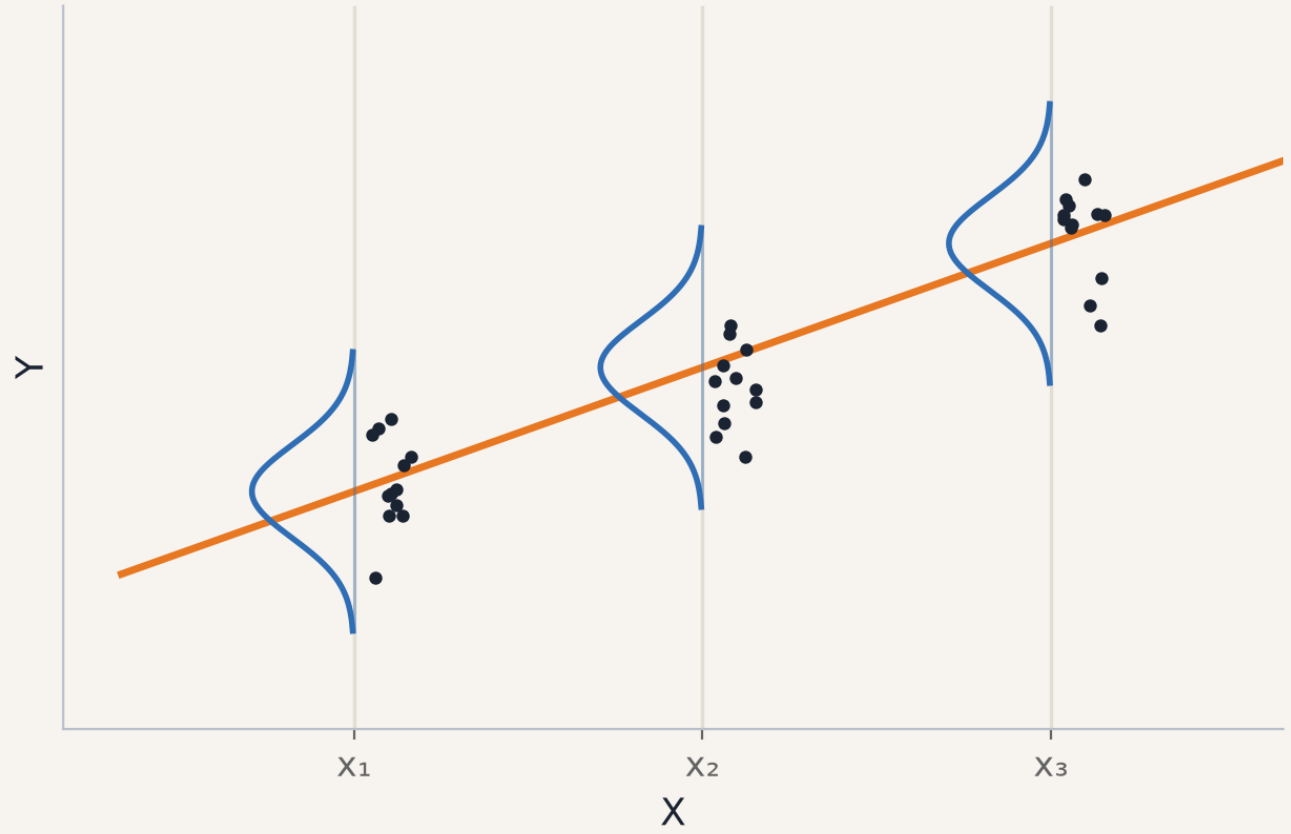
Equal variance

Jednaka varijansa

Rasutost oko prave je slična za svako x.

Jedna slika za sve četiri pretpostavke

Za svako x, vrednosti y su rasute oko prave po istom „zvonu“.



L: centri zvona leže na pravoj.

I: svaka tačka je „izvučena“ nezavisno od ostalih.

N: rasipanje ima oblik zvona (normalna raspodela) sa centrom na pravoj.

E: sva zvona su iste širine.

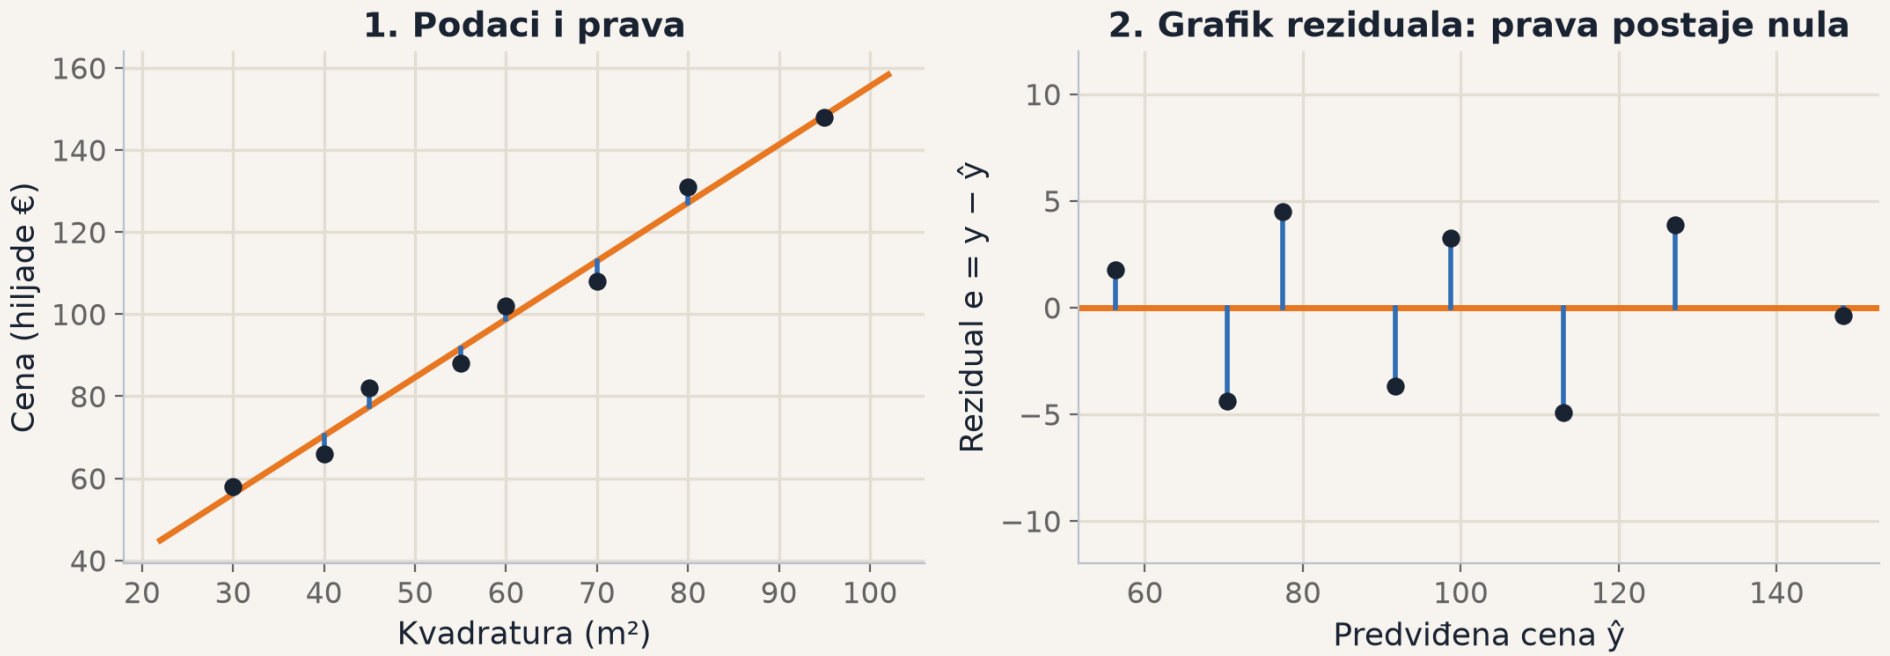
Kratko: $\varepsilon \sim N(0, \sigma^2)$

Greške su normalne, sa sredjnom vrednosti 0 i istom varijansom σ^2.

ALAT

Glavni alat: grafik reziduala

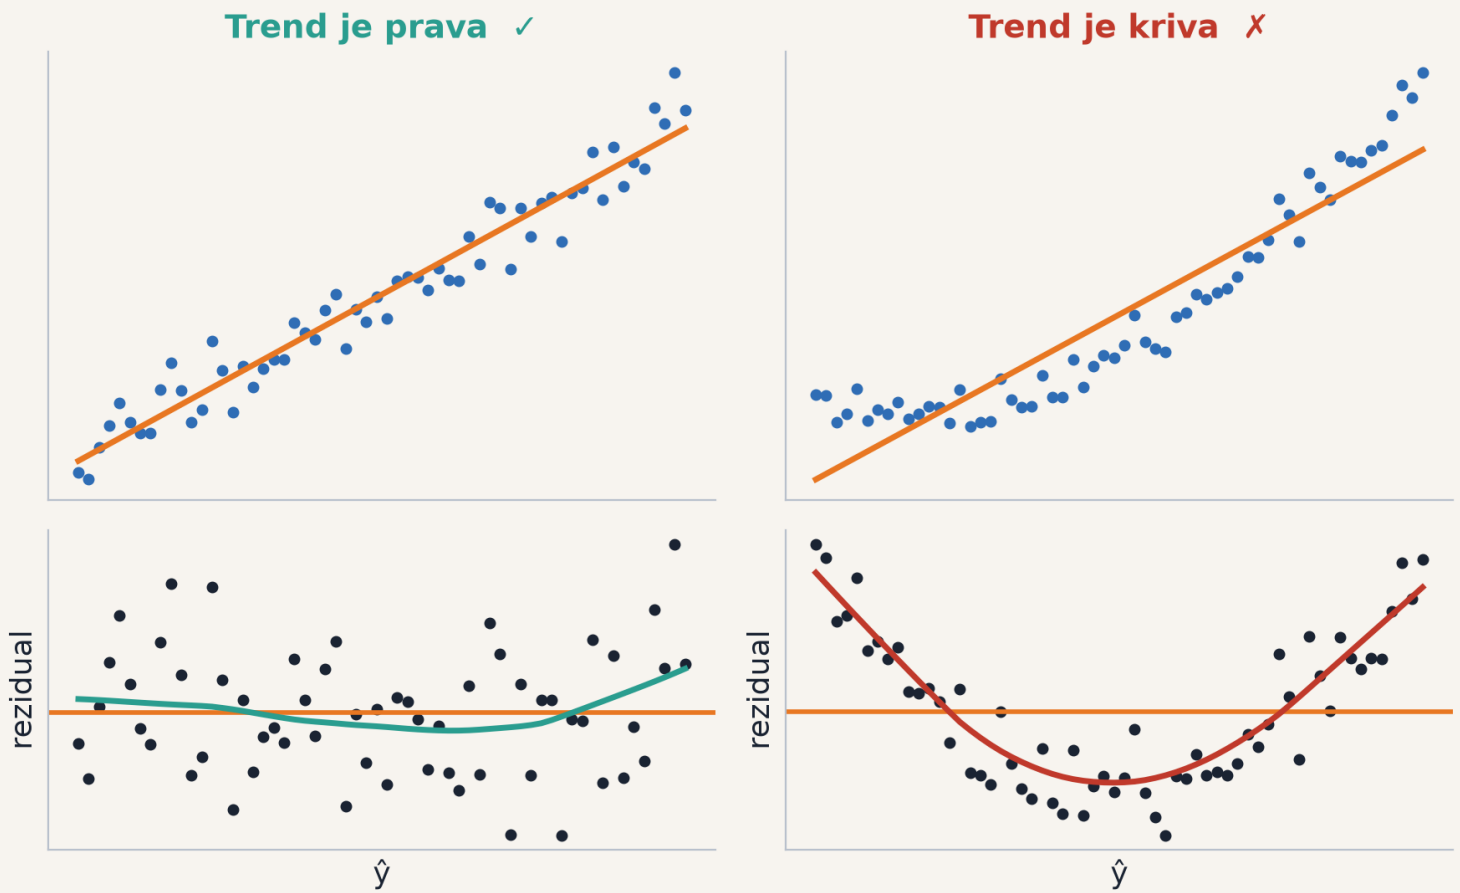
Prava postaje horizontalna linija na nuli, pa se odstupanja lako vide.



Rezidual e = y − ŷ. **Dobar model:** reziduali izgledaju kao slučajan oblak oko nule, bez ikakvog šablona.

Da li je trend zaista prava?

Ako nije, koristimo pogrešan model.

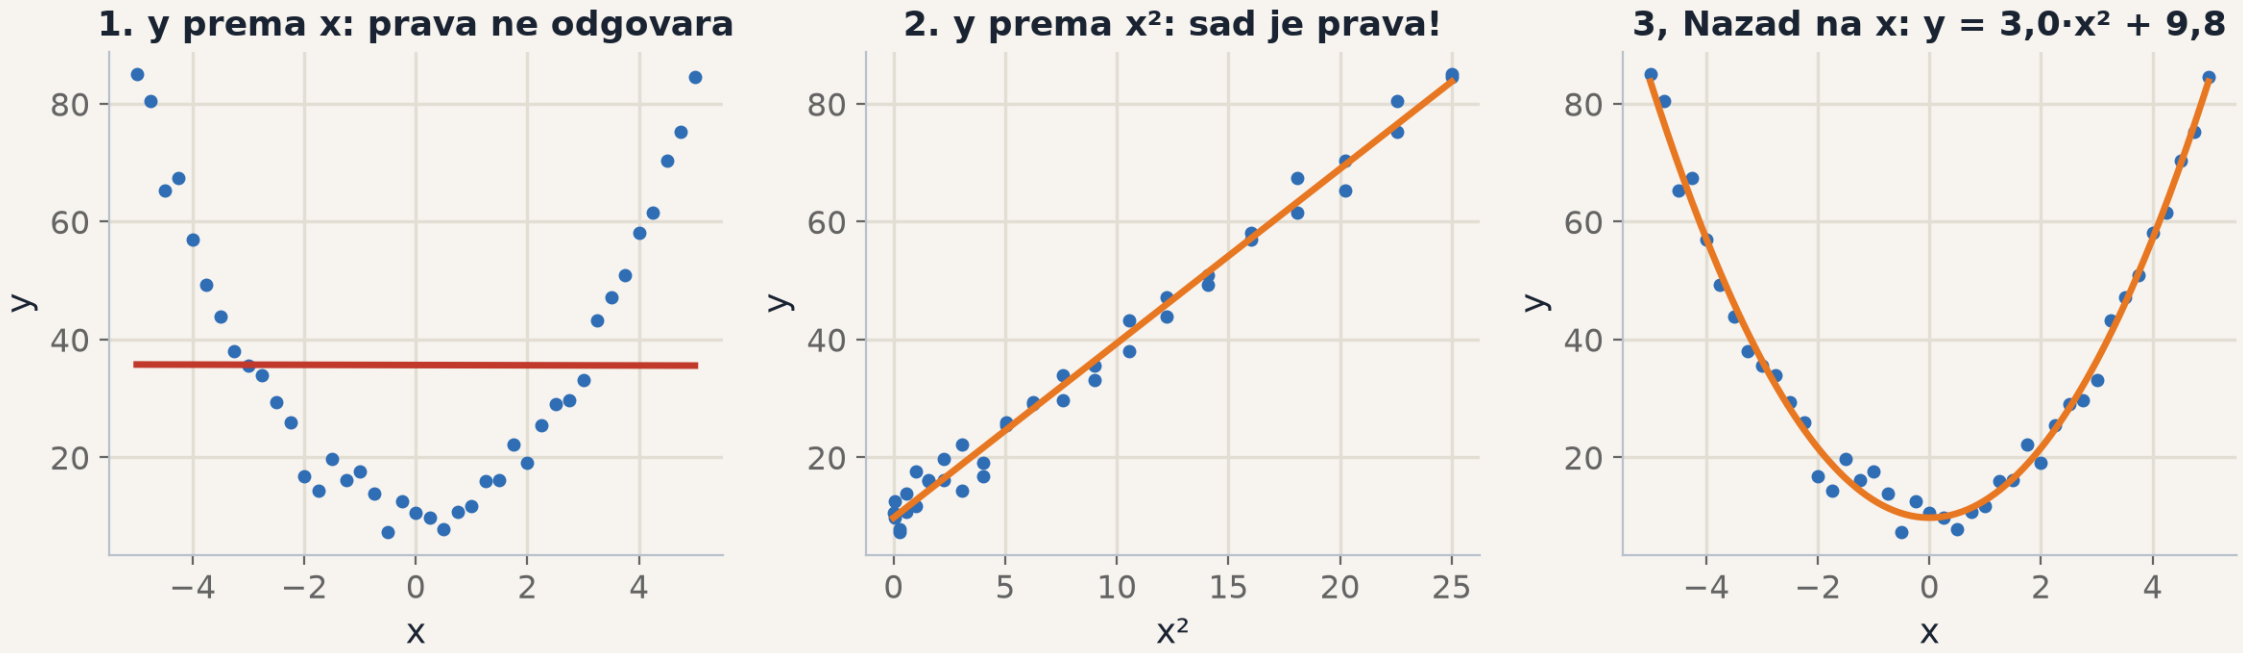


- Levo: tačke prate pravu, reziduali su slučajno rasuti oko nule.
- Desno: trend je kriv. Prava je na krajevima ispod tačaka, a u sredini iznad.
- Na grafiku reziduala to se vidi kao slovo U.

Linearnost je najvažnija pretpostavka. Ako ne važi, model ne valja ni za predviđanje.

Rešenje: transformišemo x

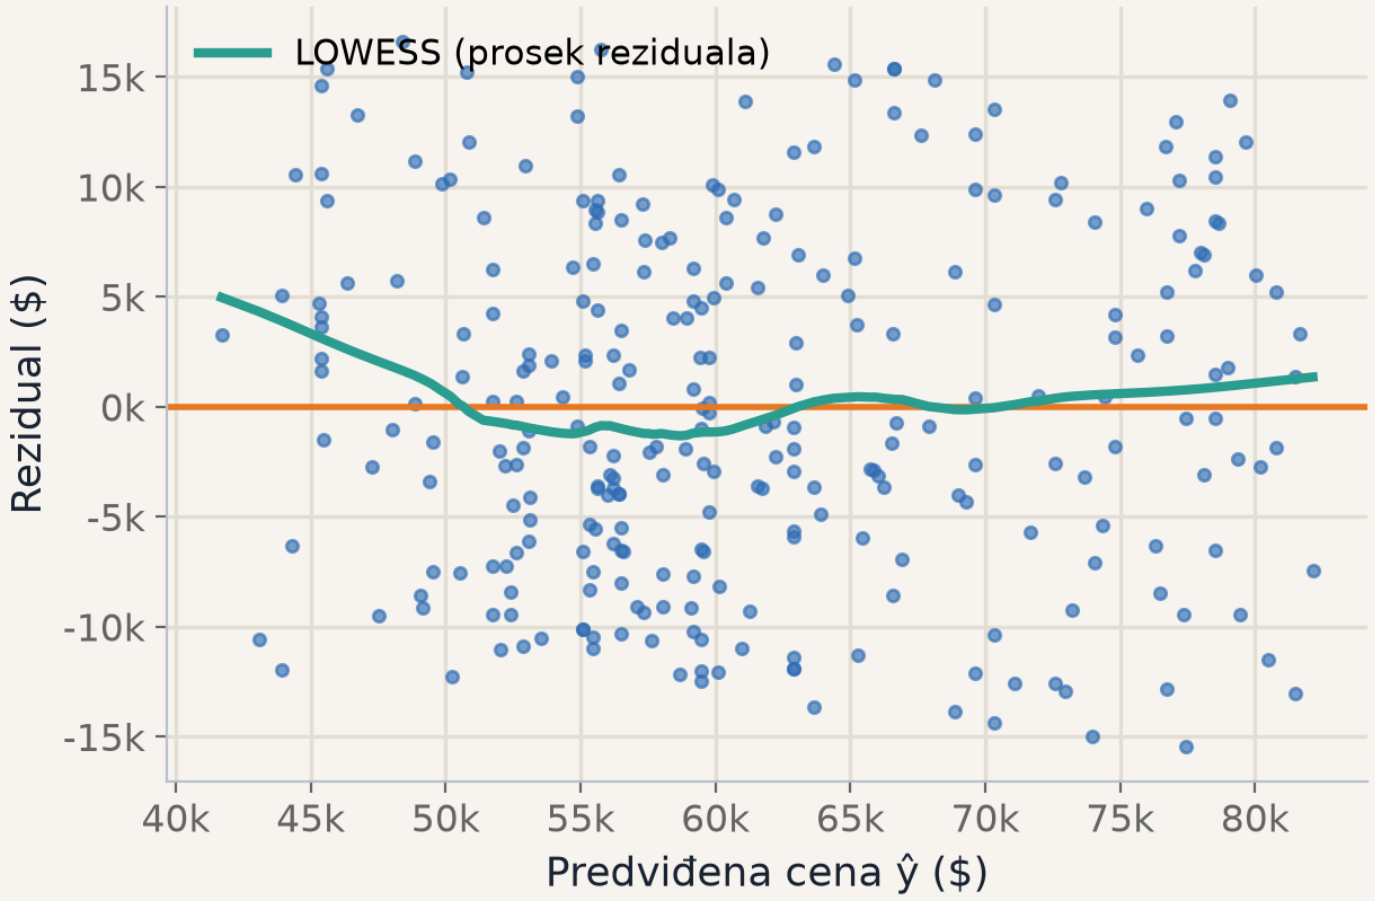
Linearna regresija može da opiše i krivu, ako izaberemo pravi x.



Model $y = 3{,}0 \cdot x^2 + 9{,}8$ je i dalje **linearan po parametrima** b_0 i b_1: umesto x smo samo uzeli x^2. Takve nove promenljive zovemo **obeležja** (features).

Kuće: linearnost važi

Grafik reziduala nema oblik krive.



- Reziduali su rasuti oko nule u celom opsegu.
- LOWESS* linija (prosek reziduala) je skoro ravna.

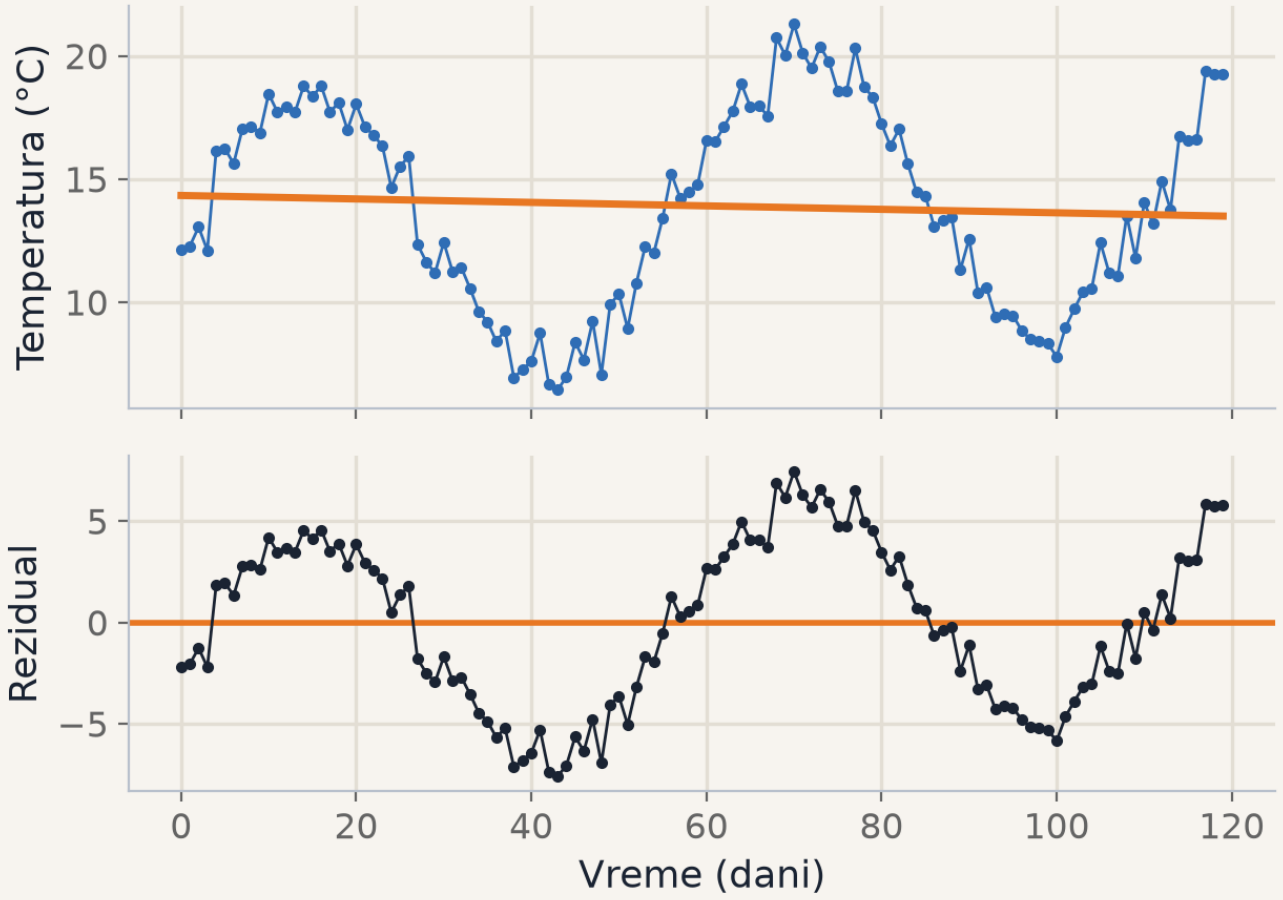
Ako ne važi:

- transformacija x (x^2, log x, $\sqrt{x}$)
- nelinearan model (npr. neuronska mreža)

- **Locally Weighted Scatterplot Smoothing* je glatka linija koja za svaki deo x-ose koristi samo obližnje tačke, pa pokazuje stvarni prosek reziduala u tom delu.
Ako je (skoro) ravna oko nule prepostavka o linearnosti je dobra.

Nezavisnost grešaka

Ako jedna greška pomaže da pogodimo sledeću, model nešto propušta.



- Primer: dnevna temperatura kroz vreme.

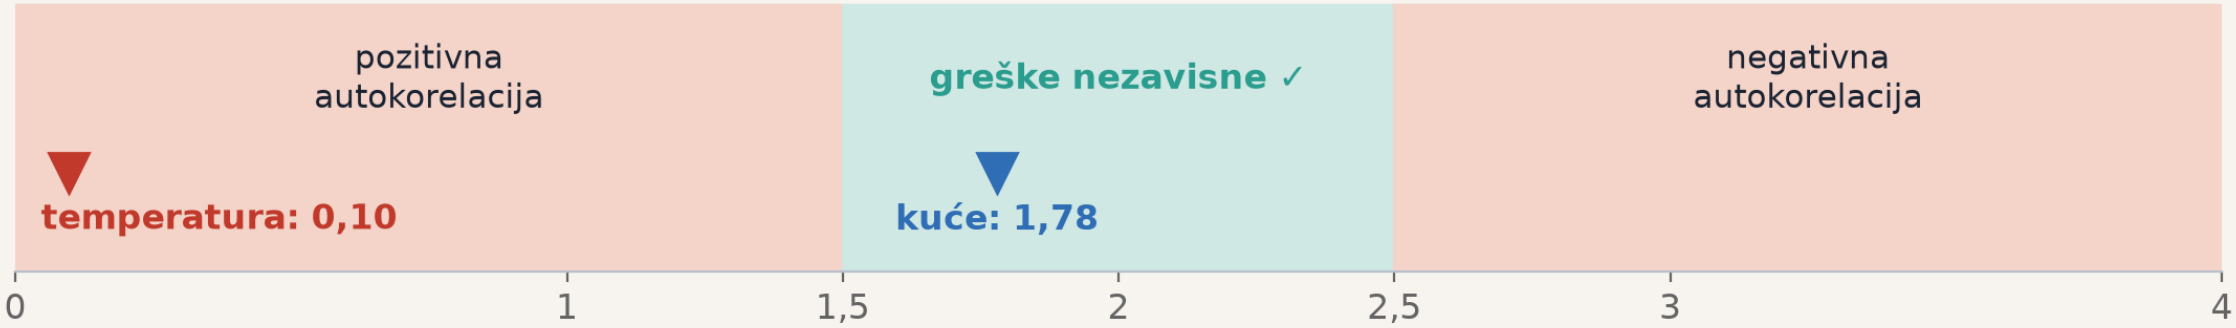
X je samo trenutni dan npr. dan 1, dan 2,..., bez informacija o tome šta je bilo prethodnih dana.

- Prava ne prati talase temperature (gornji grafik). To se vidi i iz reziduala (donji grafik).
- Ako je juče bilo toplo, verovatno je i danas. Tu informaciju model ne koristi.

Najčešće se javlja kod podataka merenih kroz vreme (**vremenske serije**).

Kako proveravamo nezavisnost?

Gledamo grafik reziduala i računamo Durbin-Watson test.



Durbin-Watson je broj od 0 do 4.

Pretpostavka važi ako je između 1,5 i 2,5.

Kuće: 1,78, važi. Temperatura: 0,10, ne važi.

Ako ne važi:

- dodati nove promenljive (sobe, kupatila...)
- za vremenske serije: posebni modeli
- p-vrednosti i intervali nisu pouzdani

Normalnost grešaka: dva dela

Greške imaju (1) oblik zvona i (2) prosek nula za svako x.

(1) Oblik zvona

Mnogo malih, malo velikih grešaka, simetrično oko nule.

Proveravamo: histogram reziduala i Shapiro-Wilk test.

(2) Prosek nula za svako x

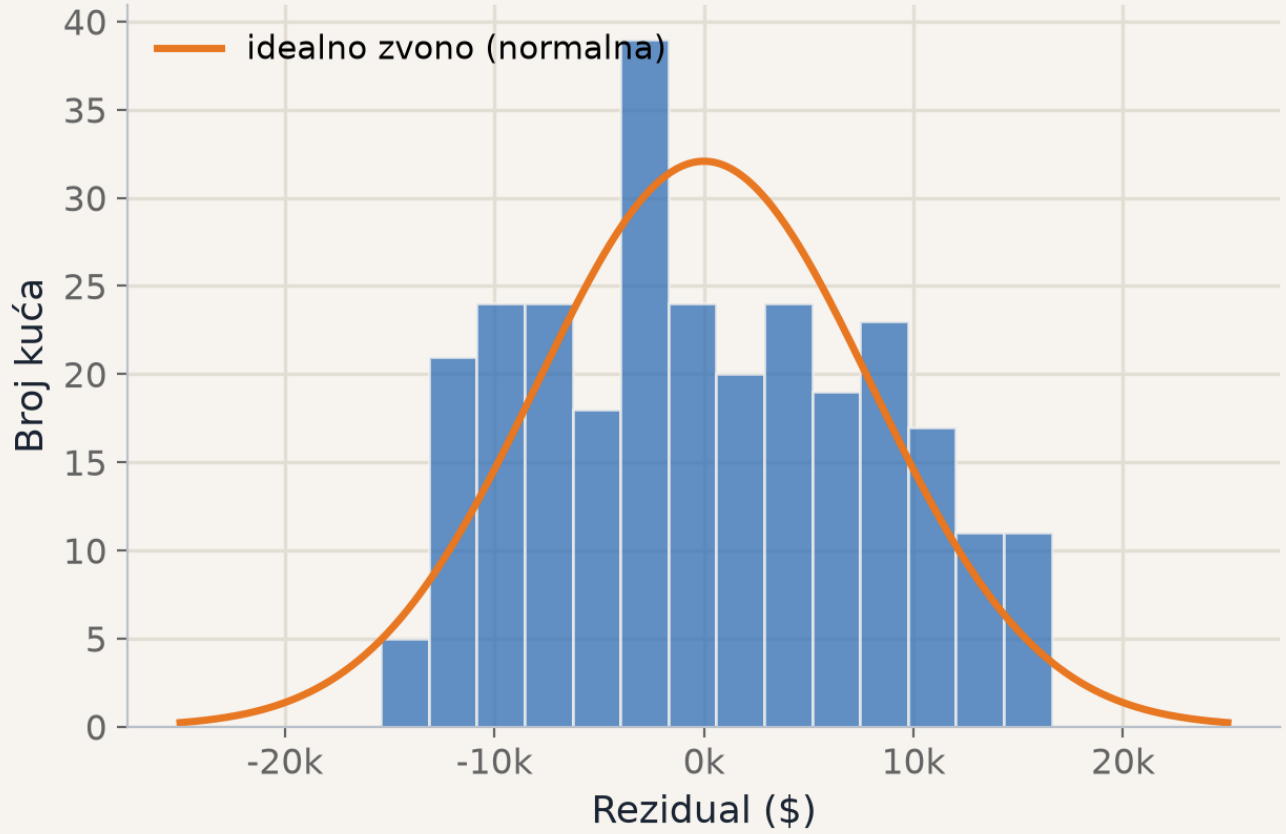
Za svako x model u proseku pogađa, bez sistematske greške.

Proveravamo: LOWESS linija na grafiku reziduala.

Prosek svih reziduala ne pomaže: kod najmanjih kvadrata je **uvek tačno 0** (dokaz u dodatku). Zato gledamo prosek za svako x.

Kuće: histogram reziduala

Zvono nije savršeno, pa test kaže da deo (1) ne važi.



Shapiro-Wilk: p = 0,00004

- Po definiciji testa: p ≥ 0,05 znači normalnost.

U našem sluaju je p < 0,05 - **deo (1) testa ne važi**.

- Histogram je „spljošten“ sa strana: premalo malih grešaka
- **Deo (2) važi**: LOWESS je ravna - to smo videli na prethodnim slajdovima.

Kada dodamo ostale atribute kuće (višestruka regresija), p = 0,124 i normalnost važi.

Šta ako normalnost ne važi?

Zavisi od toga koliko podataka imamo.

Veliki uzorak

- Grubo pravilo: n ≥ 105 (104 + broj promenljivih).
- Deo (1) se u praksi može zanemariti.
- Kuće: n = 280, pa smo u redu.

Mali uzorak

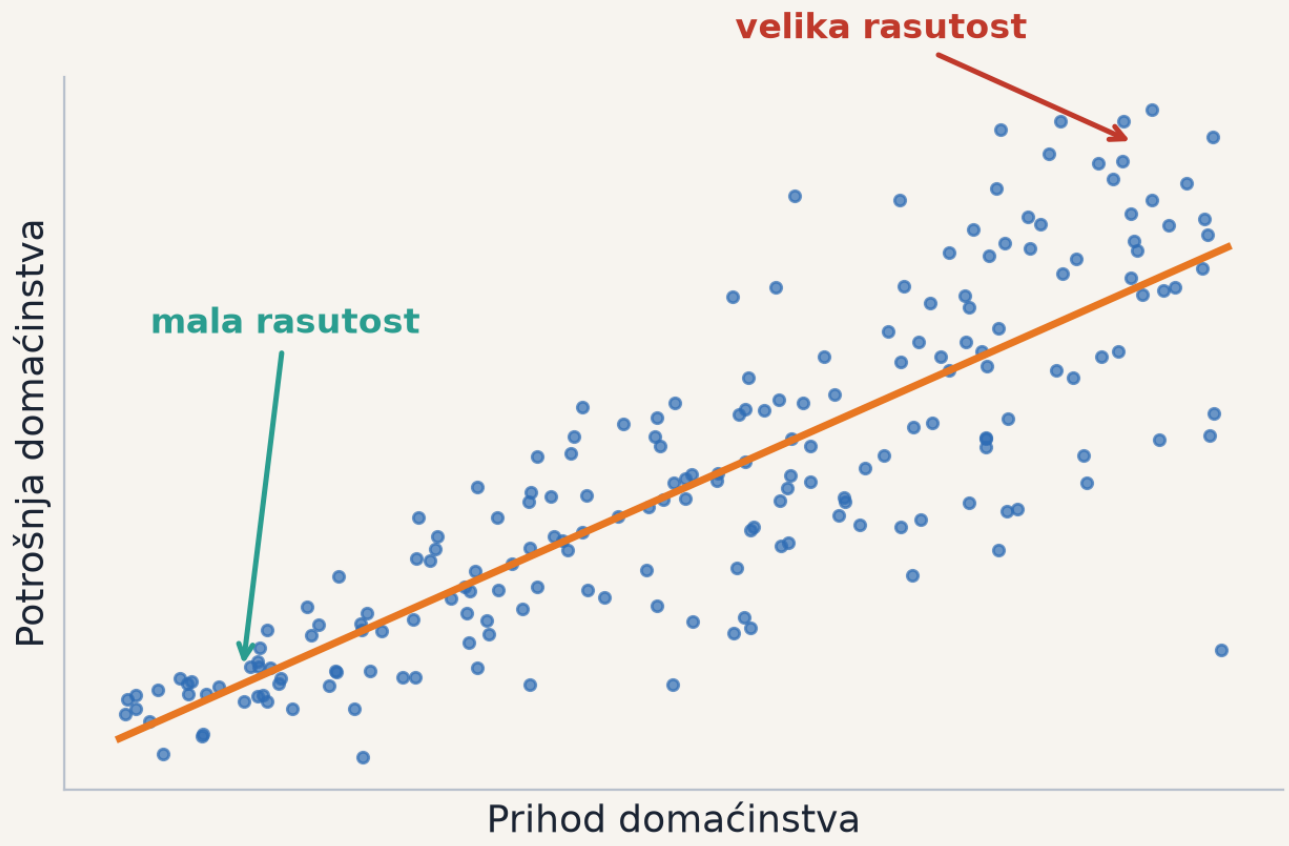
- p-vrednosti i intervali nisu pouzdani.
- Probati transformaciju x i/ili y (log, √).

Ako ne važi deo (2), model je pogrešan. Rešenja su ista kao kod linearnosti.

Pravilo za veličinu uzorka: Green, S. B. (1991), Multivariate Behavioral Research 26(3).

Jednaka varijansa grešaka

Želimo da model bude podjednako tačan za svako x.

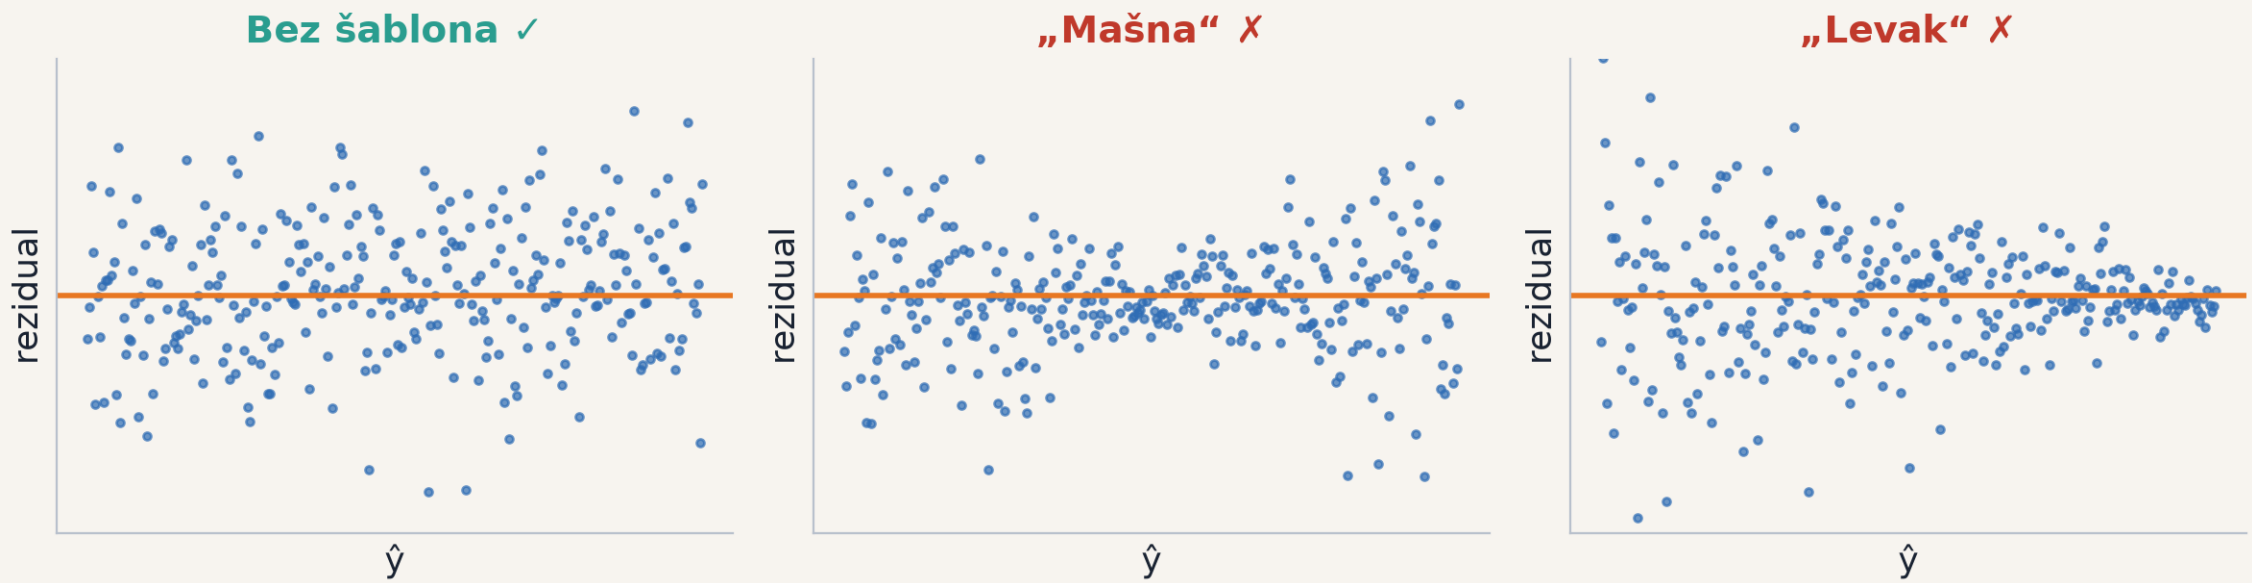


- Primer: potrošnja domaćinstva prema prihodu.
- Domaćinstva sa malim prihodom troše slično: mala rasutost.
- Bogatija domaćinstva mogu da troše malo ili mnogo: velika rasutost.

Procene za velike prihode su mnogo manje pouzdane nego za male.
To ne želimo.

Kako proveravamo: „levak“ i „mašna“

Na grafiku reziduala tražimo da li se širina oblaka menja.

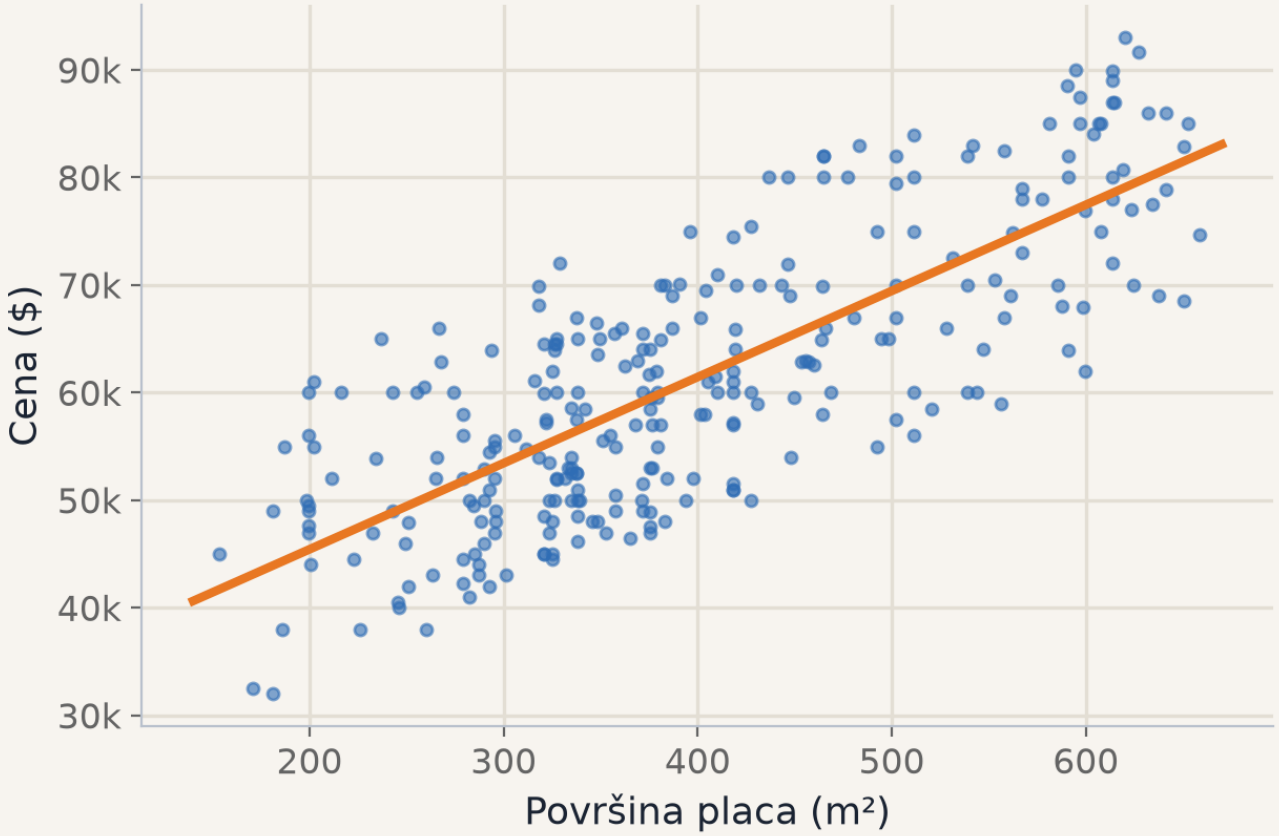


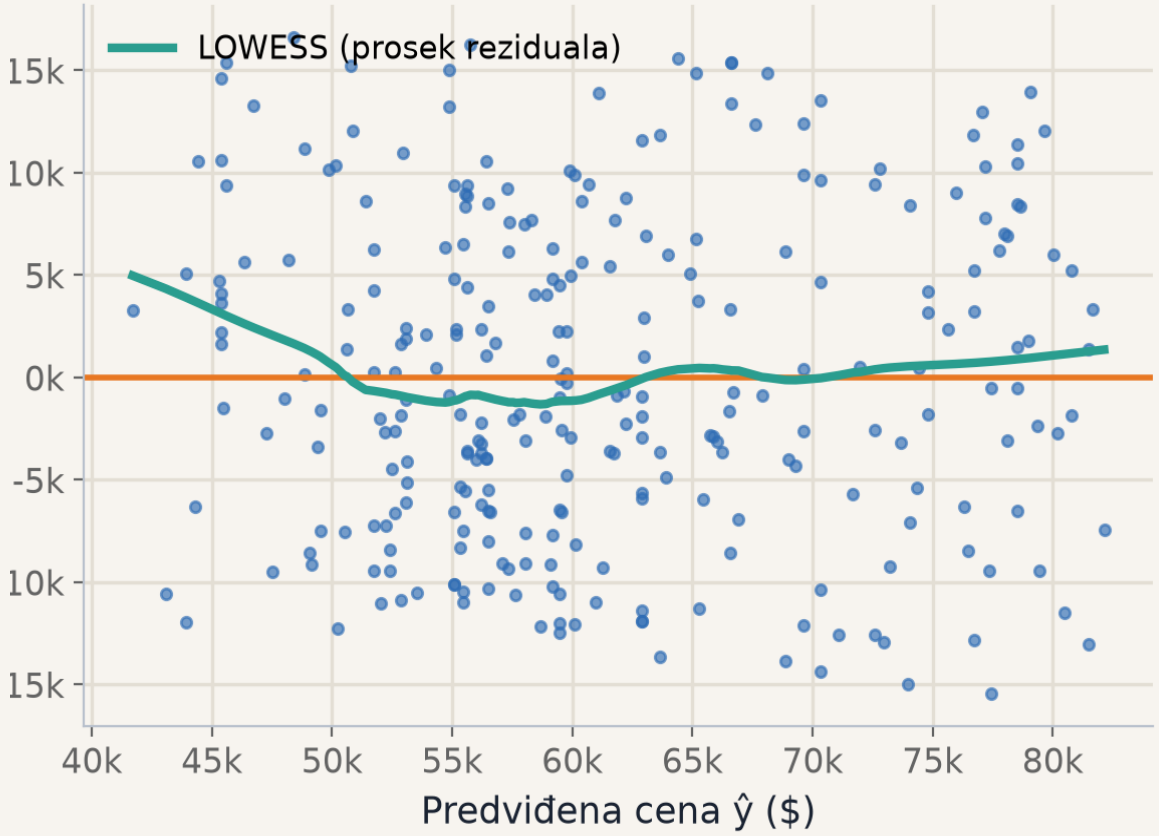
Kuće: nema šablona (grafik na sledećem slajdu), pa pretpostavka važi.

Ako ne važi: transformacija y (log, √). Ako ne pomogne, drugi estimator, npr. ponderisani najmanji kvadrati (WLS).

Kuće: jednaka varijansa važi

Cene kuća su približno jednako rasute oko prave, a reziduali oko nule.





Pretpostavke na jednom mestu

Šta proveravamo, kako, i šta radimo ako ne važi.

Pretpostavka	Kako proveravamo	Ako ne važi	Kuće
L Linearnost	grafik rasipanja, grafik reziduala	transformacija x, nelinearan model	✓
I Nezavisnost	grafik reziduala, Durbin-Watson ∈ [1,5; 2,5]	nove promenljive, modeli za vremenske serije	✓ (1,78)
N Normalnost	histogram, Shapiro-Wilk p ≥ 0.05, LOWESS	veliki n: zanemariti; mali n: log, √	✗ (1), ali n = 280
E Jednaka varijansa	grafik reziduala: levak, mašna	transformacija y, WLS	✓

REZIME

Šta treba da zapamtimo

1. Model: $Y = \beta_0 + \beta_1 \cdot X + \varepsilon$. Iz uzorka procenjujemo b_0 i b_1.
2. Nagib b_1: promena y kada x poraste za 1. Odsečak b_0 često nema značenje.
3. Ne predviđamo daleko van opsega podataka.
4. $p \leq 0{,}05$ i interval poverenja bez nule znače da veza postoji.
5. Interval predikcije (jedna kuća) je širi od intervala poverenja (prosek).
6. P-vrednostima i intervalima poverenja verujemo tek kad proverimo L.I.N.E, najviše pomoću grafika reziduala.

DODATAK

Formule i izvođenja

Formule za b_0 i b_1, zbir reziduala, standardna greška, t-test, intervali, Durbin-Watson.

DODATAK

Formule za b_0 i b_1

Isto kao u predavanju 2 (a i b), samo zapisano preko proseka.

$$b_1 = \frac{\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^{n}(x_i - \bar{x})^2}$$

$$b_0 = \bar{y} - b_1 \bar{x}$$

Kuće:

$\bar{x} = 398{,}4\ m^2,\ \bar{y} = 61.320{,}6\ \$$

$b_1 = 80{,}07$

$b_0 = 61.320{,}6 - 80{,}07 \cdot 398{,}4 = 29.422$

Iz formule za b_0 vidimo: prava uvek prolazi kroz tačku $(\bar{x}, \bar{y})$.

DODATAK

Zašto je zbir reziduala uvek 0?

Sledi direktno iz uslova minimuma po odsečku b_0.

$$SSE(b_0, b_1) = \sum_{i=1}^{n} (y_i - b_0 - b_1 x_i)^2$$

$$\frac{\partial SSE}{\partial b_0} = -2 \sum_{i=1}^{n} (y_i - b_0 - b_1 x_i) = 0$$

$$\Rightarrow \sum_{i=1}^{n} e_i = 0 \quad \Rightarrow \quad \bar{e} = 0$$

Zato prosek svih reziduala ne može da proveri pretpostavku N(2). Važi za svaki model sa odsečkom.

DODATAK

Standardna greška nagiba

Mera koliko bi se b_1 menjao sa drugim uzorkom.

$$s = \sqrt{\frac{SSE}{n-2}}$$

$$SE(b_1) = \frac{s}{\sqrt{\sum_{i=1}^{n}(x_i - \bar{x})^2}}$$

Kuće:

$s = 7.993{,}2$ \$

$\Sigma(x_i - \bar{x})^2 = 4.297.203$

$SE(b_1) = 7.993{,}2 / \sqrt{4.297.203} = 3{,}856$

Više podataka i veći raspon x-a daju veći imenilac, pa manji SE: procena je stabilnija.

DODATAK

t-test i stepeni slobode

Kakve t-vrednosti očekujemo kada je $\beta_1 = 0$?

$$t = \frac{b_1 - 0}{SE(b_1)}$$

Ako je $\beta_1 = 0$, t prati t-raspodelu sa n − 2 stepena slobode (n tačaka, 2 parametra).

Slična je normalnoj, ali ima „deblje repove“.

Kuće:

n − 2 = 278 stepeni slobode

t = 80,07 / 3,856 = 20,76

p < 0,001

p-vrednost je površina ispod t-raspodele levo od −|t| i desno od |t|.

DODATAK

Interval poverenja za β_1

Procena ± margina greške.

$$b_1 \pm t_{\alpha/2,\ n-2} \cdot SE(b_1)$$

α = 0,05 daje pouzdanost (1 − α) · 100% = 95%.

α/2 jer delimo 5% na dve strane: 2,5% levo i 2,5% desno.

$t_{0,025;278}$ = 1,969 (za veliko n je oko 2).

Kuće:

80,07 ± 1,969 · 3,856

= 80,07 ± 7,59

= [72,48; 87,66]

DODATAK

Interval predikcije

Tri izvora nesigurnosti pod korenom.

$$\hat{y}^* \pm t_{\alpha/2,\ n-2} \cdot s \cdot \sqrt{1 + \frac{1}{n} + \frac{(x^* - \bar{x})^2}{\sum_{i=1}^{n} (x_i - \bar{x})^2}}$$

1: greška ε jedne kuće (zato je širi od intervala poverenja).

1/n: nesigurnost procene prave; manja za veće n.

$(x^* - \bar{x})^2$: što je novi plac x^* dalje od sredine podataka, interval je širi.

Kuće, $x^* = 658{,}48\ m^2$:

$\hat{y}^* = 82.144\ \$$

koren $\approx 1{,}0096$

$82.144 \pm 1{,}969 \cdot 7.993 \cdot 1{,}0096$

$= [66.258;\ 98.030]\ \$$

DODATAK

Durbin-Watson i Shapiro-Wilk

Kako se tumače rezultati dva testa.

$$DW = \frac{\sum_{i=2}^{n} (e_i - e_{i-1})^2}{\sum_{i=1}^{n} e_i^2}$$

DW ≈ 2 · (1 − r_1), gde je r_1 korelacija susednih reziduala.

r_1 = 0 daje DW ≈ 2: greške nezavisne.

Ima smisla samo kada su podaci poređani, npr. po vremenu. Kuće u našem skupu su poređane po površini placa.

Shapiro-Wilk

Proverava da li podaci (ovde reziduali) dolaze iz normalne raspodele.

p ≥ 0,05: nema dokaza protiv normalnosti.

p < 0,05: reziduali nisu normalni.

Kuće: $p = 3{,}8 \cdot 10^{-5}$