

АСП Пројекат 2

Последња измена: 11.06.2026.

Имплементирати апликацију која симулира рад дела друштвене мреже.

Уз задатак ће бити приложени фајлови **users.txt**, **connections.txt** и **blocked.txt**. Скуп података је подељен у 3 величине, мали, средњи и пун скуп података. Мали и средњи скуп могу бити корисни приликом развоја пројекта, док се пун скуп може искористити за проверу перформанси алгоритама када се ради са великим бројем података. Обавезно је користити приложени скуп података. Скуп података је формиран комбиновањем реалне структуре графа друштвене мреже и реалистичних корисничких профила. Везе између корисника представљају усмерени граф праћења, док су корисничка имена и описи профила припремљени тако да омогуће смислено тестирање претраге, *autocomplete* функционалности и хибридних препорука.

Фајл **users.txt** садржи податке о корисницима у формату:

`id|username|bio`

где *id* представља јединствени идентификатор корисника, *username* корисничко име, а *bio* текстуални опис профила корисника.

Фајл **connections.txt** садржи податке о везама праћења у формату:

`from_id|to_id`

где *from_id* представља корисника који прати, а *to_id* корисника који је праћен.

Фајл **blocked.txt** садржи податке о блокираним корисницима у формату:

`blocker_id|blocked_id`

где *blocker_id* представља корисника који је блокирао другог корисника, *blocked_id* корисника који је блокира.

Приликом покретања учитати садржај фајлова и креирати структуре података за ефикасно претраживање, рангирање и препоруку корисника.

1. (2 поена) Изградња графа друштвене мреже: Креирати класе *User* и *SocialGraph*. За сваког корисника чувати идентификатор, корисничко име и биографију. Везе праћења представити усмереним графом. Омогућити ефикасно чување излазних веза, улазних веза и излазног степена сваког корисника. За брзо проналажење корисника користити *hash* мапе.

2. (3 поена) Рангирање утицаја корисника: Имплементирати итеративни *PageRank* алгоритам над графом праћења. Користити *damping factor* 0.85 и зауставити алгоритам када се достигне конвергенција, нпр. *epsilon* = $1e-6$. Омогућити приказ најутицајнијих корисника. За приказ *top* резултата користити *heap*.

Након додавања новог корисника или нове везе потребно је поново израчунати *PageRank*. Дозвољено је користити претходно израчунате *PageRank* вредности као почетну тачку за ново рачунање (*warm start*).

3. (2 поена) Претрага корисника: Омогућити претрагу корисника по корисничком имену и по речима из биографије. Биографија представља текстуални опис профила. Потребно је извршити једноставну обраду текста, на пример пребацивање у мала слова, уклањање непотребних знакова и издвајање речи. За ефикасну претрагу по речима из биографије формирати *inverted index* (структура података која мапира сваку реч на листу корисника чије биографије садрже ту реч). Претрага не треба да буде осетљива на разлику у величини слова. Резултате претраге рангирати на основу релевантности упита и *PageRank* вредности корисника. За приказ *top* резултата користити *heap*.
4. (2 поена) Евидентирати додавање нових веза праћења. За задатог корисника омогућити приказ историје интеракција, односно корисника које је запратио и корисника који су њега запратили. Исписе приказати у хронолошком редоследу. За чување историје могу се користити одговарајуће структуре података.
5. (1 поен) Текстуални мени: Омогућити кориснику да преко текстуалног менија бира опције за претрагу, приказ најутицајнијих корисника, додавање нове везе праћења, приказ историје интеракција и излазак из програма.

Основни део, до 10 поена

Имплементирати задатке 1, 2, 3, 4 и 5. У задатку 2 потребно је коректно имплементирати *PageRank* алгоритам и омогућити приказ *top* корисника. У задатку 3 потребно је омогућити претрагу по корисничком имену и по речима из биографије, уз рангирање резултата на основу релевантности и *PageRank* вредности.

Додатни део, до укупно 25 поена

Резултате претраге, *autocomplete*-а и препорука приказивати рангирано, тако да се прво приказују релевантнији резултати, а у случају сличне релевантности корисници са већом *PageRank* вредношћу. *PageRank* вредност представља меру утицаја корисника у графу праћења.

6. (3 поена) *Trie* и *autocomplete*: Ефикасну префиксну претрагу корисничких имена подржати помоћу структуре података *trie*. Одабиром *autocomplete* опције, кориснику се нуди неколико популарних завршетака задатог упита.

На пример, ако корисник унесе *mar** понуђене опције могу бити *marko_ai*, *maria_dev* или *marketing_notes*, у зависности од постојећих корисничких имена. Претрага треба да ради у *case insensitive* режиму. Резултате сортирати на основу *PageRank* вредности корисника.

7. (2 поена) Хибридне препоруке корисника: За задатог корисника предложити кориснике које још не прати, а који су релевантни на основу графа праћења и садржаја биографија. Препорука треба да комбинује *Personalized PageRank (PPR)* из перспективе задатог корисника и сличност биографија. Комбиновани скор рачунати у облику:

$$\alpha \times PPR + (1 - \alpha) \times content_similarity$$

Кориснику омогућити да изабере вредност параметра α .

Personalized PageRank (PPR) је варијанта *PageRank* алгоритма у којој се рангирање рачуна из перспективе једног задатог корисника. Интуитивно, при насумичној шетњи кроз граф постоји вероватноћа да се шетња врати назад на почетног корисника и поново крене од његовог чвора. Због тога корисници који су ближи и релевантнији за почетног корисника добијају већи значај.

Сличност биографија може се рачунати помоћу *Jaccard* сличности, једноставне *Cosine* сличности или неке друге мере сличности текста по избору студента.

Jaccard сличност две биографије рачуна се тако што се свака биографија представи као скуп речи. Затим се број заједничких речи подели бројем различитих речи које се појављују у бар једној од те две биографије. Већа вредност значи да су биографије сличније.

$$J(A, B) = |A \cap B| / |A \cup B|$$

Cosine сличност се може рачунати тако што се свака биографија представи као вектор речи. Вредности у вектору могу бити број појављивања речи или 0/1 вредности које означавају да ли се реч појављује у биографији. Сличност се затим добија као косинус угла између та два вектора.

$$Cosine(A, B) = (A \cdot B) / (||A|| * ||B||)$$

8. (3 поена) Обилазак мреже: Имплементирати обилазак графа праћења помоћу *BFS* алгоритма. За задатог корисника приказати ко су његове прве, друге, треће и даље конекције. Корисник може да зада до ког нивоа жели да се врши претрага. Ниво 1 представља директне follow везе, ниво 2 кориснике до којих се стиже преко једног посредника, ниво 3 кориснике до којих се стиже преко два посредника, итд. Потребно је водити рачуна да се исти корисник не обрађује више пута.

9. (3 поена) “*Did you mean*”: У случају да је приликом уноса корисничког имена дошло до грешке, односно уколико задати корисник не постоји, понудити неколико сличних исправних могућности.
10. (2 поена) Блокирани корисници: Из фајла *blocked.txt* учитати податке о томе који корисник је блокирао ког другог корисника. Приликом препоруке корисника, не приказивати кориснике које је задати корисник блокирао, као ни кориснике који су блокирали њега. Приликом додавања нове везе, проверити да ли између та два корисника постоји блокирање у било ком смеру и, ако постоји, забранити додавање везе уз адекватно обавештење.
11. (1 поен) Квалитет кода, *OOP* и документација: Код треба да буде јасно организован, подељен у класе и функције, без непотребног понављања. Обавезно је приложити *README.md* фајл у коме је описано како се програм покреће, који су улазни фајлови потребни и које су имплементирани функционалности.
12. (1 поен) Ефикасан рад над приложеним скупом података: Апликација треба да ради над приложеним скупом података без поновног учитавања и поновног формирања структура при свакој операцији. Пожељно је да се након покретања програма формирају све потребне структуре података за претрагу, рангирање, препоруке и обилазак графа. Време од покретања до извођења прве операције у апликацији не би требало да траје предуго. За *medium* скуп очекује се интерактиван рад. За *full* скуп потребно је документовати време учитавања и време извршавања најскупљих операција.

Опште информације о слању задатка:

- Задатак носи 25 поена.
- Обавезно је користити приложени скуп података. Апликација мора радити над све три величине скупа. За развој се препоручује *small*, за демонстрацију *medium*, а *full* се користи за проверу перформанси.
- Сместити све фајлове задатка у folder под називом *projekat2_sv_XX_YYYY* где се уместо *XX_YYYY* наводи број индекса - број уписа и година уписа (пример: *projekat2_sv_02_2025*).
- Убацити фајл у *zip* архиву и назвати је исто као и задатак (*projekat2_sv_XX_YYYY.zip*).
- Upload-овати *zip* архиву као *assignment* на Канвас.
- Уколико буде проблема са *upload*-ом, можете у предвиђеном року послати *zip* на email адресу предметног асистента.